Исследование объявлений о продаже квартир

В вашем распоряжении данные сервиса Яндекс.Недвижимость — архив объявлений о продаже квартир в Санкт-Петербурге и соседних населённых пунктов за несколько лет. Нужно научиться определять рыночную стоимость объектов недвижимости. Ваша задача — установить параметры. Это позволит построить автоматизированную систему: она отследит аномалии и мошенническую деятельность.

По каждой квартире на продажу доступны два вида данных. Первые вписаны пользователем, вторые — получены автоматически на основе картографических данных. Например, расстояние до центра, аэропорта, ближайшего парка и водоёма.

Откройте файл с данными и изучите общую информацию.

In [ ]:
```
import pandas as pd
import matplotlib.pyplot as plt
```

In [ ]:
```
data = pd.read_csv('/datasets/real_estate_data.csv',  sep='\t')
data.info() #выводим общую информацию
data.head() #выводим первые пять строк таблицы
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 23699 entries, 0 to 23698
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype  
---  ------                --------------  -----  
 0   total_images          23699 non-null  int64  
 1   last_price            23699 non-null  float64
 2   total_area            23699 non-null  float64
 3   first_day_exposition  23699 non-null  object 
 4   rooms                 23699 non-null  int64  
 5   ceiling_height        14504 non-null  float64
 6   floors_total          23613 non-null  float64
 7   living_area           21796 non-null  float64
 8   floor                 23699 non-null  int64  
 9   is_apartment          2775 non-null   object 
 10  studio                23699 non-null  bool   
 11  open_plan             23699 non-null  bool   
 12  kitchen_area          21421 non-null  float64
 13  balcony               12180 non-null  float64
 14  locality_name         23650 non-null  object 
 15  airports_nearest      18157 non-null  float64
 16  cityCenters_nearest   18180 non-null  float64
 17  parks_around3000      18181 non-null  float64
 18  parks_nearest         8079 non-null   float64
 19  ponds_around3000      18181 non-null  float64
 20  ponds_nearest         9110 non-null   float64
 21  days_exposition       20518 non-null  float64
dtypes: bool(2), float64(14), int64(3), object(3)
memory usage: 3.7+ MB
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	balcon
0	20	13000000.0	108.0	2019-03-07T00:00:00	3	2.70	16.0	51.0	8	NaN	...	25.0	Nal
1	7	3350000.0	40.4	2018-12-04T00:00:00	1	NaN	11.0	18.6	1	NaN	...	11.0	2.
2	10	5196000.0	56.0	2015-08-20T00:00:00	2	NaN	5.0	34.3	4	NaN	...	8.3	0.
3	0	64900000.0	159.0	2015-07-24T00:00:00	3	NaN	14.0	NaN	9	NaN	...	NaN	0.
4	2	10000000.0	100.0	2018-06-19T00:00:00	2	3.03	14.0	32.0	13	NaN	...	41.0	Nal

5 rows × 22 columns

In [ ]:
```
data.hist(figsize=(15, 20))
plt.show()
```

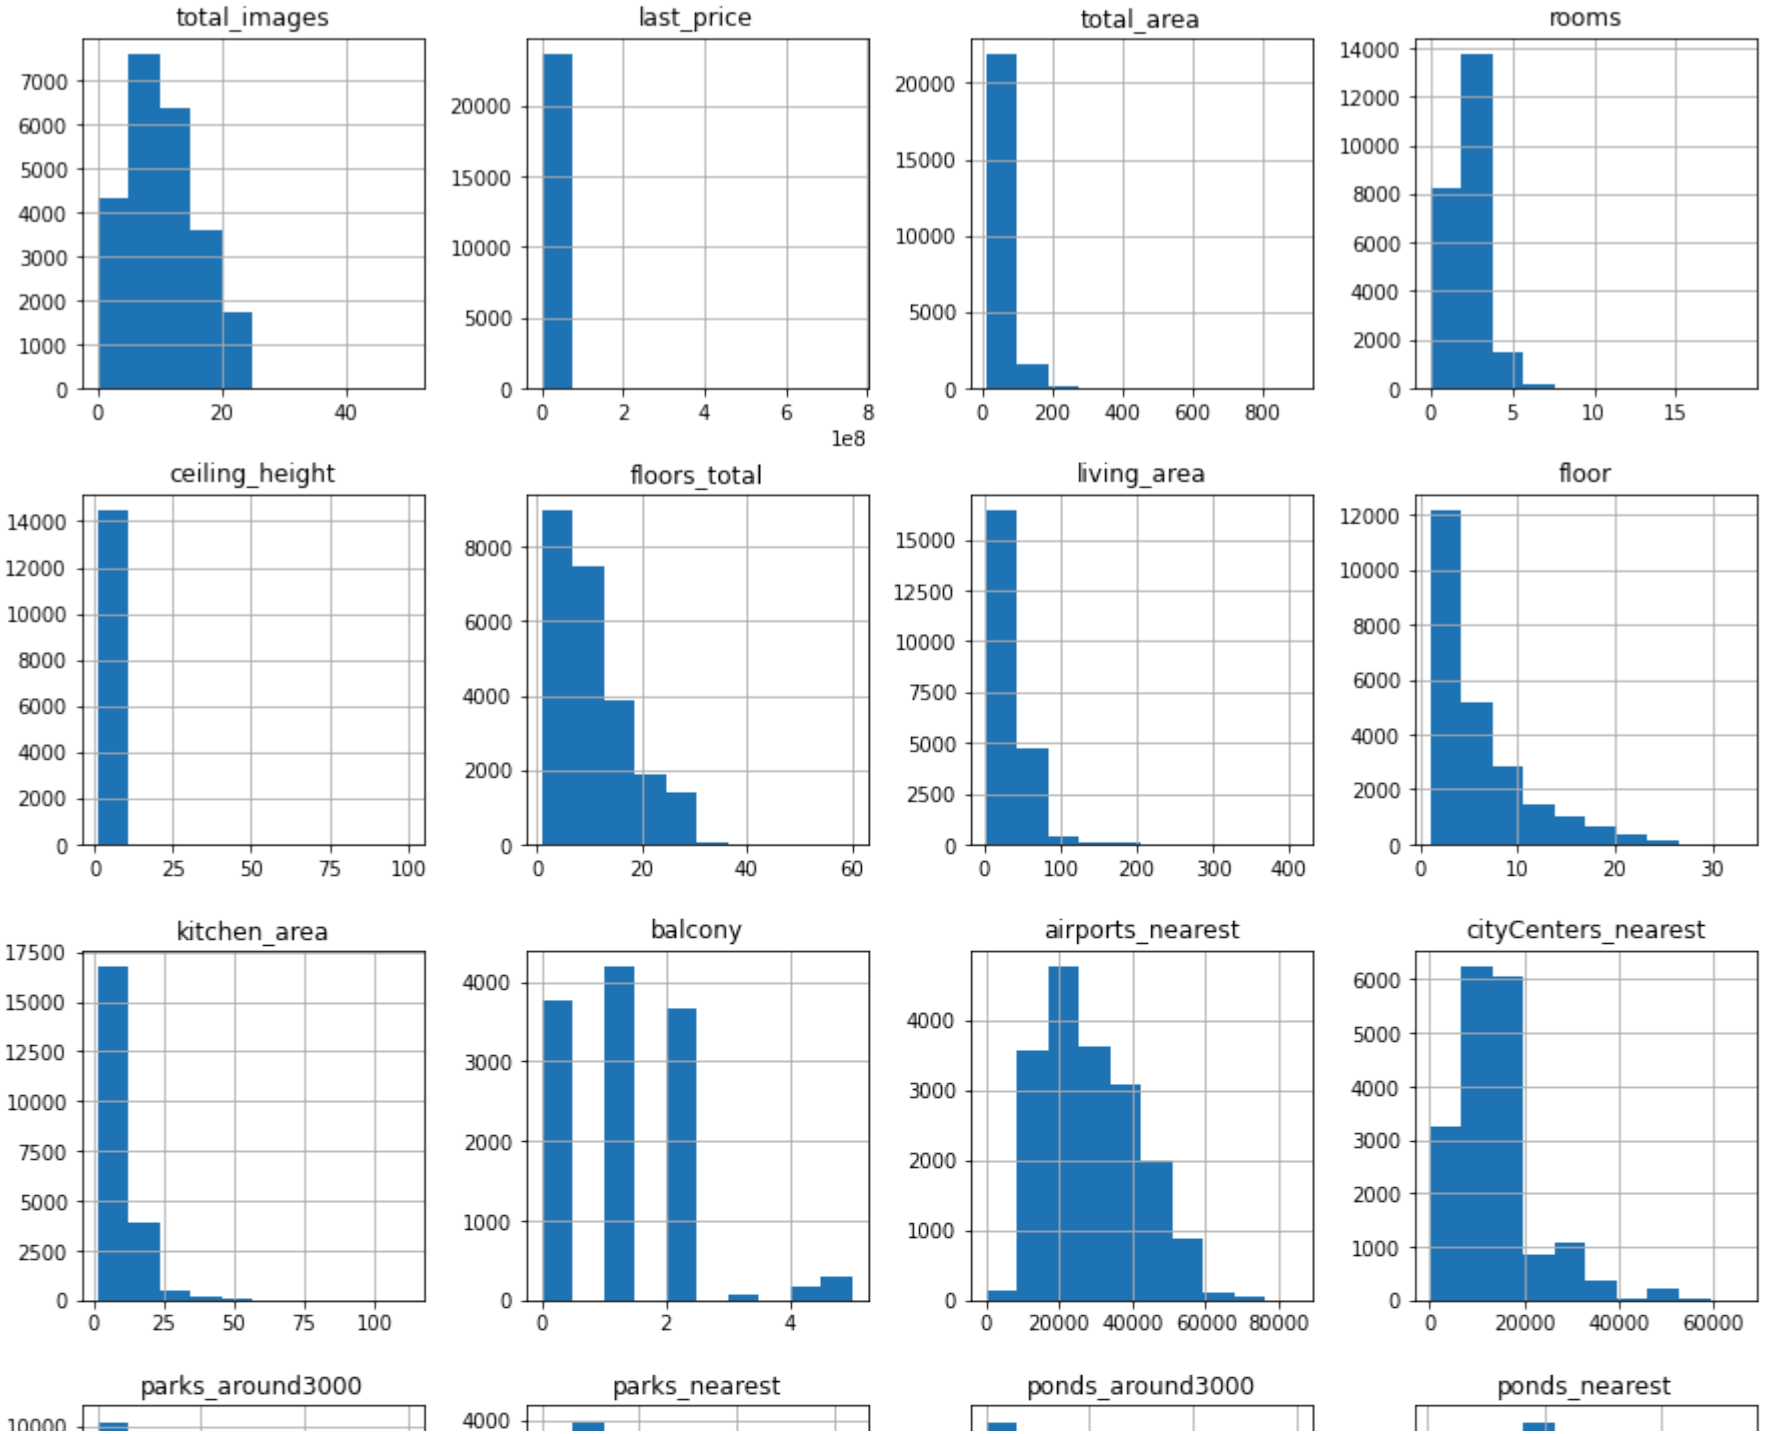
total_images
last_price
1e8
total_area
rooms
ceiling_height
floors_total
living_area
floor
kitchen_area
balcony
airports_nearest
cityCenters_nearest
parks_around3000
parks_nearest
ponds_around3000
ponds_nearest

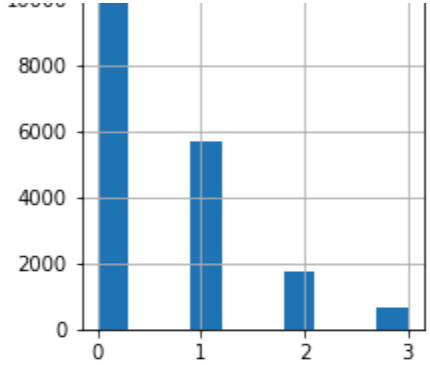

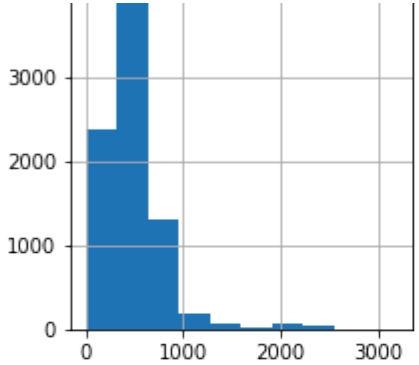

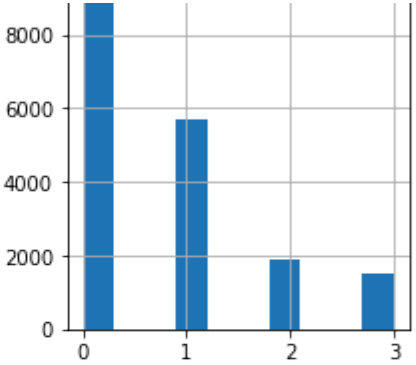

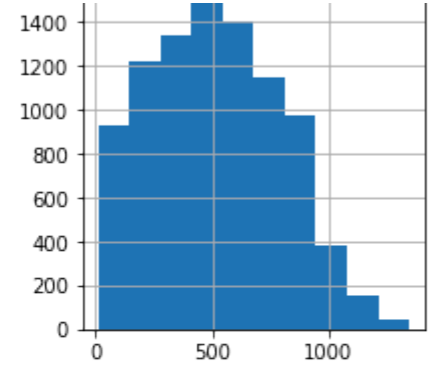

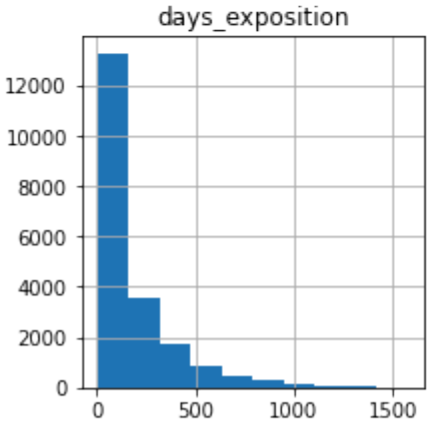

Предобработка данных

In [ ]:
```
data.isna().sum() # определяем количество пропусков в каждом столбце
```

Out[ ]:
```
total_images               0
last_price                 0
total_area                 0
first_day_exposition       0
rooms                      0
ceiling_height          9195
floors_total              86
living_area             1903
floor                      0
is_apartment           20924
studio                     0
open_plan                  0
kitchen_area            2278
balcony                11519
locality_name             49
airports_nearest        5542
cityCenters_nearest     5519
parks_around3000        5518
parks_nearest          15620
ponds_around3000        5518
ponds_nearest          14589
days_exposition         3181
dtype: int64
```

Высота потолка ceiling_height

> В 9195 строках не указана высота потолка. Можно предположить, что это квартиры с так называемым "стандартным" потолком, т.к если бы потолки были высокими, то, скорее всего, это было бы указано. Соответственно, заменим отстуствующие значения на среднюю высоту потолка. Воспользуемся медианой, чтобы не включать в среднее значение экстримальные показатели.

In [ ]:
```
data['ceiling_height'].describe()
```

Out[ ]:
```
count    14504.000000
mean         2.771499
std          1.261056
min          1.000000
25%          2.520000
50%          2.650000
75%          2.800000
max        100.000000
Name: ceiling_height, dtype: float64
```

Видим очевидные аномальные значения минимума 1 м. и максимума 100 м.

In [ ]:
```
data['ceiling_height'].hist(bins = 10, figsize = (7,5), range = (0,40));
```

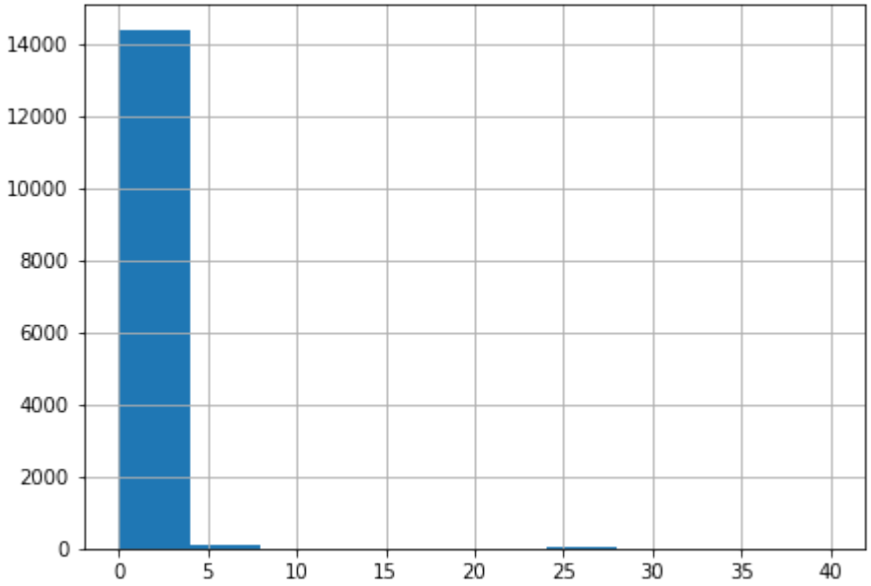

Видим, что большая часть потолков 2-4,5 м. Есть значения в районе 25ти. Скорее всего это неверно записанные данные. Проверим

In [ ]:
```
data.query('ceiling_height>20')
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	ba
355	17	3600000.0	55.2	2018-07-12T00:00:00	2	25.0	5.0	32.0	2	False	...	NaN	
3148	14	2900000.0	75.0	2018-11-12T00:00:00	3	32.0	3.0	53.0	2	NaN	...	8.0	
4643	0	4300000.0	45.0	2018-02-01T00:00:00	2	25.0	9.0	30.0	2	NaN	...	7.0	
4876	7	3000000.0	25.0	2017-09-27T00:00:00	0	27.0	25.0	17.0	17	NaN	...	NaN	
5076	0	3850000.0	30.5	2018-10-03T00:00:00	1	24.0	5.0	19.5	1	True	...	5.5	
5246	0	2500000.0	54.0	2017-10-13T00:00:00	2	27.0	5.0	30.0	3	NaN	...	9.0	
5669	4	4400000.0	50.0	2017-08-08T00:00:00	2	26.0	9.0	21.3	3	NaN	...	7.0	
5807	17	8150000.0	80.0	2019-01-09T00:00:00	2	27.0	36.0	41.0	13	NaN	...	12.0	
6246	6	3300000.0	44.4	2019-03-25T00:00:00	2	25.0	5.0	31.3	5	NaN	...	5.7	
9379	5	3950000.0	42.0	2017-03-26T00:00:00	3	25.0	5.0	30.0	2	NaN	...	5.2	
10773	8	3800000.0	58.0	2017-10-13T00:00:00	2	27.0	10.0	30.1	3	False	...	8.1	
11285	0	1950000.0	37.0	2019-03-20T00:00:00	1	25.0	5.0	17.0	4	False	...	9.0	
14382	9	1700000.0	35.0	2015-12-04T00:00:00	1	25.0	5.0	20.0	2	False	...	8.0	
17857	1	3900000.0	56.0	2017-12-22T00:00:00	3	27.0	5.0	33.0	4	False	...	NaN	
18545	6	3750000.0	43.0	2019-03-18T00:00:00	2	25.0	5.0	29.0	3	False	...	NaN	
20478	11	8000000.0	45.0	2017-07-18T00:00:00	1	27.0	4.0	22.0	2	NaN	...	10.0	
20507	12	5950000.0	60.0	2018-02-19T00:00:00	2	22.6	14.0	35.0	11	NaN	...	13.0	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	ba
21377	19	4900000.0	42.0	2017-04-18T00:00:00	1	27.5	24.0	37.7	19	False	...	11.0	
21824	20	2450000.0	44.0	2019-02-12T00:00:00	2	27.0	2.0	38.0	2	False	...	8.6	
22336	19	9999000.0	92.4	2019-04-05T00:00:00	2	32.0	6.0	55.5	5	False	...	16.5	
22869	0	15000000.0	25.0	2018-07-25T00:00:00	1	100.0	5.0	14.0	5	True	...	11.0	
22938	14	4000000.0	98.0	2018-03-15T00:00:00	4	27.0	2.0	73.0	2	True	...	9.0	

Действительно похоже, что кроме 100, в значениях просто потеряна запятая. Исправим

In [ ]:
```
data.loc[data['ceiling_height'] > 20, 'ceiling_height'] /= 10
```

In [ ]:
```
data.query('ceiling_height>20')#проверим
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	balcony

0 rows × 22 columns

In [ ]:
```
data.query('ceiling_height >= 6 or ceiling_height <= 2 ').count()
```

Out[ ]:
```
total_images            23
last_price              23
total_area              23
first_day_exposition    23
rooms                   23
ceiling_height          23
floors_total            23
living_area             21
floor                   23
is_apartment             3
studio                  23
open_plan               23
kitchen_area            19
balcony                  9
locality_name           23
airports_nearest        13
cityCenters_nearest     13
parks_around3000        13
parks_nearest            8
ponds_around3000        13
ponds_nearest            8
days_exposition         19
dtype: int64
```

23 строки со значением потолка выше 6 метров и ниже 2 м. Это меньше одного процента. Удалим их. Пропуски оставим

In [ ]:
```
data = data.loc[(data['ceiling_height'] <= 6)&(data['ceiling_height'] >= 2)|(data['ceiling_height']).isna()]
```

Количество этажей в доме floors_total

> Скорее всего значения в этих строках отсутствуют потому, что эти дома одноэтажные. Поэтому заменим значения ячеек на 1. В любом случае, эти строки не должны сильно повлиять на результат исследования, т.к их количество незначительно (86 строк)

In [ ]:
```
data['floors_total'] = data['floors_total'].fillna(1)#заменяем значения NAN на 1 в столбце количества этажей в доме
data['floors_total'] = data['floors_total'].astype(int)#поменяем тип данных на целочисленный
```

Жилая площадь living_area

> Выбирая квартиру, покупатели чаще ориентируются на общую площадь квартиры, а не на жилую площадь. Поэтому пока оставим ячейки как есть.

In [ ]:
```
data[['living_area']].apply (['count', 'min', 'max']).style.format("{:,.2f}")
```

Out[ ]:

	living_area
count	21,785.00
min	2.00
max	409.70

In [ ]:
```
data['living_area'].hist(bins = 15, figsize = (7,5));
```

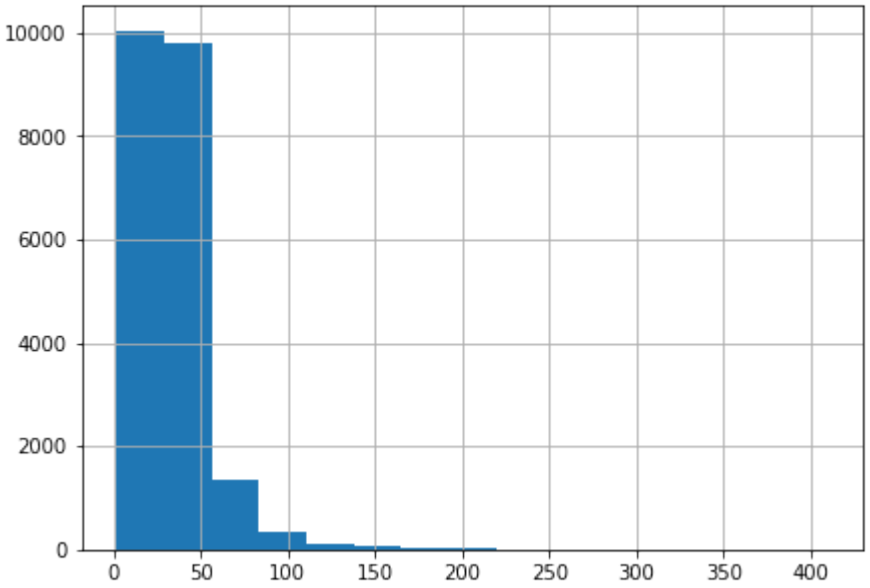

Количество квартир с жилой площадью больше 130 кв.м. резко снижается. Посчитаем сколько их

In [ ]:
```
data.query('living_area > 130').count()
```

Out[ ]:
```
total_images            176
last_price              176
total_area              176
first_day_exposition    176
rooms                   176
ceiling_height          118
floors_total            176
living_area             176
floor                   176
is_apartment             15
studio                  176
open_plan               176
kitchen_area            164
balcony                  86
locality_name           176
airports_nearest        171
cityCenters_nearest     174
parks_around3000        174
parks_nearest           124
ponds_around3000        174
ponds_nearest           128
days_exposition         137
dtype: int64
```

176 строк это меньше 1%, можно удалить эти строки,как редкие.

In [ ]:
```
data = data.loc[(data['living_area'] < 130)|(data['living_area'].isna())]
```

Количество балконов balcony

> Отсутствующие значения количества балконов заменим на 0, т.к. скорее всего они не указаны по причине отсутствия балкона в квартире.

In [ ]:
```
data['balcony'] = data['balcony'].fillna(0) #заменяем значения NAN на 0 в столбце количества балконов
data['balcony'] = data['balcony'].astype(int) #заменим тип данных на целочисленный.
```

Площадь kitchen_area

> Пока не хватает данных, чтобы сделать замену отсутстсвующих значений по площади кухни. Ни среднее арифметическое, ни медиана не подходят, т.к все квартиры отличаются площадью и брать средеее просто некорректно. Можем

> предположить, что площадь кухни не указана в апартаментах и студиях, т.к она объединина с жилой и общей площадью.

Проверим это предположение, построив графики зависимости отсутствия значения о площади кухни в апартаментах и студиях

In [ ]:
```
no_kitch_sq = data[data['kitchen_area'].isnull()] #вводим переменную со значением NaN в столбце площадь кухни
#строим график, проверяем в скольких апартаментах не указана площадь кухни
no_kitch_sq['is_apartment'].value_counts().plot(kind='pie', figsize = (7,7))
plt.show() #убираем служебную информацию
#строим график, проверяем в скольких студиях не указана площадь кухни
no_kitch_sq['studio'].value_counts().plot(kind='pie', figsize = (7,7))
plt.show()
```

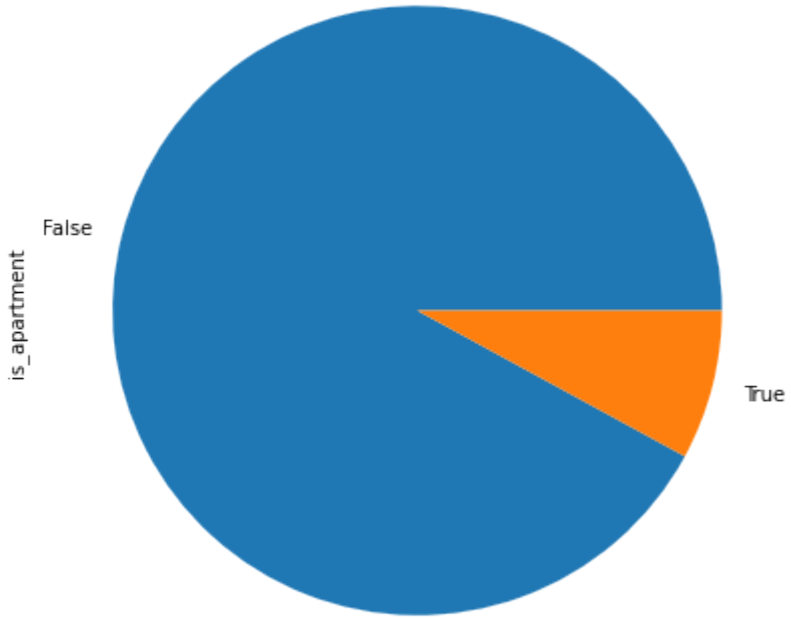

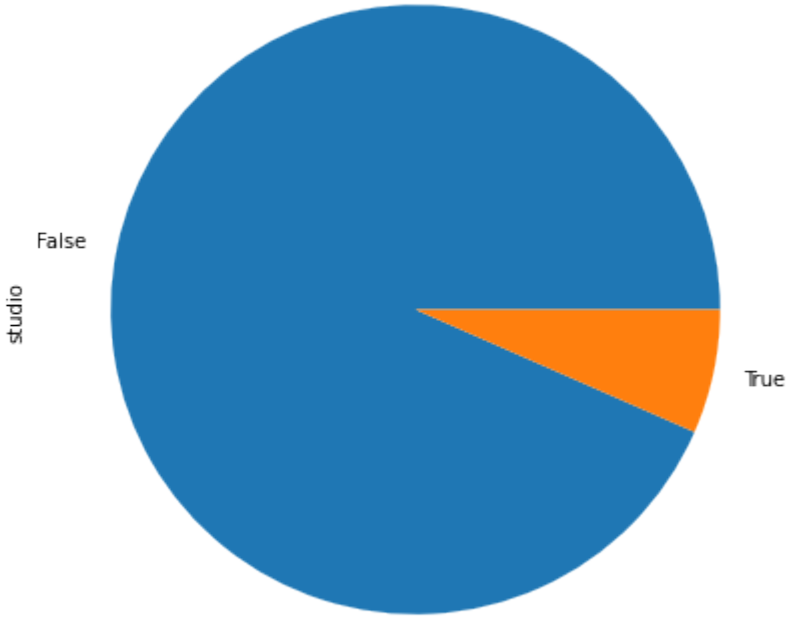

In [ ]:
```
data[['kitchen_area']].apply (['count', 'min', 'max']).style.format("{:,.2f}")
```

Out[ ]:

	kitchen_area
count	21,244.00
min	1.30
max	107.00

In [ ]:
```
data['kitchen_area'].hist(bins = 15, figsize = (7,5));
```

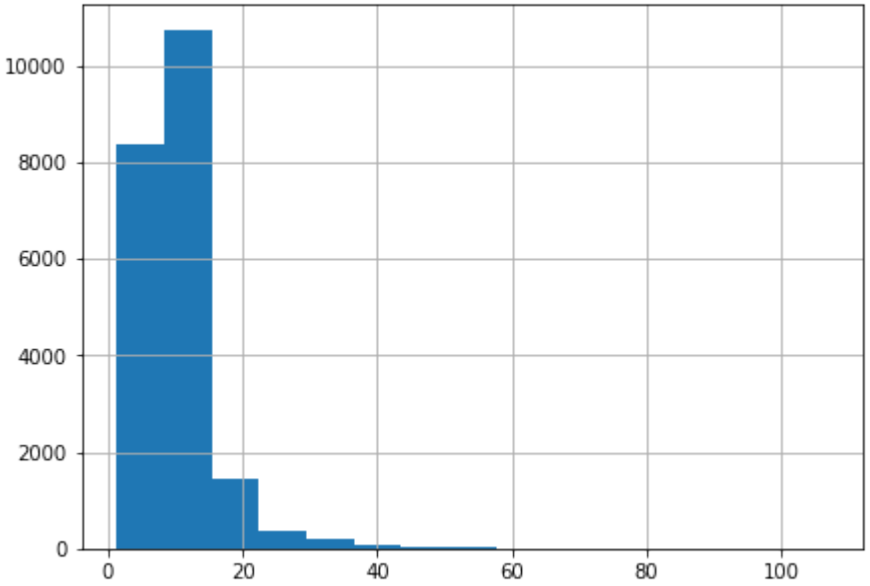

Значения больше 50 довольно редки, посчитаем их

In [ ]:
```
data.query('kitchen_area > 50').count()
```

Out[ ]:
```
total_images            35
last_price              35
total_area              35
first_day_exposition    35
rooms                   35
ceiling_height          25
floors_total            35
living_area             33
floor                   35
is_apartment             5
studio                  35
open_plan               35
kitchen_area            35
balcony                 35
locality_name           35
airports_nearest        34
cityCenters_nearest     34
parks_around3000        34
parks_nearest           24
ponds_around3000        34
ponds_nearest           20
days_exposition         28
dtype: int64
```

35 строк. Можем удалить, как редко встречающиеся

In [ ]:
```
data = data.loc[(data['kitchen_area'] < 50)|(data['kitchen_area'].isna())]
```

По графикам видно, что отсутствие данных о площади кухни никак не зависит от того квартира это, апартаменты или студия. Оставим значения ячеек как есть.

Город locality_name

> 49 строк с пропущенными значениями местоположения квартир удалим из датафрейма. Т.к расположение является одним из главных критереев выбора жилья, строки где этих значений нет, не имеют смысла.

In [ ]:
```
data.loc[data['locality_name'].isna() == True] #посмотрим на данные без указания населенного пункта
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	ba
1097	3	8600000.0	81.70	2016-04-15T00:00:00	3	3.55	5	50.80	2	NaN	...	8.80	
2033	6	5398000.0	80.00	2017-05-30T00:00:00	3	NaN	4	42.60	2	NaN	...	18.60	
2603	20	3351765.0	42.70	2015-09-20T00:00:00	1	NaN	24	15.60	3	NaN	...	10.70	
2632	2	5130593.0	62.40	2015-10-11T00:00:00	2	NaN	24	33.10	21	NaN	...	8.20	
3574	10	4200000.0	46.50	2016-05-28T00:00:00	2	NaN	5	30.80	5	NaN	...	6.50	
4151	17	17600000.0	89.50	2014-12-09T00:00:00	2	3.00	8	39.62	7	NaN	...	13.38	
4189	7	9200000.0	80.00	2015-12-10T00:00:00	3	4.00	4	52.30	3	False	...	10.40	
4670	1	5500000.0	83.00	2015-08-14T00:00:00	3	NaN	7	NaN	6	NaN	...	NaN	
5343	19	13540000.0	85.50	2016-01-20T00:00:00	3	NaN	7	59.10	5	False	...	8.30	
5707	7	3700000.0	30.00	2016-04-29T00:00:00	1	NaN	24	20.00	23	NaN	...	NaN	
6765	20	4895892.0	60.70	2015-03-12T00:00:00	2	NaN	24	31.90	3	NaN	...	12.20	
7114	5	4250000.0	56.00	2016-03-16T00:00:00	3	NaN	5	40.00	4	NaN	...	6.00	
7330	8	5100000.0	63.00	2015-01-27T00:00:00	3	NaN	5	42.00	1	False	...	7.50	
7600	8	6800000.0	70.00	2016-01-31T00:00:00	3	NaN	11	42.00	9	NaN	...	11.00	
8568	10	16000000.0	155.00	2016-05-09T00:00:00	3	NaN	6	94.00	3	NaN	...	23.00	
8986	10	4850000.0	103.10	2018-07-10T00:00:00	3	NaN	1	68.10	4	NaN	...	16.70	
9821	13	8000000.0	94.50	2015-01-21T00:00:00	4	3.00	2	57.80	2	NaN	...	11.30	
10122	5	8200000.0	83.00	2015-06-24T00:00:00	4	NaN	5	53.00	2	NaN	...	10.00	
11248	12	6300000.0	63.10	2015-01-16T00:00:00	4	NaN	8	44.00	7	NaN	...	8.70	
12879	12	4400000.0	39.20	2016-04-26T00:00:00	1	NaN	12	20.00	12	False	...	7.90	
12936	6	6800000.0	73.00	2015-11-01T00:00:00	3	NaN	5	53.10	2	NaN	...	8.20	
13223	1	2919911.0	29.40	2015-03-12T00:00:00	1	2.75	24	21.10	2	NaN	...	NaN	
13690	7	3500000.0	71.00	2016-06-23T00:00:00	3	2.75	2	45.60	1	False	...	8.00	
14273	2	4422000.0	60.00	2016-03-23T00:00:00	2	2.75	23	32.00	14	NaN	...	11.90	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	ba
14342	3	3611000.0	53.50	2017-04-27T00:00:00	1	NaN	4	25.80	3	False	...	NaN	
15686	13	4700000.0	44.00	2015-12-01T00:00:00	2	NaN	5	28.00	3	NaN	...	5.00	
15866	10	3950000.0	44.00	2016-04-16T00:00:00	2	2.70	5	28.50	5	False	...	5.50	
16499	2	4995573.0	56.90	2016-06-17T00:00:00	2	NaN	24	29.20	14	NaN	...	10.90	
16561	3	2450000.0	30.00	2016-06-02T00:00:00	1	NaN	4	17.00	2	NaN	...	6.00	
16610	11	11940000.0	112.00	2015-11-19T00:00:00	3	3.00	5	64.00	2	NaN	...	23.00	
17535	2	5985000.0	79.80	2018-07-30T00:00:00	3	NaN	9	NaN	2	False	...	NaN	
17764	9	8400000.0	94.00	2016-01-24T00:00:00	3	NaN	23	52.00	5	NaN	...	NaN	
18526	3	10800000.0	86.00	2016-06-24T00:00:00	4	3.20	7	48.00	2	NaN	...	12.00	
18917	3	2660000.0	37.99	2017-08-17T00:00:00	1	NaN	4	13.00	1	NaN	...	12.40	
19045	6	4650000.0	48.00	2016-01-25T00:00:00	2	3.12	5	26.20	1	False	...	8.00	
19972	20	4361004.0	62.40	2015-09-20T00:00:00	2	NaN	24	33.10	21	NaN	...	8.20	
20057	13	11500000.0	102.00	2015-10-14T00:00:00	2	NaN	5	70.00	2	NaN	...	NaN	
20382	8	1750000.0	72.90	2018-10-27T00:00:00	3	NaN	5	47.30	2	NaN	...	8.30	
20590	7	3380000.0	56.00	2017-11-06T00:00:00	2	2.70	4	29.00	3	NaN	...	10.00	
20654	7	6100000.0	43.00	2016-01-13T00:00:00	1	NaN	5	21.00	3	NaN	...	12.00	
21119	8	3500000.0	43.20	2018-11-11T00:00:00	2	NaN	4	NaN	2	NaN	...	NaN	
21276	0	17122148.0	178.30	2017-02-10T00:00:00	1	NaN	3	NaN	1	NaN	...	41.60	
21333	10	5900000.0	58.00	2015-03-12T00:00:00	3	NaN	6	35.20	6	False	...	11.00	
21715	2	6047550.0	80.10	2018-07-30T00:00:00	2	NaN	9	30.50	2	False	...	29.20	
21898	2	5886750.0	83.50	2018-07-30T00:00:00	2	NaN	9	36.60	2	False	...	29.70	
22474	7	24000000.0	128.00	2015-07-24T00:00:00	4	2.75	6	68.40	6	False	...	16.50	
22717	9	3000000.0	35.00	2018-01-02T00:00:00	1	2.60	16	16.00	7	False	...	10.00	
22933	20	3176015.0	33.30	2015-04-22T00:00:00	1	NaN	23	15.40	22	NaN	...	9.00	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	ba
23214	3	7990000.0	56.00	2016-05-31T00:00:00	2	NaN	6	NaN	5	False	...	NaN	

In [ ]:
```
data = data.dropna(subset = ['locality_name']) #ничего выделяющегося на первый взгляд в этих строках нет, удалим их
```

Расстояние до аэропорта airports_nearest, расстояние до ценнтра cityCenters_nearest

> Отсутствующие значения расстояния до аэропорта и до центра города имеет смысл заменить на медианные значения, сгруппировав по населенному пункту

In [ ]:
```
#for row in data['locality_name'].unique():
 #   data.loc[(data['locality_name'] == row) & (data['airports_nearest'].isna()), 'airports_nearest'] = \
  #  data.loc[(data['locality_name'] == row), 'airports_nearest'].median()
```

При проверке, получаем предупреждение от Python, что заставляет задуматься, а есть ли аэропорт в тех локациях, где ячейки со значением NaN. Т.к. оценить наверняка очень сложно, будем отталкиваться от того, что аэропорт находится в Санкт-Петербурге. Проверим, есть ли незаполненные ячейки с локацией там.

In [ ]:
```
data.query('airports_nearest.isna() and airports_nearest == "Санкт-Петербург"')
```

Out[ ]:

total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	balcony

0 rows × 22 columns

Нет. Таких строк нет. Будем иметь в виду, что если значение не заполнено, значит аэропорт где-то далеко. Значения менять не будем.

Апартаменты is_apartment

> Заменим все недостающие знгачения на False

In [ ]:
```
pd.set_option('mode.chained_assignment', None)
#уберем предупреждение, связанное с особенностью библиотеки, оно не влияет на результат
data['is_apartment'] = data['is_apartment'].fillna(False)
```

Парки поблизости parks_around3000, водоемы поблизости ponds_around3000

> Заменим эти значения на 0, т.к. скорее всего парков и водоемов поблизости просто нет

In [ ]:
```
data['parks_around3000'] = data['parks_around3000'].fillna(0)
data['ponds_around3000'] = data['ponds_around3000'].fillna(0)
```

Расстояние до ближайшего парка parks_nearest, расстояние до ближайшего водоема ponds_nearest

> Замениить отсутствующие значения на 0 мы не можем, т.к. в этом случае получится, что квартира находится в непосредственной близости от парка/водоема. Поэтому эти значения оставим как есть/

Количество дней, на которе было размещено объявление days_exposition

> Пропуски в ['days_exposition'] говорят нам, что квартиры еще не проданы. Оставляем.

In [ ]:
```
data[['days_exposition']].apply (['count', 'min', 'max']).style.format("{:,.2f}")
```

Out[ ]:

	days_exposition
count	20,285.00
min	1.00
max	1,580.00

In [ ]:
```
data.days_exposition.hist(bins = 15, figsize = (15,3), range = (1,1600))
plt.show()
```

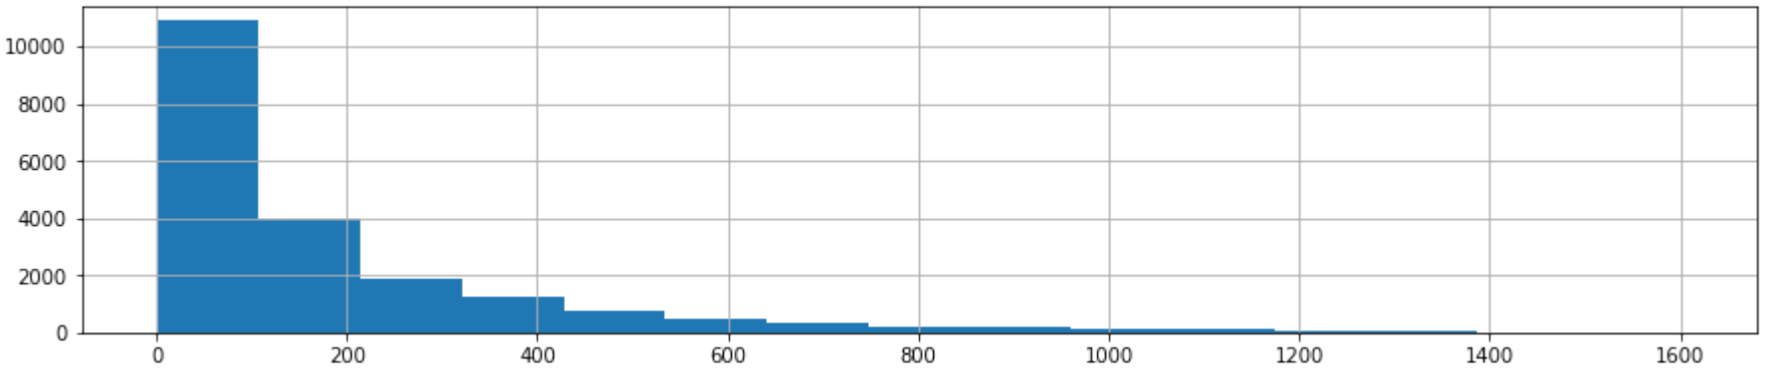

Видим низкое количесвто значений после 1150. Проверим сколько это строк

In [ ]:
```
data[data['days_exposition'] > 1000].count()
```

Out[ ]:
```
total_images            266
last_price              266
total_area              266
first_day_exposition    266
rooms                   266
ceiling_height          180
floors_total            266
living_area             242
floor                   266
is_apartment            266
studio                  266
open_plan               266
kitchen_area            251
balcony                 266
locality_name           266
airports_nearest        225
cityCenters_nearest     225
parks_around3000        266
parks_nearest           112
ponds_around3000        266
ponds_nearest           145
days_exposition         266
dtype: int64
```

256 строк - это около 1%, можем удалить

In [ ]:
```
data = data.loc[(data['days_exposition'] < 1000)|(data['days_exposition'].isna())]
```

Цена

In [ ]:
```
data['last_price'] = data['last_price'].astype(int)
```

In [ ]:
```
data[['last_price']].apply (['count', 'min', 'max']).style.format("{:,.2f}")
```

Out[ ]:

	last_price
count	23,149.00
min	12,190.00
max	330,000,000.00

In [ ]:
```
data.last_price.hist(bins = 100, figsize = (10,6), range = (0, 1.4e+07))
plt.show()
```

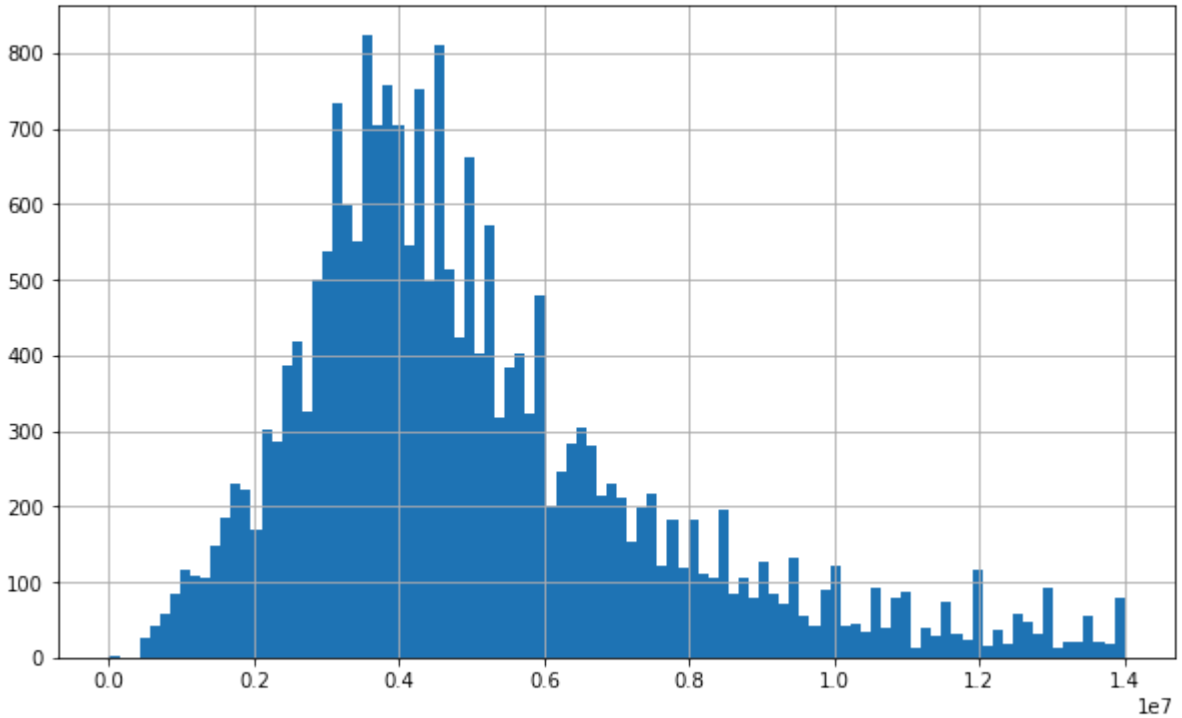

In [ ]:
```
data['last_price'].describe()
```

Out[ ]:
```
count    2.314900e+04
mean     6.032660e+06
std      6.555309e+06
min      1.219000e+04
25%      3.400000e+06
50%      4.600000e+06
75%      6.650000e+06
max      3.300000e+08
Name: last_price, dtype: float64
```

In [ ]:
```
data[data['last_price'] > 3.0e+07].count() # квартиры стоимостью выше 30 млн
```

Out[ ]:
```
total_images            190
last_price              190
total_area              190
first_day_exposition    190
rooms                   190
ceiling_height          124
floors_total            190
living_area             155
floor                   190
is_apartment            190
studio                  190
open_plan               190
kitchen_area            163
balcony                 190
locality_name           190
airports_nearest        184
cityCenters_nearest     184
parks_around3000        190
parks_nearest           138
ponds_around3000        190
ponds_nearest           148
days_exposition         136
dtype: int64
```

In [ ]:
```
data = data.loc[(data['last_price'] < 3.0e+07)|(data['last_price'].isna())]
```

Дата публикации first_day_exposition

> В столбце Дата публикации поменяем тип данных на datetime и проверим

In [ ]:
```
data['first_day_exposition'] = pd.to_datetime(data['first_day_exposition'], format = '%Y-%m-%d')
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 22952 entries, 0 to 23698
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype         
---  ------                --------------  -----         
 0   total_images          22952 non-null  int64         
 1   last_price            22952 non-null  int64         
 2   total_area            22952 non-null  float64       
 3   first_day_exposition  22952 non-null  datetime64[ns]
 4   rooms                 22952 non-null  int64         
 5   ceiling_height        14015 non-null  float64       
 6   floors_total          22952 non-null  int64         
 7   living_area           21115 non-null  float64       
 8   floor                 22952 non-null  int64         
 9   is_apartment          22952 non-null  bool          
 10  studio                22952 non-null  bool          
 11  open_plan             22952 non-null  bool          
 12  kitchen_area          20739 non-null  float64       
 13  balcony               22952 non-null  int64         
 14  locality_name         22952 non-null  object        
 15  airports_nearest      17475 non-null  float64       
 16  cityCenters_nearest   17495 non-null  float64       
 17  parks_around3000      22952 non-null  float64       
 18  parks_nearest         7648 non-null   float64       
 19  ponds_around3000      22952 non-null  float64       
 20  ponds_nearest         8629 non-null   float64       
 21  days_exposition       19877 non-null  float64       
dtypes: bool(3), datetime64[ns](1), float64(11), int64(6), object(1)
memory usage: 3.6+ MB
```

Теперь разберемся с дубликатами.

In [ ]:
```
duplicated_data  = data[data.duplicated()]
duplicated_data
```

Out[ ]:

total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	...	kitchen_area	balcony

0 rows × 22 columns

Полных дубликатов нет. Поищем неявные дубликаты

In [ ]:
```
data['locality_name'].unique()
```

Out[ ]:
```
array(['Санкт-Петербург', 'посёлок Шушары', 'городской посёлок Янино-1',
       'посёлок Парголово', 'посёлок Мурино', 'Ломоносов', 'Сертолово',
       'Петергоф', 'Пушкин', 'деревня Кудрово', 'Коммунар', 'Колпино',
       'поселок городского типа Красный Бор', 'Гатчина', 'поселок Мурино',
       'деревня Фёдоровское', 'Выборг', 'Кронштадт', 'Кировск',
       'деревня Новое Девяткино', 'посёлок Металлострой',
       'посёлок городского типа Лебяжье',
       'посёлок городского типа Сиверский', 'поселок Молодцово',
       'поселок городского типа Кузьмоловский',
       'садовое товарищество Новая Ропша', 'Павловск',
       'деревня Пикколово', 'Всеволожск', 'Волхов', 'Кингисепп',
       'Приозерск', 'Сестрорецк', 'деревня Куттузи', 'посёлок Аннино',
       'поселок городского типа Ефимовский', 'посёлок Плодовое',
       'деревня Заклинье', 'поселок Торковичи', 'поселок Первомайское',
       'Красное Село', 'посёлок Понтонный', 'Сясьстрой', 'деревня Старая',
       'деревня Лесколово', 'посёлок Новый Свет', 'Сланцы',
       'село Путилово', 'Ивангород', 'Мурино', 'Шлиссельбург',
       'Никольское', 'Зеленогорск', 'Сосновый Бор', 'поселок Новый Свет',
       'деревня Оржицы', 'деревня Кальтино', 'Кудрово',
       'поселок Романовка', 'посёлок Бугры', 'поселок Бугры',
       'поселок городского типа Рощино', 'Кириши', 'Луга', 'Волосово',
       'Отрадное', 'село Павлово', 'поселок Оредеж', 'село Копорье',
       'посёлок городского типа Красный Бор', 'посёлок Молодёжное',
       'Тихвин', 'посёлок Победа', 'деревня Нурма',
       'поселок городского типа Синявино', 'Тосно',
       'посёлок городского типа Кузьмоловский', 'посёлок Стрельна',
       'Бокситогорск', 'посёлок Александровская', 'деревня Лопухинка',
       'Пикалёво', 'поселок Терволово',
       'поселок городского типа Советский', 'Подпорожье',
       'посёлок Петровское', 'посёлок городского типа Токсово',
       'поселок Сельцо', 'посёлок городского типа Вырица',
       'деревня Кипень', 'деревня Келози', 'деревня Вартемяги',
       'посёлок Тельмана', 'городской поселок Большая Ижора',
       'городской посёлок Павлово', 'деревня Агалатово',
       'посёлок Новогорелово', 'городской посёлок Лесогорский',
       'деревня Лаголово', 'поселок Цвелодубово',
       'поселок городского типа Рахья', 'поселок городского типа Вырица',
       'деревня Белогорка', 'поселок Заводской',
       'городской посёлок Новоселье', 'деревня Большие Колпаны',
       'деревня Горбунки', 'деревня Батово', 'деревня Заневка',
       'деревня Иссад', 'Приморск', 'городской посёлок Фёдоровское',
       'деревня Мистолово', 'Новая Ладога', 'поселок Зимитицы',
       'поселок Барышево', 'деревня Разметелево',
       'поселок городского типа имени Свердлова', 'деревня Пеники',
```

```
'поселок Рябово', 'деревня Пудомяги', 'поселок станции Корнево',
'деревня Низино', 'деревня Бегуницы', 'посёлок Поляны',
'городской посёлок Мга', 'поселок Елизаветино',
'посёлок городского типа Кузнечное', 'деревня Колтуши',
'поселок Запорожское', 'посёлок городского типа Рощино',
'деревня Гостилицы', 'деревня Малое Карлино',
'посёлок Мичуринское', 'посёлок городского типа имени Морозова',
'посёлок Песочный', 'посёлок Сосново', 'деревня Аро',
'поселок Ильичёво', 'посёлок городского типа Тайцы',
'деревня Малое Верево', 'деревня Извара', 'поселок станции Вещево',
'село Паша', 'деревня Калитино',
'посёлок городского типа Ульяновка', 'деревня Чудской Бор',
'поселок городского типа Дубровка', 'деревня Мины',
'поселок Войсковицы', 'посёлок городского типа имени Свердлова',
'деревня Коркино', 'посёлок Ропша',
'поселок городского типа Приладожский', 'посёлок Щеглово',
'посёлок Гаврилово', 'Лодейное Поле', 'деревня Рабитицы',
'поселок городского типа Никольский', 'деревня Кузьмолово',
'деревня Малые Колпаны', 'поселок Тельмана',
'посёлок Петро-Славянка', 'городской посёлок Назия',
'посёлок Репино', 'посёлок Ильичёво', 'поселок Углово',
'поселок Старая Малукса', 'садовое товарищество Рахья',
'поселок Аннино', 'поселок Победа', 'деревня Меньково',
'деревня Старые Бегуницы', 'посёлок Сапёрный', 'поселок Семрино',
'поселок Гаврилово', 'поселок Глажево', 'поселок Кобринское',
'деревня Гарболово', 'деревня Юкки',
'поселок станции Приветнинское', 'деревня Мануйлово',
'деревня Пчева', 'поселок Поляны', 'поселок Цвылёво',
'поселок Мельниково', 'посёлок Пудость', 'посёлок Усть-Луга',
'Светогорск', 'Любань', 'поселок Селезнёво',
'поселок городского типа Рябово', 'Каменногорск', 'деревня Кривко',
'поселок Глебычево', 'деревня Парицы', 'поселок Жилпосёлок',
'посёлок городского типа Мга', 'городской поселок Янино-1',
'посёлок Войскорово', 'село Никольское', 'посёлок Терволово',
'поселок Стеклянный', 'посёлок городского типа Важины',
'посёлок Мыза-Ивановка', 'село Русско-Высоцкое',
'поселок городского типа Лебяжье',
'поселок городского типа Форносово', 'село Старая Ладога',
'поселок Житково', 'городской посёлок Виллози', 'деревня Лампово',
'деревня Шпаньково', 'деревня Лаврики', 'посёлок Сумино',
'посёлок Возрождение', 'деревня Старосиверская',
'посёлок Кикерино', 'поселок Возрождение',
'деревня Старое Хинколово', 'посёлок Пригородный',
'посёлок Торфяное', 'городской посёлок Будогощь',
```

```
'поселок Суходолье', 'поселок Красная Долина', 'деревня Хапо-Ое',
'поселок городского типа Дружная Горка', 'поселок Лисий Нос',
'деревня Яльгелево', 'село Рождествено', 'деревня Старополье',
'посёлок Левашово', 'деревня Сяськелево', 'деревня Камышовка',
'садоводческое некоммерческое товарищество Лесная Поляна',
'деревня Хязельки', 'поселок Жилгородок',
'посёлок городского типа Павлово', 'деревня Ялгино',
'поселок Новый Учхоз', 'городской посёлок Рощино',
'поселок Гончарово', 'поселок Почап', 'посёлок Сапёрное',
'посёлок Платформа 69-й километр', 'поселок Каложицы',
'деревня Фалилеево', 'деревня Пельгора',
'поселок городского типа Лесогорский', 'деревня Торошковичи',
'посёлок Белоостров', 'посёлок Алексеевка', 'поселок Серебрянский',
'поселок Лукаши', 'поселок Петровское', 'деревня Щеглово',
'поселок Мичуринское', 'деревня Тарасово', 'поселок Кингисеппский',
'посёлок при железнодорожной станции Вещево', 'поселок Ушаки',
'деревня Котлы', 'деревня Сижно', 'деревня Торосово',
'посёлок Форт Красная Горка', 'поселок городского типа Токсово',
'деревня Новолисино', 'посёлок станции Громово', 'деревня Глинка',
'посёлок Мельниково', 'поселок городского типа Назия',
'деревня Старая Пустошь', 'поселок Коммунары', 'поселок Починок',
'посёлок городского типа Вознесенье', 'деревня Разбегаево',
'посёлок городского типа Рябово', 'поселок Гладкое',
'посёлок при железнодорожной станции Приветнинское',
'поселок Тёсово-4', 'посёлок Жилгородок', 'посёлок Коробицыно',
'деревня Большая Вруда', 'деревня Курковицы',
'городской посёлок Советский', 'посёлок Кобралово',
'деревня Суоранда', 'поселок Кобралово',
'поселок городского типа Кондратьево',
'коттеджный поселок Счастье', 'поселок Любань', 'деревня Реброво',
'деревня Зимитицы', 'деревня Тойворово', 'поселок Семиозерье',
'поселок Лесное', 'поселок Совхозный', 'поселок Усть-Луга',
'посёлок Ленинское', 'посёлок Суйда',
'посёлок городского типа Форносово', 'деревня Нижние Осельки',
'деревня Бор', 'посёлок станции Свирь', 'поселок Перово', 'Высоцк',
'поселок Гарболово', 'село Шум', 'поселок Котельский',
'поселок станции Лужайка', 'посёлок Стеклянный',
'деревня Большая Пустомержа', 'поселок Красносельское',
'деревня Вахнова Кара', 'деревня Пижма',
'коттеджный поселок Кивеннапа Север', 'поселок Коробицыно',
'поселок Ромашки', 'посёлок Перово', 'деревня Каськово',
'деревня Куровицы', 'посёлок Плоское', 'поселок Сумино',
'поселок городского типа Большая Ижора', 'поселок Кирпичное',
'деревня Ям-Тесово', 'деревня Раздолье', 'деревня Терпилицы',
```

```
'посёлок Шугозеро', 'деревня Ваганово', 'поселок Пушное',
'садовое товарищество Садко', 'посёлок Усть-Ижора',
'деревня Выскатка', 'городской посёлок Свирьстрой',
'поселок Громово', 'деревня Кисельня', 'посёлок Старая Малукса',
'деревня Трубников Бор', 'поселок Калитино',
'посёлок Высокоключевой', 'садовое товарищество Приладожский',
'посёлок Пансионат Зелёный Бор', 'деревня Ненимяки',
'поселок Пансионат Зелёный Бор', 'деревня Снегирёвка',
'деревня Рапполово', 'деревня Пустынка', 'поселок Рабитицы',
'деревня Большой Сабск', 'деревня Русско', 'посёлок Лисий Нос',
'деревня Лупполово', 'деревня Большое Рейзино',
'деревня Малая Романовка', 'поселок Дружноселье', 'поселок Пчевжа',
'поселок Володарское', 'деревня Нижняя',
'коттеджный посёлок Лесное', 'деревня Тихковицы',
'деревня Борисова Грива', 'посёлок Дзержинского'], dtype=object)
```

In [ ]:
```
# check
data['locality_name'].nunique()
```

Out[ ]:
```
363
```

In [ ]:
```
# Используем метод replace()
data['locality_name'] = data['locality_name'].str.replace('посёлок','поселок')
data['locality_name'] = (
    data['locality_name'].str.replace('поселок Мурино','Мурино')
    .str.replace('деревня Кудрово','Кудрово')
    .str.replace('поселок городского типа Рябово','Рябово')
)
```

In [ ]:
```
#проверим
pd.set_option('display.max_columns', None) #строчки, чтобы Юпитер полностью вывел таблицу
pd.set_option('display.max_rows', None)
data['locality_name'].value_counts()
```

Out[ ]:

Санкт-Петербург	15109
Мурино	584
Кудрово	466
поселок Шушары	436
Всеволожск	394
Пушкин	356
Колпино	335
поселок Парголово	326
Гатчина	307
Выборг	236
Петергоф	195
Сестрорецк	181
Красное Село	175
деревня Новое Девяткино	142
Сертолово	138
Ломоносов	132
Кириши	124
поселок Бугры	112
Сланцы	112
Волхов	111
Кингисепп	104
Тосно	104
Кронштадт	94
Никольское	93
Сосновый Бор	87
Коммунар	86
Кировск	84
Отрадное	79
городской поселок Янино-1	68
поселок Металлострой	66
Приозерск	66
деревня Старая	64
Шлиссельбург	56
Луга	56
Тихвин	49
поселок Стрельна	43
поселок Тельмана	40
Павловск	36
Волосово	36
поселок Романовка	36
поселок городского типа имени Свердлова	36
поселок городского типа Кузьмоловский	35
поселок городского типа Рощино	34
поселок городского типа Сиверский	29

Ивангород	28
городской поселок Новоселье	28
городской поселок Мга	26
Сясьстрой	24
Зеленогорск	24
поселок Щеглово	23
поселок Новый Свет	22
поселок городского типа Синявино	21
поселок городского типа Вырица	21
деревня Вартемяги	20
поселок городского типа Токсово	20
поселок Понтонный	20
поселок Новогорелово	20
деревня Лесколово	20
Подпорожье	19
Лодейное Поле	19
Пикалёво	18
поселок Сосново	18
поселок городского типа имени Морозова	17
деревня Бегуницы	17
городской поселок Большая Ижора	16
поселок Аннино	16
деревня Большие Колпаны	16
Бокситогорск	16
поселок городского типа Рахья	15
городской поселок Назия	15
деревня Горбунки	15
поселок городского типа Лебяжье	15
поселок городского типа Дубровка	15
Новая Ладога	14
поселок городского типа Ульяновка	13
поселок городского типа Кузнечное	13
поселок Елизаветино	13
Каменногорск	13
деревня Гарболово	13
деревня Мистолово	11
поселок Мичуринское	11
Светогорск	11
деревня Гостилицы	11
деревня Малое Верево	11
деревня Колтуши	10
деревня Сяськелево	10
деревня Лаголово	10
поселок Войсковицы	10

деревня Низино	10
деревня Белогорка	10
поселок Молодцово	9
деревня Оржицы	9
поселок Сельцо	9
село Русско-Высоцкое	9
деревня Батово	9
поселок городского типа Советский	9
поселок городского типа Приладожский	9
деревня Малое Карлино	9
городской поселок Павлово	9
деревня Нурма	9
поселок Кобралово	9
поселок Пудость	9
деревня Фёдоровское	8
поселок Первомайское	8
поселок городского типа Красный Бор	8
Любань	8
поселок Суходолье	8
Приморск	8
поселок Запорожское	8
поселок Ильичёво	8
поселок Стеклянный	7
деревня Малые Колпаны	7
деревня Извара	7
городской поселок Фёдоровское	7
село Павлово	7
деревня Кальтино	7
деревня Куттузи	7
деревня Кузьмолово	7
поселок городского типа Никольский	7
поселок Углово	7
деревня Кипень	7
поселок городского типа Тайцы	6
поселок Сапёрный	6
деревня Лампово	6
поселок городского типа Важины	6
поселок Новый Учхоз	6
поселок городского типа Мга	6
деревня Яльгелево	6
деревня Пудомяги	6
поселок Победа	6
деревня Заневка	6
поселок Поляны	6

поселок Кобринское	6
поселок городского типа Форносово	6
деревня Лопухинка	6
деревня Калитино	6
деревня Пеники	6
поселок Ушаки	6
поселок Терволово	6
поселок Семрино	5
поселок Селезнёво	5
поселок Глажево	5
поселок городского типа Дружная Горка	5
село Копорье	5
поселок Мельниково	5
деревня Юкки	5
поселок Петровское	5
городской поселок Рощино	5
поселок Войскорово	5
поселок Плодовое	5
поселок Гаврилово	5
поселок Усть-Луга	5
поселок Репино	4
поселок станции Вещево	4
городской поселок Будогощь	4
поселок Гарболово	4
деревня Агалатово	4
деревня Келози	4
поселок Старая Малукса	4
Высоцк	4
деревня Большая Вруда	4
деревня Парицы	4
деревня Разметелево	4
поселок Торфяное	4
поселок Перово	4
деревня Разбегаево	4
поселок Цвелодубово	4
поселок Песочный	4
поселок Суйда	4
поселок Кикерино	4
поселок Лукаши	3
поселок Торковичи	3
поселок Жилгородок	3
деревня Старосиверская	3
деревня Старополье	3
поселок Пригородный	3

поселок станции Громово	3
деревня Заклинье	3
деревня Торошковичи	3
поселок Заводской	3
поселок Любань	3
поселок Красная Долина	3
деревня Торосово	3
городской поселок Виллози	3
поселок Возрождение	3
поселок Зимитицы	3
поселок Молодёжное	3
поселок Глебычево	3
село Рождествено	3
поселок городского типа Ефимовский	3
деревня Ваганово	3
деревня Аро	3
поселок Громово	3
поселок Котельский	3
поселок Оредеж	3
поселок городского типа Лесогорский	3
деревня Камышовка	2
деревня Выскатка	2
село Паша	2
поселок Лесное	2
деревня Суоранда	2
городской поселок Лесогорский	2
поселок Серебрянский	2
деревня Коркино	2
поселок Сумино	2
поселок Пушное	2
село Путилово	2
поселок Пансионат Зелёный Бор	2
поселок станции Приветнинское	2
поселок Кингисеппский	2
поселок Лисий Нос	2
поселок Починок	2
деревня Ненимяки	2
деревня Фалилеево	2
поселок Коробицыно	2
село Старая Ладога	2
поселок Усть-Ижора	2
поселок Житково	2
поселок Совхозный	2
поселок городского типа Назия	2

деревня Глинка	2
деревня Старые Бегуницы	2
городской поселок Советский	2
Рябово	2
поселок Александровская	2
деревня Мины	2
деревня Старая Пустошь	2
деревня Тарасово	2
поселок Ленинское	2
поселок городского типа Вознесенье	2
деревня Ям-Тесово	2
поселок Барышево	2
поселок Сапёрное	2
поселок городского типа Павлово	2
поселок станции Свирь	2
поселок Ропша	1
деревня Большая Пустомержа	1
деревня Реброво	1
деревня Ялгино	1
поселок Жилпоселок	1
деревня Каськово	1
село Никольское	1
деревня Рапполово	1
поселок Плоское	1
поселок Коммунары	1
поселок Кирпичное	1
поселок Тёсово-4	1
деревня Пчева	1
деревня Хязельки	1
поселок Ромашки	1
деревня Иссад	1
садовое товарищество Новая Ропша	1
поселок Пчевжа	1
поселок Каложицы	1
поселок Красносельское	1
деревня Щеглово	1
коттеджный поселок Лесное	1
деревня Терпилицы	1
деревня Большое Рейзино	1
деревня Борисова Грива	1
деревня Рабитицы	1
деревня Зимитицы	1
деревня Пустынка	1
поселок Цвылёво	1

деревня Раздолье	1
деревня Нижняя	1
поселок Петро-Славянка	1
поселок Левашово	1
садовое товарищество Рахья	1
деревня Пижма	1
деревня Меньково	1
поселок Высокоключевой	1
садовое товарищество Садко	1
деревня Пельгора	1
деревня Большой Сабск	1
поселок Форт Красная Горка	1
деревня Тихковицы	1
поселок Калитино	1
деревня Старое Хинколово	1
деревня Вахнова Кара	1
деревня Чудской Бор	1
поселок при железнодорожной станции Вещево	1
деревня Сижно	1
городской поселок Свирьстрой	1
поселок Гладкое	1
деревня Лупполово	1
деревня Кисельня	1
деревня Пикколово	1
поселок Рабитицы	1
поселок Дзержинского	1
деревня Хапо-Ое	1
деревня Куровицы	1
поселок Почап	1
деревня Нижние Оселькы	1
поселок Гончарово	1
деревня Лаврики	1
поселок Платформа 69-й километр	1
садоводческое некоммерческое товарищество Лесная Поляна	1
деревня Трубников Бор	1
поселок Семиозерье	1
садовое товарищество Приладожский	1
деревня Курковицы	1
поселок городского типа Кондратьево	1
поселок Мыза-Ивановка	1
коттеджный поселок Кивеннапа Север	1
деревня Шпаньково	1
деревня Кривко	1
поселок при железнодорожной станции Приветнинское	1

```
поселок Белоостров                                1
деревня Мануйлово                                 1
деревня Малая Романовка                           1
деревня Тойворово                                 1
поселок станции Корнево                           1
деревня Снегирёвка                                1
поселок городского типа Большая Ижора             1
деревня Котлы                                     1
поселок Шугозеро                                  1
деревня Бор                                       1
деревня Русско                                    1
деревня Новолисино                                1
поселок Дружноселье                               1
поселок Рябово                                    1
село Шум                                          1
поселок станции Лужайка                           1
поселок Володарское                               1
поселок Алексеевка                                1
коттеджный поселок Счастье                        1
Name: locality_name, dtype: int64
```

In [ ]:
```
data['locality_name'].nunique()
```

Out[ ]:
```
327
```

Найдем аномальные значения. Выведем таблицу методом describe

In [ ]:
```
data.describe()
```

Out[ ]:

	total_images	last_price	total_area	rooms	ceiling_height	floors_total	living_area	floor	kitchen_area	balcony	ai
count	22952.000000	2.295200e+04	22952.000000	22952.000000	14015.000000	22952.000000	21115.000000	22952.000000	20739.000000	22952.000000	
mean	9.844284	5.645989e+06	57.383432	2.019127	2.713378	10.698501	32.770104	5.908635	10.207226	0.594240	
std	5.653254	3.865348e+06	25.779422	0.983738	0.258572	6.634260	16.605272	4.900658	4.810324	0.959013	
min	0.000000	1.219000e+04	12.000000	0.000000	2.000000	1.000000	2.000000	1.000000	1.300000	0.000000	
25%	6.000000	3.400000e+06	40.000000	1.000000	2.500000	5.000000	18.500000	2.000000	7.000000	0.000000	
50%	9.000000	4.590000e+06	51.000000	2.000000	2.650000	9.000000	30.000000	4.000000	9.000000	0.000000	
75%	14.000000	6.550000e+06	68.000000	3.000000	2.800000	16.000000	41.900000	8.000000	11.700000	1.000000	
max	50.000000	2.999900e+07	441.980000	9.000000	5.800000	60.000000	128.000000	33.000000	49.400000	5.000000	

Если посмотреть на минимальные, максимальные значения, становятся очевидными выбросы в столбцах floors_total (максимальное значение 60 этажей, тогда как в Санкт-Петербурге самое высокое здание Лахта-центр имеет 35 этажей) rooms (минммальное значение 0)

In [ ]:
```
data = data.loc[(data['rooms'] >= 1)|(data['rooms'].isna())]
                                    #отметаем нулевые значения количества комнат
```

In [ ]:
```
data.query('floors_total > 35') #проверим много ли выбросов по этажности
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
397	15	5990000	54.0	2018-03-22	2	NaN	36	21.4	28	False	False	False	
2253	12	3800000	45.5	2018-06-28	2	2.88	60	27.4	4	False	False	False	
5807	17	8150000	80.0	2019-01-09	2	2.70	36	41.0	13	False	False	False	
11079	16	9200000	75.0	2019-02-22	2	2.70	36	40.0	29	False	False	False	
16731	9	3978000	40.0	2018-09-24	1	2.65	52	10.5	18	False	False	False	

6 строк имееют значение этажности здания более 35 эт. 36 и 37 этажей значение очень близкое к 35, поэтому их оставим. Вдруг где-то в пригороде и правда уже построили здание выше Лахта-центра. Строки со значением 52 и 60 явно ошибочные. Удалим их.

In [ ]:
```
data = data.loc[(data['floors_total'] <= 37)|(data['last_price'].isna())]
#оставляем в таблице значения меньше 37 этажей
```

In [ ]:
```
# check
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 22754 entries, 0 to 23698
Data columns (total 22 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   total_images          22754 non-null  int64
 1   last_price            22754 non-null  int64
 2   total_area            22754 non-null  float64
 3   first_day_exposition  22754 non-null  datetime64[ns]
 4   rooms                 22754 non-null  int64
 5   ceiling_height        13932 non-null  float64
 6   floors_total          22754 non-null  int64
 7   living_area           20930 non-null  float64
 8   floor                 22754 non-null  int64
 9   is_apartment          22754 non-null  bool
 10  studio                22754 non-null  bool
 11  open_plan             22754 non-null  bool
 12  kitchen_area          20737 non-null  float64
 13  balcony               22754 non-null  int64
 14  locality_name         22754 non-null  object
 15  airports_nearest      17356 non-null  float64
 16  cityCenters_nearest   17376 non-null  float64
 17  parks_around3000      22754 non-null  float64
 18  parks_nearest         7618 non-null   float64
 19  ponds_around3000      22754 non-null  float64
 20  ponds_nearest         8560 non-null   float64
 21  days_exposition       19693 non-null  float64
dtypes: bool(3), datetime64[ns](1), float64(11), int64(6), object(1)
memory usage: 3.5+ MB
```

In [ ]:
```
# check

# Показатели о кол-ве объявлений в датасете, минимальных и максимальных значениях
```

```
# в выбранных параметрах о продаже квартир
# сырые данные

(
    data[['rooms', 'total_area', 'ceiling_height', 'days_exposition', 'last_price', 'living_area',  'kitchen_area',
          'floor', 'floors_total']]
    .apply (['count', 'min', 'max'])
    .style.format("{:,.2f}")
)
```

Out[ ]:

	rooms	total_area	ceiling_height	days_exposition	last_price	living_area	kitchen_area	floor	floors_total
count	22,754.00	22,754.00	13,932.00	19,693.00	22,754.00	20,930.00	20,737.00	22,754.00	22,754.00
min	1.00	12.00	2.00	1.00	12,190.00	2.00	1.30	1.00	1.00
max	9.00	441.98	5.30	999.00	29,999,000.00	128.00	49.40	33.00	36.00

In [ ]:
```
# check
data.rooms.value_counts().to_frame()
```

Out[ ]:

	rooms
1	7959
2	7802
3	5610
4	1067
5	242
6	53
7	18
8	2
9	1

In [ ]:
```
data.query('rooms > 7').count()
```

Out[ ]:
```
total_images            3
last_price              3
total_area              3
first_day_exposition    3
rooms                   3
ceiling_height          3
floors_total            3
living_area             2
floor                   3
is_apartment            3
studio                  3
open_plan               3
kitchen_area            2
balcony                 3
locality_name           3
airports_nearest        3
cityCenters_nearest     3
parks_around3000        3
parks_nearest           3
ponds_around3000        3
ponds_nearest           1
days_exposition         2
dtype: int64
```

In [ ]:
```
data[['rooms']].apply (['count', 'min', 'max']).style.format("{:,.2f}")
```

Out[ ]:

	rooms
count	22,754.00
min	1.00
max	9.00

3 строк - это почти ничего, можем их удалить

In [ ]:
```
data = data.loc[(data['rooms'] <= 7)|(data['rooms'].isna())]
```

In [ ]:
```
# check
data.total_area.hist(bins = 150, figsize = (15,3));
```

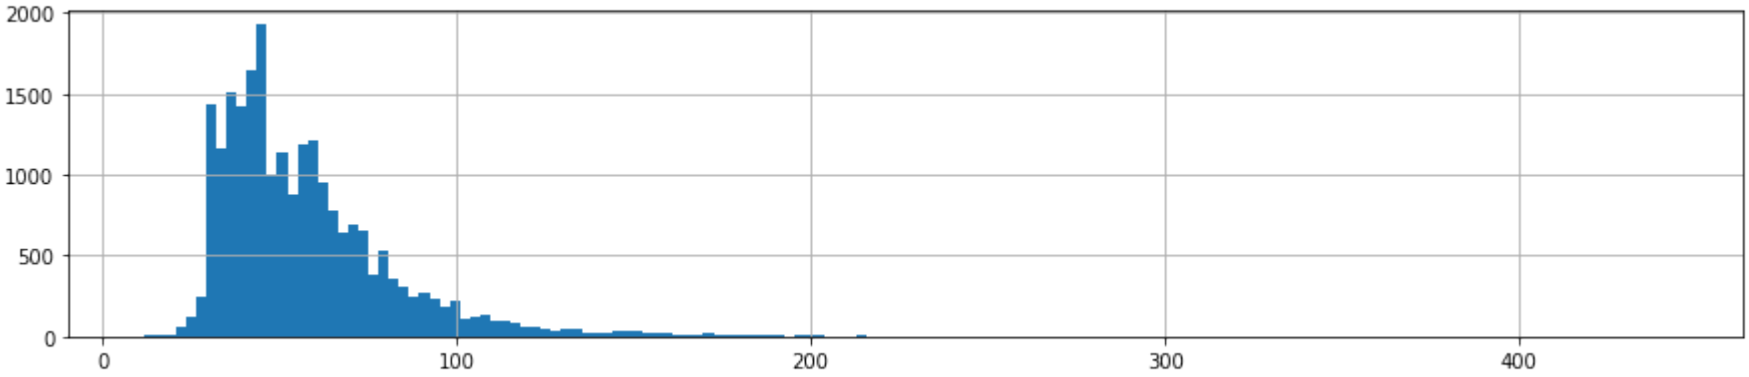

In [ ]:
```
# check
data.total_area.hist(bins = 150, figsize = (15,3), range = (180,500));
```

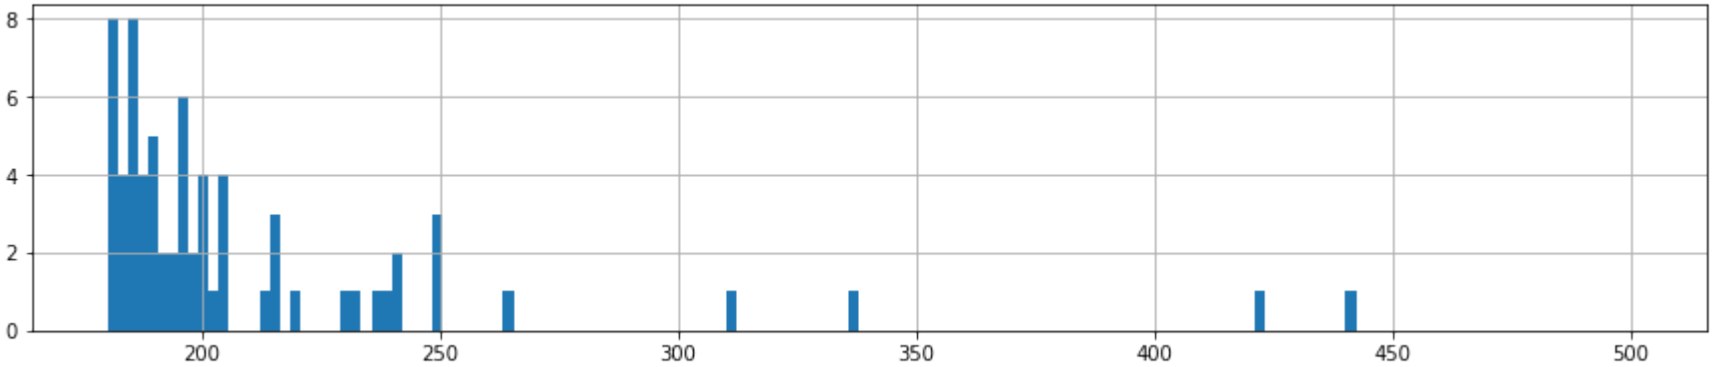

In [ ]:
```
# check
data.total_area.hist(bins = 15, figsize = (15,3), range = (180,500));
```

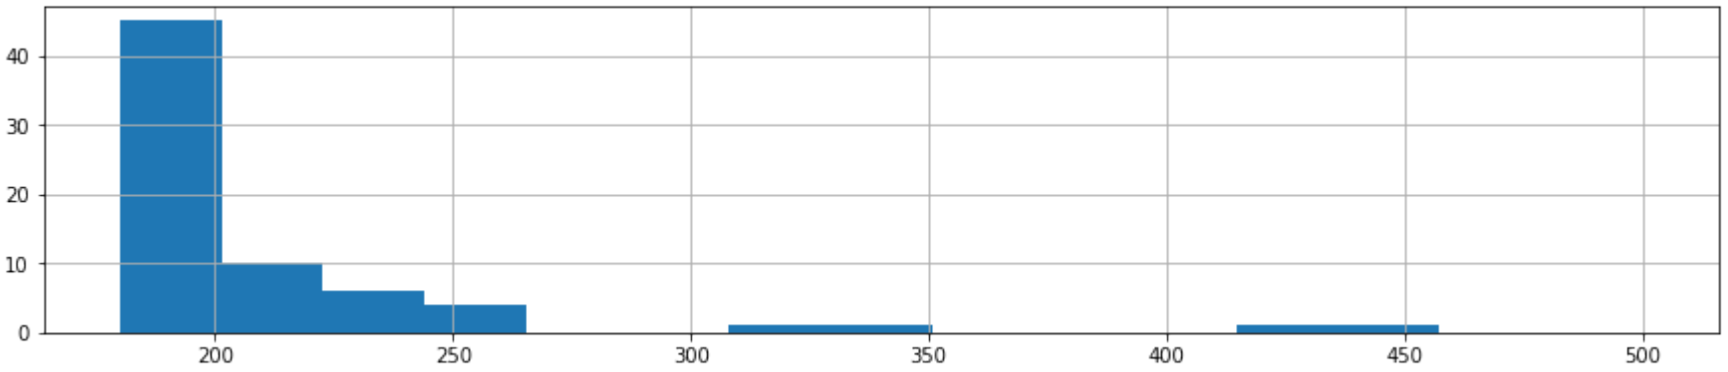

In [ ]:
```
data.query('total_area > 250').count()
```

Out[ ]:
```
total_images            6
last_price              6
total_area              6
first_day_exposition    6
rooms                   6
ceiling_height          3
floors_total            6
living_area             3
floor                   6
is_apartment            6
studio                  6
open_plan               6
kitchen_area            5
balcony                 6
locality_name           6
airports_nearest        6
cityCenters_nearest     6
parks_around3000        6
parks_nearest           2
ponds_around3000        6
ponds_nearest           2
days_exposition         4
dtype: int64
```

In [ ]:
```
data = data.loc[(data['total_area'] <= 250)|(data['total_area'].isna())]
```

In [ ]:
```
# check
```

```
# Значения параметров объектов недвижимости на разных квантилях

(
    data[['rooms', 'total_area', 'ceiling_height', 'days_exposition', 'last_price', 'living_area',
        'kitchen_area', 'floor',   'floors_total']]
    .quantile([0.0012, 0.01, .5, .99, .9988]) # выбираем размах в 0,9976 квантилей
    .style.format("{:,.2f}")
)
```

Out[ ]:

	rooms	total_area	ceiling_height	days_exposition	last_price	living_area	kitchen_area	floor	floors_total
0.0012	1.00	20.62	2.30	3.00	560,000.00	10.00	3.67	1.00	1.00
0.01	1.00	27.00	2.50	4.00	1,000,000.00	13.00	5.00	1.00	2.00
0.5	2.00	51.40	2.65	93.00	4,600,000.00	30.00	9.00	4.00	9.00
0.99	5.00	151.56	3.66	863.00	22,000,000.00	92.33	30.00	23.00	26.00
0.9988	6.00	196.00	4.20	976.38	28,555,679.74	120.89	43.00	26.00	28.71

In [ ]:
```
# check

# Показатели о кол-ве объявлений в датасете, минимальных и максимальных значениях
# в выбранных параметрах о продаже квартир

(
    data[['rooms', 'total_area', 'ceiling_height', 'days_exposition', 'last_price', 'living_area',  'kitchen_area',
          'floor', 'floors_total']]
    .apply (['count', 'min', 'max'])
    .style.format("{:,.2f}")
)
```

Out[ ]:

	rooms	total_area	ceiling_height	days_exposition	last_price	living_area	kitchen_area	floor	floors_total
count	22,745.00	22,745.00	13,926.00	19,687.00	22,745.00	20,925.00	20,730.00	22,745.00	22,745.00
min	1.00	12.00	2.00	1.00	12,190.00	2.00	1.30	1.00	1.00
max	7.00	250.00	5.30	999.00	29,999,000.00	128.00	49.40	33.00	36.00

In [ ]:
```
# check
data.hist(column = 'days_exposition', bins = 50, figsize = (15,3), range = (0,5));
```

```
data.hist(column = 'days_exposition', bins = 50, figsize = (15,3), range = (0,5))
plt.ylim(0, 40);
```

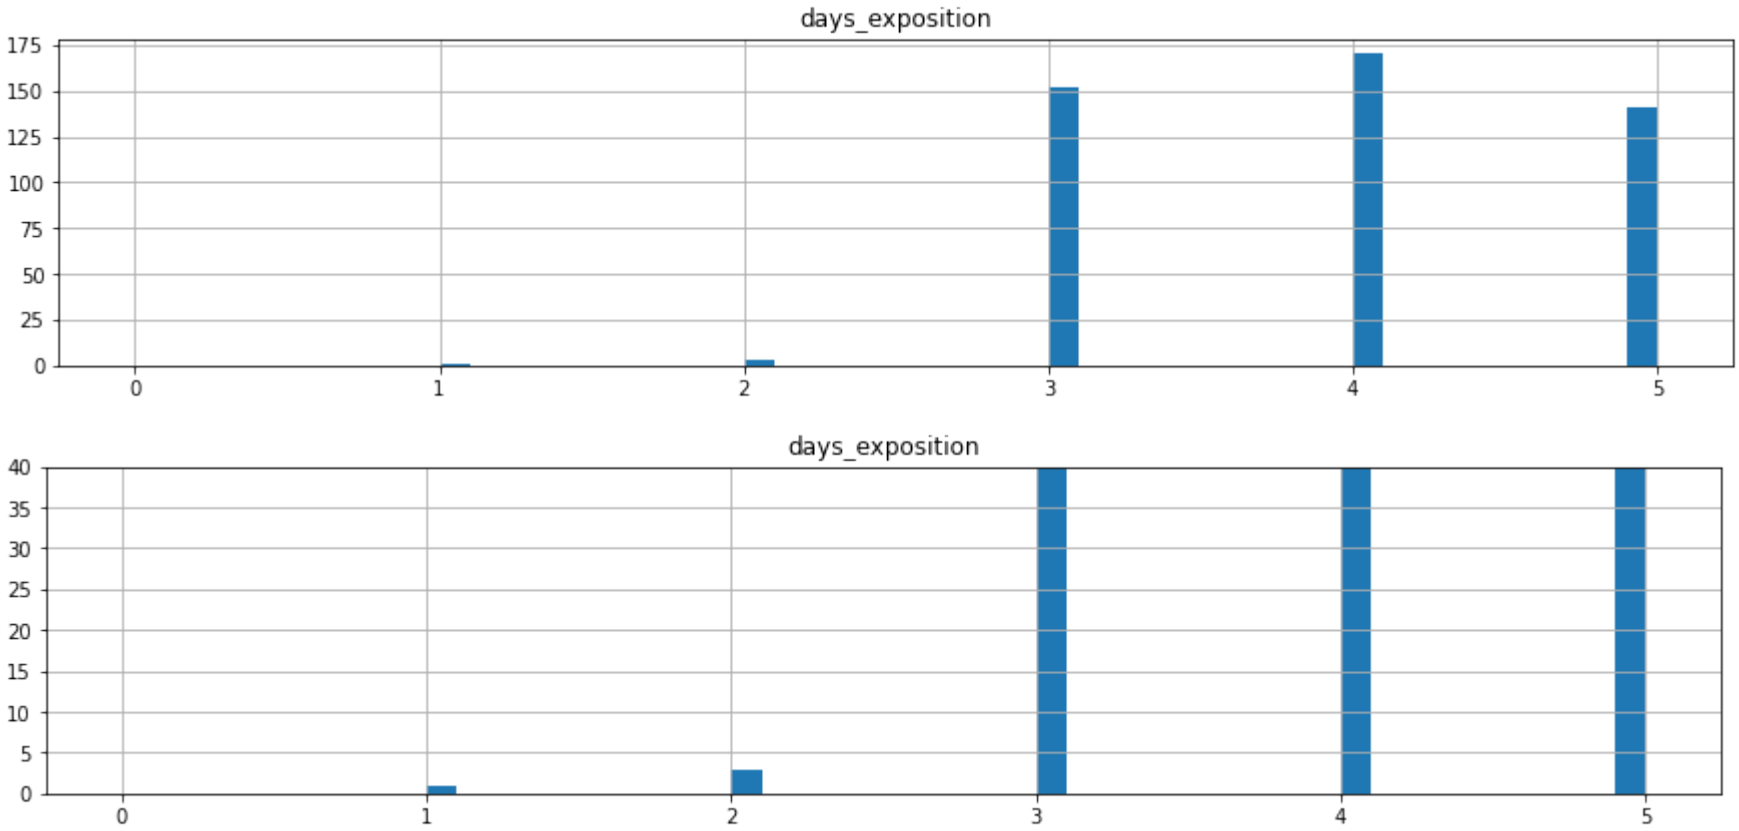

In [ ]:
```
data.query('days_exposition < 3').count()
```

Out[ ]:
```
total_images           4
last_price             4
total_area             4
first_day_exposition   4
rooms                  4
ceiling_height         3
floors_total           4
living_area            3
floor                  4
is_apartment           4
studio                 4
open_plan              4
kitchen_area           3
balcony                4
locality_name          4
airports_nearest       4
cityCenters_nearest    4
parks_around3000       4
parks_nearest          2
ponds_around3000       4
ponds_nearest          1
days_exposition        4
dtype: int64
```

In [ ]:
```
data = data.loc[(data['days_exposition'] > 3)|(data['days_exposition'].isna())]
```

Посчитайте и добавьте в таблицу новые столбцы

Посчитаем среднюю цену за квадратный метр и внесем данные в отдельный столбец.

In [ ]:
```
data['price_m'] = data['last_price']/data['total_area']  # добавим столбец с ценой за метр квадратный
data['price_m'] = data['price_m'].astype('int') # поменяем тип данных на целочисленный
data.head() #проверим
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	kitche
0	20	13000000	108.0	2019-03-07	3	2.70	16	51.0	8	False	False	False	
1	7	3350000	40.4	2018-12-04	1	NaN	11	18.6	1	False	False	False	
2	10	5196000	56.0	2015-08-20	2	NaN	5	34.3	4	False	False	False	
4	2	10000000	100.0	2018-06-19	2	3.03	14	32.0	13	False	False	False	
5	10	2890000	30.4	2018-09-10	1	NaN	12	14.4	5	False	False	False	

Добавим новые столбцы со значениями дня недели, мексяца и года размещения объявления на сайте

In [ ]:
```
data['weekday'] = data['first_day_exposition'].dt.weekday
#определяем день недели размещеничя объявления, помещаем в отдельный столбец
data['month'] = data['first_day_exposition'].dt.month # месяц
data['year'] = data['first_day_exposition'].dt.year # год
data.head()
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	kitche
0	20	13000000	108.0	2019-03-07	3	2.70	16	51.0	8	False	False	False	
1	7	3350000	40.4	2018-12-04	1	NaN	11	18.6	1	False	False	False	
2	10	5196000	56.0	2015-08-20	2	NaN	5	34.3	4	False	False	False	
4	2	10000000	100.0	2018-06-19	2	3.03	14	32.0	13	False	False	False	
5	10	2890000	30.4	2018-09-10	1	NaN	12	14.4	5	False	False	False	

Сделаем категоризацию этажей: "первый", "порследний", "другой"

In [ ]:
```
# создаем функцию для категоризации типов этажей
def type_floor(data):
    if data['floor'] == 1:
        return 'первый'
    elif data['floor'] < data['floors_total']:
        return 'другой'
    elif data['floor'] == data['floors_total']:
        return 'последний'
    elif data['floor'] <= 0 :
        return 'ошибка'
    else:
        return 'не найдено'
```

In [ ]:
```
data['type_floor'] = data.apply(type_floor,axis=1) # вызываем функцию и складываем значения в новый столбец
```

Переведем значения расстояния до центра города в километры и округлим до целого

In [ ]:
```
data['cityCenters_nearest'] = round(data['cityCenters_nearest'] /1000)
data.tail(10) #проверим
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
23689	13	3550000	35.30	2018-02-28	1	2.86	15	16.3	4	False	False	False	
23690	3	5500000	52.00	2018-07-19	2	NaN	5	31.0	2	False	False	False	
23691	11	9470000	72.90	2016-10-13	2	2.75	25	40.3	7	False	False	False	
23692	2	1350000	30.00	2017-07-07	1	NaN	5	17.5	4	False	False	False	
23693	9	4600000	62.40	2016-08-05	3	2.60	9	40.0	8	False	False	False	
23694	9	9700000	133.81	2017-03-21	3	3.70	5	73.3	3	False	False	False	
23695	14	3100000	59.00	2018-01-15	3	NaN	5	38.0	4	False	False	False	
23696	18	2500000	56.70	2018-02-11	2	NaN	3	29.7	1	False	False	False	
23697	13	11475000	76.75	2017-03-28	2	3.00	17	NaN	12	False	False	False	
23698	4	1350000	32.30	2017-07-21	1	2.50	5	12.3	1	False	False	False	

Проведем исследовательский анализ данных

Общая площадь

In [ ]:
```
plt.ylim(0, 150) #выставляем значения по оси y
data.boxplot('total_area') # строим диаграмму размаха
plt.show()
```

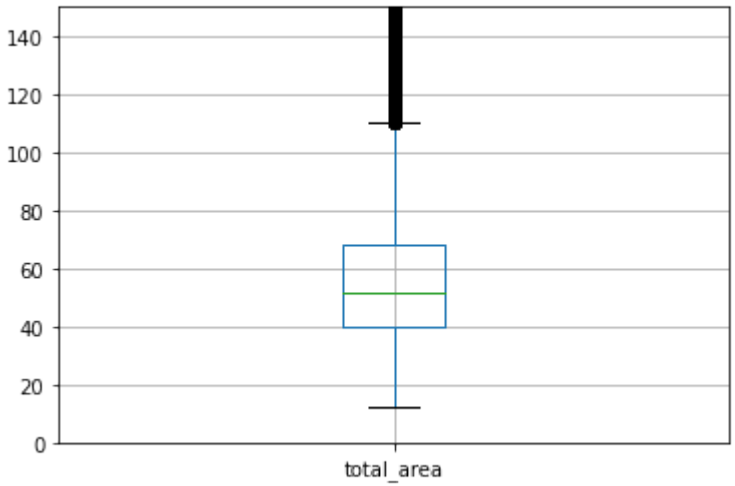

In [ ]:
```
data['total_area'].describe()
```

Out[ ]:
```
count    22741.000000
mean        57.552796
std         25.252299
min         12.000000
25%         40.000000
50%         51.400000
75%         68.000000
max        250.000000
Name: total_area, dtype: float64
```

Стандартное отклонение в 2 раза ниже среднего. Это говорит о том, что значения набора данных имеют большой разброс. Это действительно так, учитывая, что у нас есть квартира 12 квадратов и 250 квадратов. По диаграмме размаха можем определить, что большинство квартир имеют площадь от 40 до 70 кв. м. - это значения, которые входят в "ящик". Минимальное значение 12 кв.м., верхний ус примерно на 110 кв.м. Остальные значения считаем выбросами. Медиана проходит примерно на 50

In [ ]:
```
data.plot(y = 'total_area', kind = 'hist', bins = 500, grid=True, range = (0,200), figsize = (10,6)) #построим гистограмму
plt.show()
```

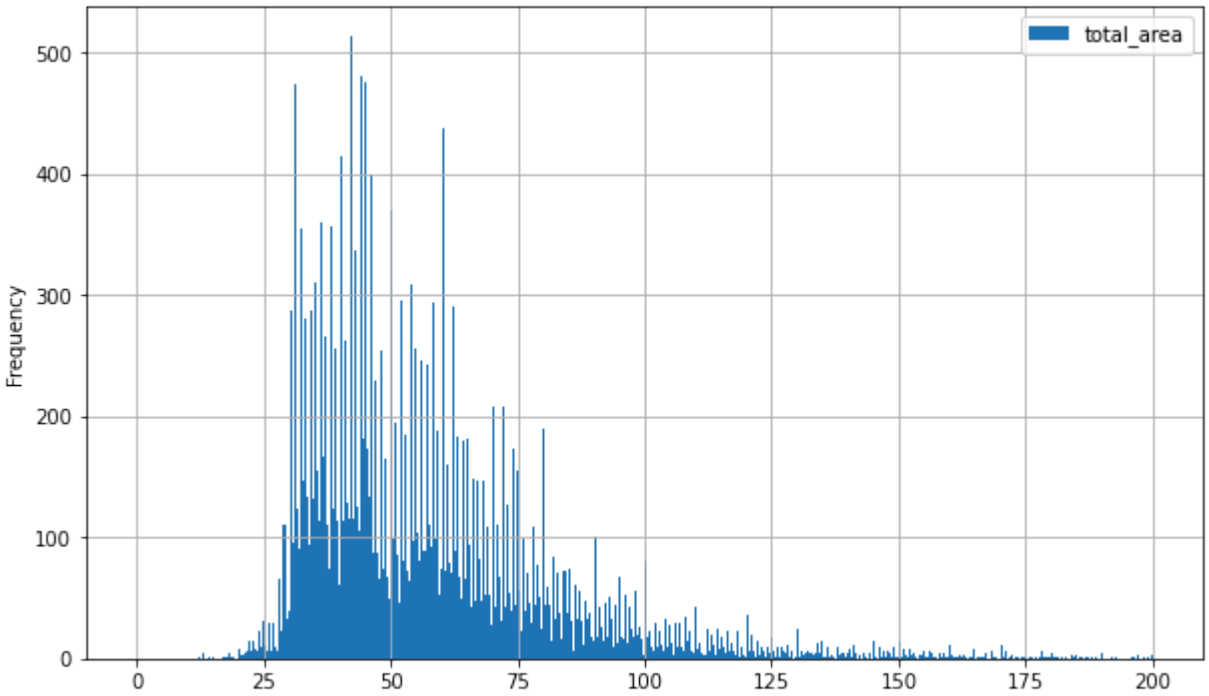

Ориентируясь на гистограмму и диаграмму размаха возьмем значения выше 120 за выбросы

Построим гистограмму минимальных значений

In [ ]:
```
data.hist(column = 'total_area', bins = 50, figsize = (15,3), range = (11,30))
plt.ylim(0, 40);
```

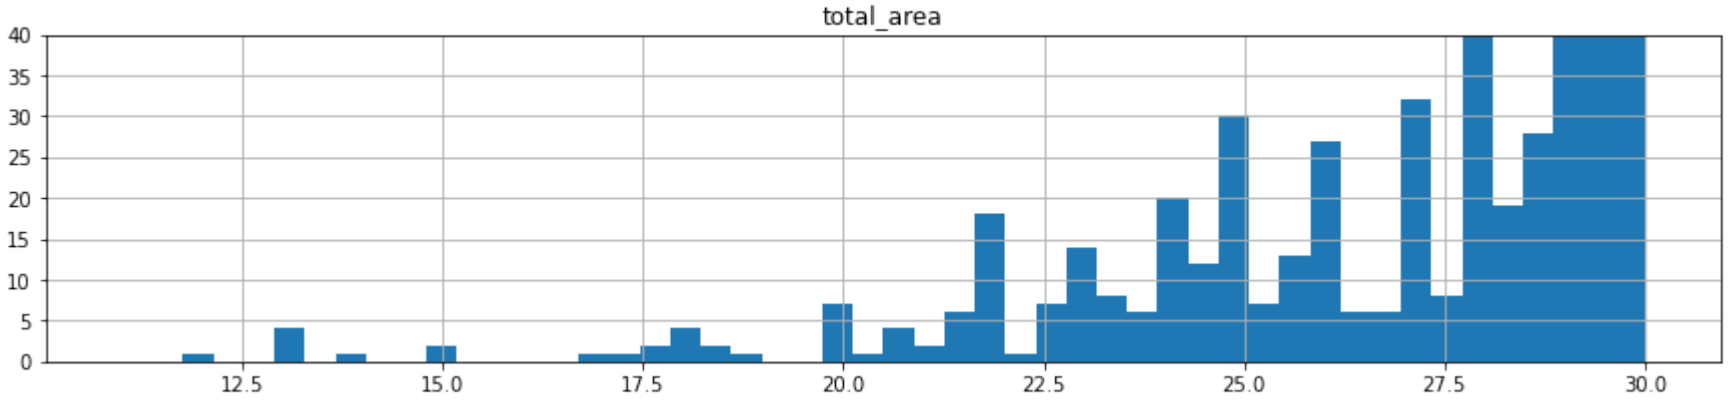

In [ ]:
```
data.query('total_area < 20').count()
```

Out[ ]:
```
total_images            19
last_price              19
total_area              19
first_day_exposition    19
rooms                   19
ceiling_height          10
floors_total            19
living_area             11
floor                   19
is_apartment            19
studio                  19
open_plan               19
kitchen_area             4
balcony                 19
locality_name           19
airports_nearest        14
cityCenters_nearest     14
parks_around3000        19
parks_nearest            6
ponds_around3000        19
ponds_nearest            9
days_exposition         19
price_m                 19
weekday                 19
month                   19
year                    19
type_floor              19
dtype: int64
```

Т.к строк со значениями ниже 20 всего 19, можем взять 20 за минимальное значение

In [ ]:
```
data = data.loc[(data['total_area'] >=20)&(data['total_area'] <=120)|(data['total_area'].isna())]
```

Жилая площадь

Проверим сразу нет ли значений жилой площади кухни превышающих значенияе общей площади квартиры

In [ ]:
```
data.query( 'living_area > total_area or kitchen_area > total_area').count()
```

Out[ ]:
```
total_images            0
last_price              0
total_area              0
first_day_exposition    0
rooms                   0
ceiling_height          0
floors_total            0
living_area             0
floor                   0
is_apartment            0
studio                  0
open_plan               0
kitchen_area            0
balcony                 0
locality_name           0
airports_nearest        0
cityCenters_nearest     0
parks_around3000        0
parks_nearest           0
ponds_around3000        0
ponds_nearest           0
days_exposition         0
price_m                 0
weekday                 0
month                   0
year                    0
type_floor              0
dtype: int64
```

Таких значений нет

In [ ]:
```
plt.ylim(0, 100) #выставляем значения по оси y
data.boxplot('living_area') # строим диаграмму размаха
plt.show()
```

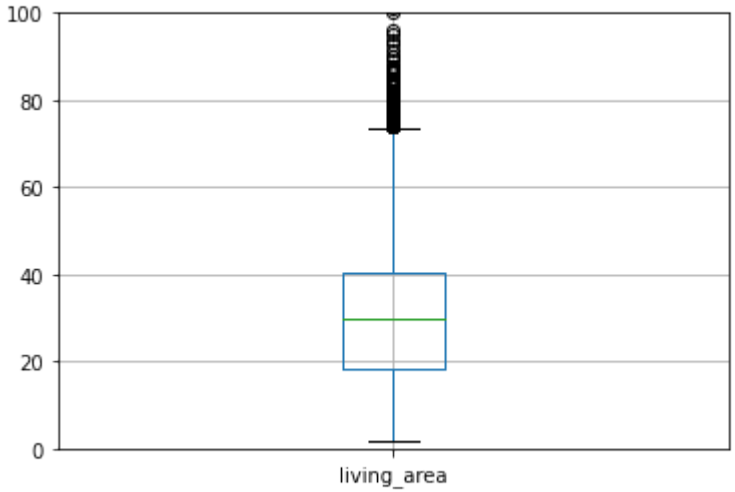

In [ ]:
```
data.plot(y = 'living_area', kind = 'hist', bins = 500, grid=True, range = (0, 80), figsize = (10,6))
#постоим гистограмму
plt.show()
```

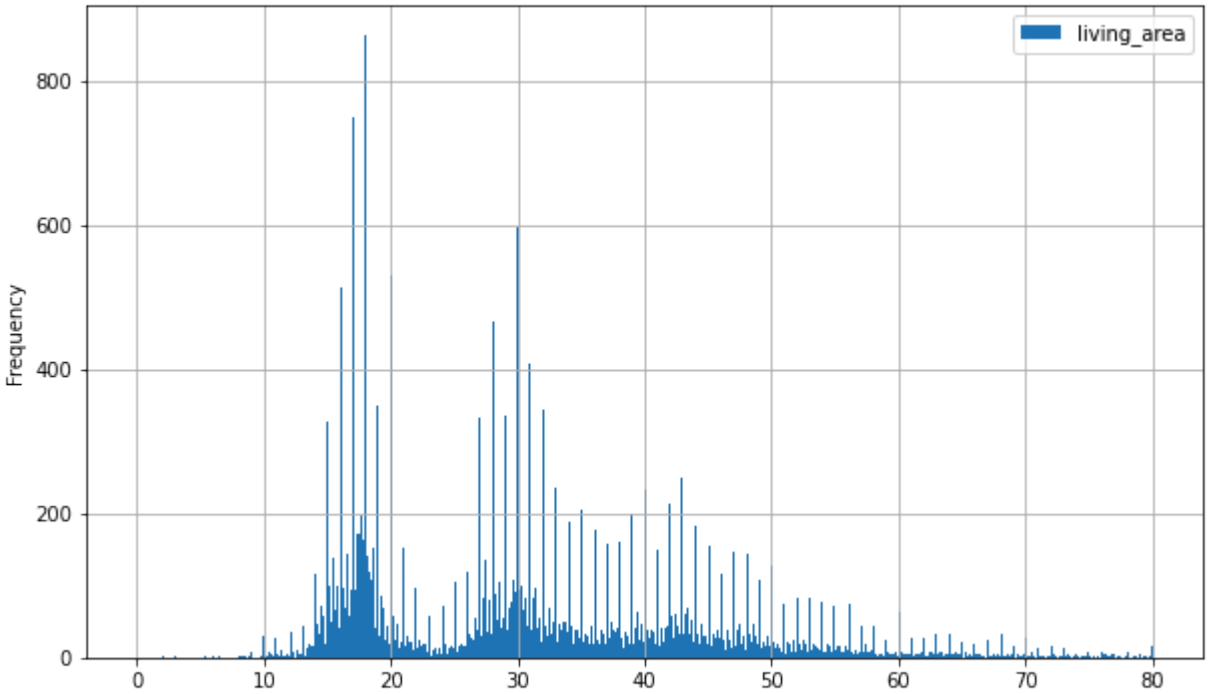

In [ ]:
```
data['living_area'].describe()
```

Out[ ]:
```
count    20333.000000
mean        31.380894
std         13.799247
min          2.000000
25%         18.400000
50%         30.000000
75%         40.500000
max        101.000000
Name: living_area, dtype: float64
```

Правильно, что мы не стали менять пропуски на среднее значение. Среднее значение выше, чем общая площадь самой маленькой квартиры. Верний ус примерно 78. Нижний - минимум - 2 кв.м., это очень мало, но и такое может быть, если это студия. Большая часть квартир имеет жилую площадь от 19 до 42 кв.м. - вполне сравнимо с общей площадью (от 40 до 70 кв. м.)

In [ ]:
```
# check
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 22069 entries, 0 to 23698
Data columns (total 27 columns):
 #   Column                Non-Null Count  Dtype         
---  ------                --------------  -----         
 0   total_images          22069 non-null  int64         
 1   last_price            22069 non-null  int64         
 2   total_area            22069 non-null  float64       
 3   first_day_exposition  22069 non-null  datetime64[ns]
 4   rooms                 22069 non-null  int64         
 5   ceiling_height        13461 non-null  float64       
 6   floors_total          22069 non-null  int64         
 7   living_area           20333 non-null  float64       
 8   floor                 22069 non-null  int64         
 9   is_apartment          22069 non-null  bool          
 10  studio                22069 non-null  bool          
 11  open_plan             22069 non-null  bool          
 12  kitchen_area          20128 non-null  float64       
 13  balcony               22069 non-null  int64         
 14  locality_name         22069 non-null  object        
 15  airports_nearest      16703 non-null  float64       
 16  cityCenters_nearest   16722 non-null  float64       
 17  parks_around3000      22069 non-null  float64       
 18  parks_nearest         7204 non-null   float64       
 19  ponds_around3000      22069 non-null  float64       
 20  ponds_nearest         8145 non-null   float64       
 21  days_exposition       19195 non-null  float64       
 22  price_m               22069 non-null  int64         
 23  weekday               22069 non-null  int64         
 24  month                 22069 non-null  int64         
 25  year                  22069 non-null  int64         
 26  type_floor            22069 non-null  object        
dtypes: bool(3), datetime64[ns](1), float64(11), int64(10), object(2)
memory usage: 4.3+ MB
```

In [ ]:
```
data.hist(column = 'living_area', bins = 50, figsize = (15,3), range = (0,12))
plt.ylim(0, 40);
```

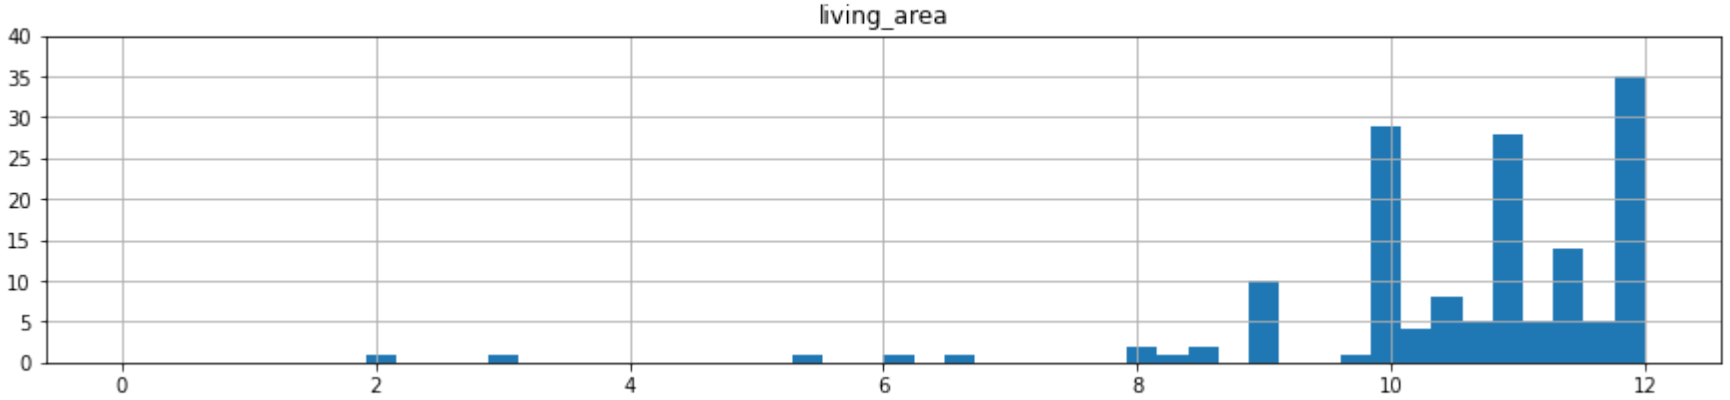

In [ ]:
```
data.query('living_area < 10').count()
```

Out[ ]:
```
total_images            21
last_price              21
total_area              21
first_day_exposition    21
rooms                   21
ceiling_height          15
floors_total            21
living_area             21
floor                   21
is_apartment            21
studio                  21
open_plan               21
kitchen_area            21
balcony                 21
locality_name           21
airports_nearest        21
cityCenters_nearest     21
parks_around3000        21
parks_nearest           10
ponds_around3000        21
ponds_nearest            9
days_exposition         18
price_m                 21
weekday                 21
month                   21
year                    21
type_floor              21
dtype: int64
```

Возьмем значение за минимум и избавимся от 21 строки с меньшими значениями

In [ ]:
```
data = data.loc[(data['living_area'] >=10)&(data['living_area'] <=78)|(data['living_area'].isna())]
#оставляем лишь значения в пределах нормальных значений
```

In [ ]:
```
# check
data.shape[0]
```

Out[ ]:
```
21973
```

Площадь кухни

In [ ]:
```
plt.ylim(0, 30) #выставляем значения по оси y
data.boxplot('kitchen_area') # строим диаграмму размаха
plt.show()
```

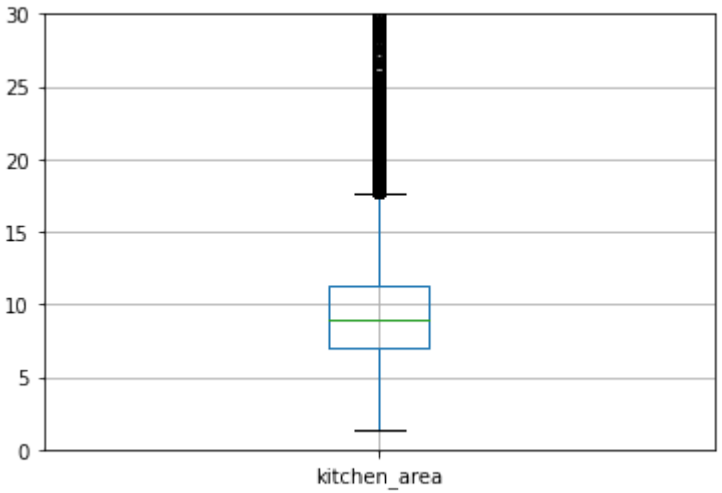

In [ ]:
```
data['kitchen_area'].describe()
```

Out[ ]:
```
count    20040.000000
mean         9.911968
std          4.339390
min          1.300000
25%          7.000000
50%          9.000000
75%         11.300000
max         49.400000
Name: kitchen_area, dtype: float64
```

История похожа на предыдущие. Разброс данных от 1кв.м до 30. Стандартное отклонение высокое. Выбросы за пределами 17кв.м. В основном кухни 6- 12 кв.м

In [ ]:
```
data.plot(y = 'kitchen_area', kind = 'hist', bins = 500, grid=True, range = (0,60), figsize = (10,6))
#построим гистограмму
plt.show()
```

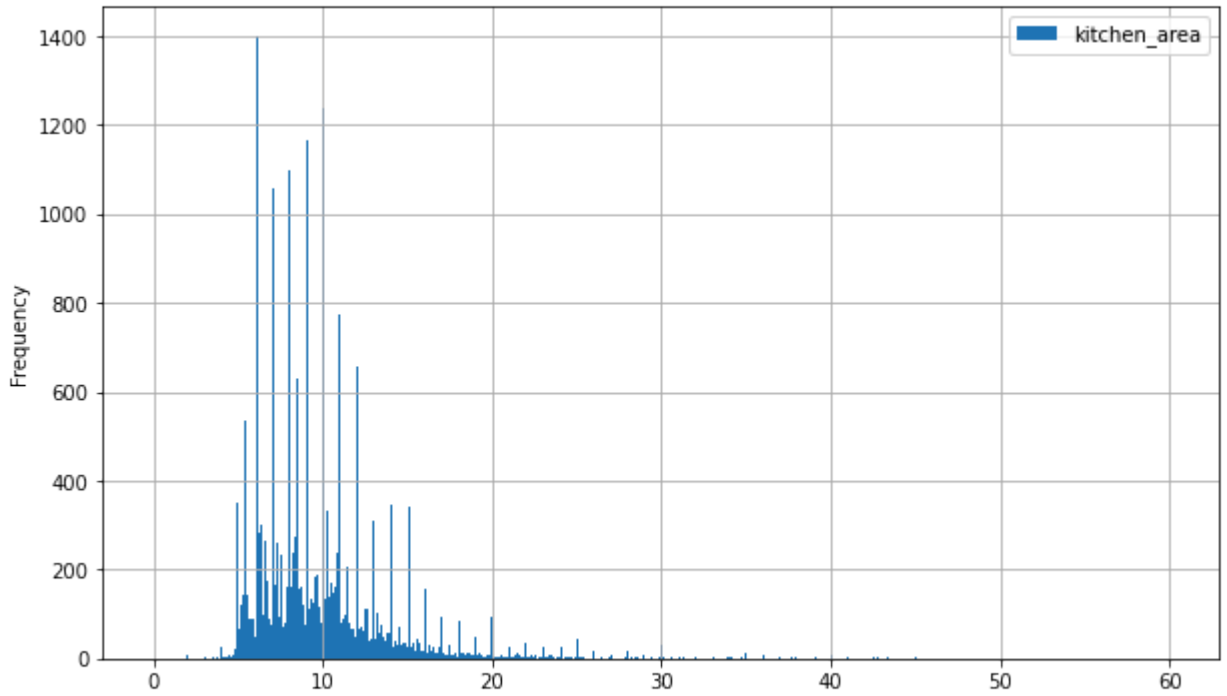

In [ ]:
```
# check
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 21973 entries, 0 to 23698
Data columns (total 27 columns):
 #   Column                Non-Null Count  Dtype         
---  ------                --------------  -----         
 0   total_images          21973 non-null  int64         
 1   last_price            21973 non-null  int64         
 2   total_area            21973 non-null  float64       
 3   first_day_exposition  21973 non-null  datetime64[ns]
 4   rooms                 21973 non-null  int64         
 5   ceiling_height        13394 non-null  float64       
 6   floors_total          21973 non-null  int64         
 7   living_area           20237 non-null  float64       
 8   floor                 21973 non-null  int64         
 9   is_apartment          21973 non-null  bool          
 10  studio                21973 non-null  bool          
 11  open_plan             21973 non-null  bool          
 12  kitchen_area          20040 non-null  float64       
 13  balcony               21973 non-null  int64         
 14  locality_name         21973 non-null  object        
 15  airports_nearest      16615 non-null  float64       
 16  cityCenters_nearest   16633 non-null  float64       
 17  parks_around3000      21973 non-null  float64       
 18  parks_nearest         7153 non-null   float64       
 19  ponds_around3000      21973 non-null  float64       
 20  ponds_nearest         8093 non-null   float64       
 21  days_exposition       19120 non-null  float64       
 22  price_m               21973 non-null  int64         
 23  weekday               21973 non-null  int64         
 24  month                 21973 non-null  int64         
 25  year                  21973 non-null  int64         
 26  type_floor            21973 non-null  object        
dtypes: bool(3), datetime64[ns](1), float64(11), int64(10), object(2)
memory usage: 4.3+ MB
```

In [ ]:
```
# check
data.plot(y = 'kitchen_area', kind = 'hist', bins = 15, grid=True, range = (20,60), figsize = (10,4));
```

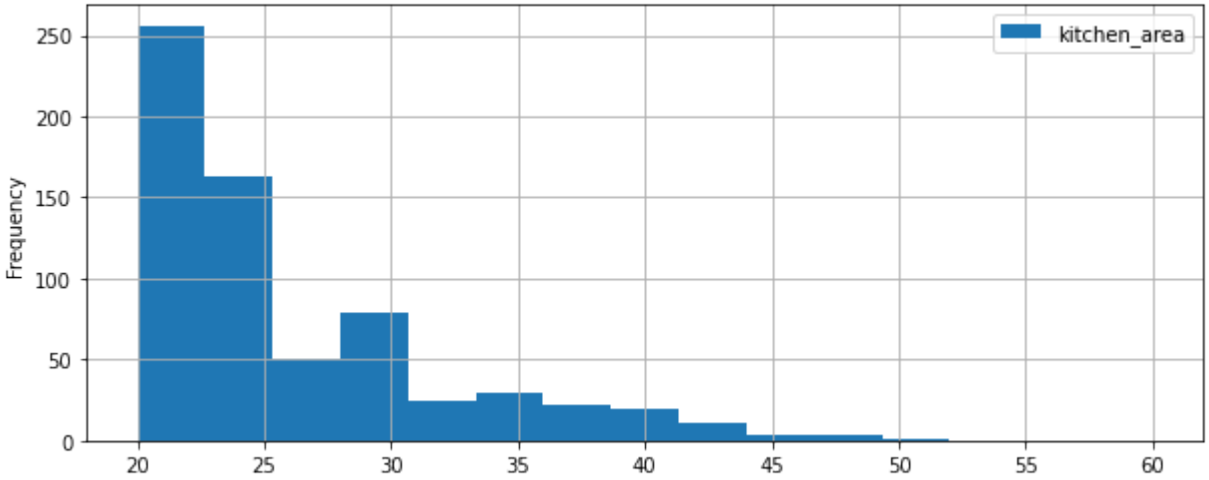

Все, что больше 40 возьмем за выбросы

In [ ]:
```
data.hist(column = 'kitchen_area', bins = 50, figsize = (15,3), range = (0,6))
plt.ylim(0, 40);
```

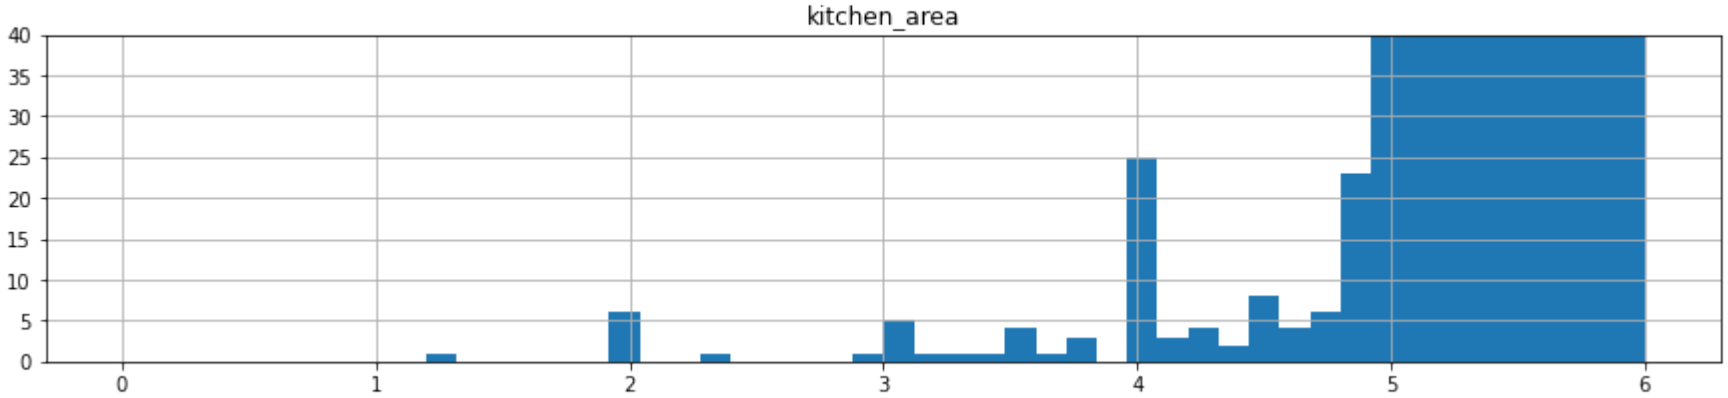

In [ ]:
```
data.query('kitchen_area < 4').count()
```

Out[ ]:
```
total_images            25
last_price              25
total_area              25
first_day_exposition    25
rooms                   25
ceiling_height          17
floors_total            25
living_area             25
floor                   25
is_apartment            25
studio                  25
open_plan               25
kitchen_area            25
balcony                 25
locality_name           25
airports_nearest        20
cityCenters_nearest     20
parks_around3000        25
parks_nearest            5
ponds_around3000        25
ponds_nearest           12
days_exposition         23
price_m                 25
weekday                 25
month                   25
year                    25
type_floor              25
dtype: int64
```

Все, что меньше 4 возьмем за выбросы

In [ ]:
```
data = data.loc[(data['kitchen_area'] >=4)&(data['kitchen_area'] <=40)|(data['kitchen_area'].isnull())]
```

In [ ]:
```
# check
data.shape[0]
```

Out[ ]:
```
21924
```

Цена

In [ ]:
```
data['last_price'].describe()
```

Out[ ]:
```
count    2.192400e+04
mean     5.288666e+06
std      3.143623e+06
min      4.300000e+05
25%      3.400000e+06
50%      4.500000e+06
75%      6.300000e+06
max      2.990000e+07
Name: last_price, dtype: float64
```

In [ ]:
```
plt.ylim(-3e+04, 1.4e+07)
data.boxplot('last_price')
plt.show()
```

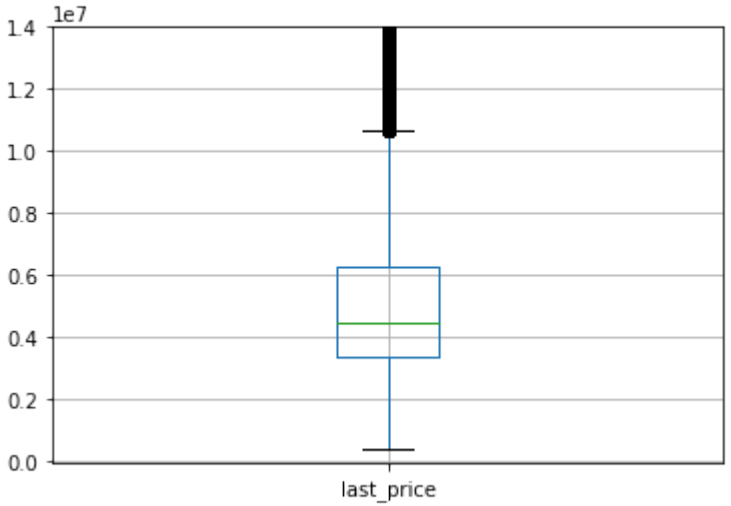

Разброс цен огромен. Не удивительно, ведь расположены они в разных местах. Большая часть квартир стоит 3,5 - 7 млн. руб.

In [ ]:
```
data.plot(y = 'last_price', kind = 'hist', bins = 1000, grid=True, range = (0,3.0e+07), figsize = (10,6))
#построим гистограмму
plt.show()
```

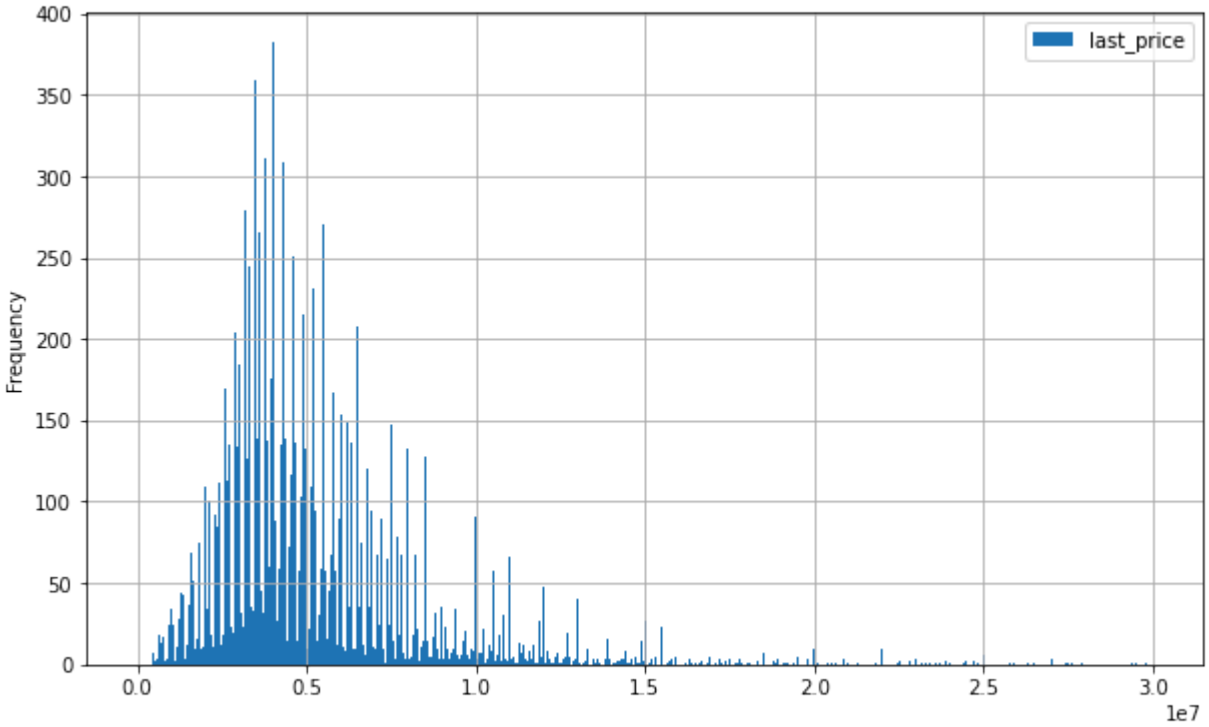

По гистограмме видно, что самая частая цена около 4 млн.руб

In [ ]:
```
data = data.loc[(data['last_price'] <=2.0e+07)] #избавляемся от выбросов
```

In [ ]:
```
# check
data.shape[0]
```

Out[ ]:
```
21816
```

Количество комнат

In [ ]:
```
data['rooms'].describe()
```

Out[ ]:
```
count    21816.000000
mean         1.966355
std          0.887515
min          1.000000
25%          1.000000
50%          2.000000
75%          3.000000
max          7.000000
Name: rooms, dtype: float64
```

In [ ]:
```
data.plot(y = 'rooms', kind = 'hist', bins = 10, grid=True, range = (0,7), figsize = (8,5)) #построим гистограмму
plt.show()
```

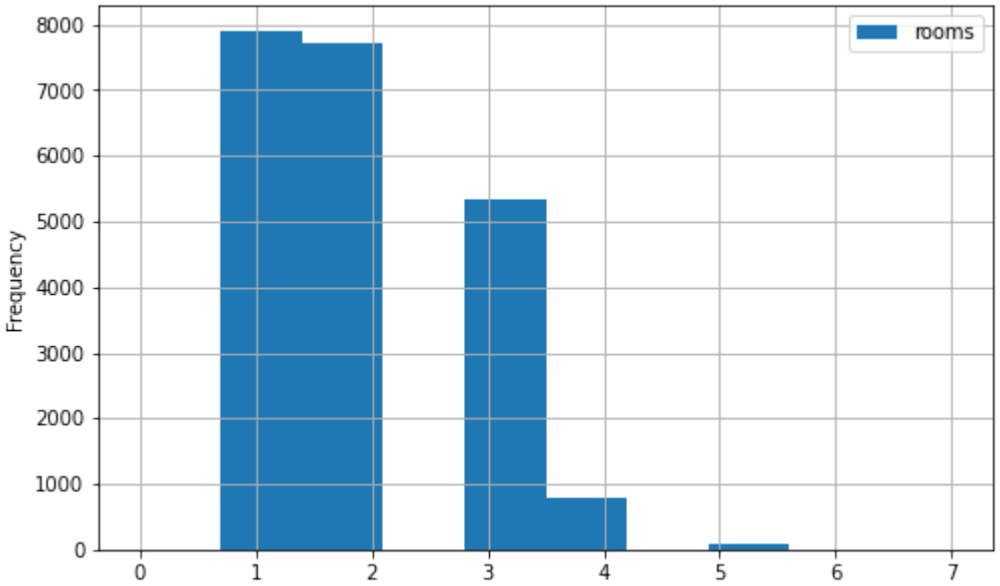

По гистограмме видим, что чаще всего продают однокомнатные и двухкомнатные квартиры.

In [ ]:
```
plt.ylim(0,10)
data.boxplot('rooms')
plt.show()
```

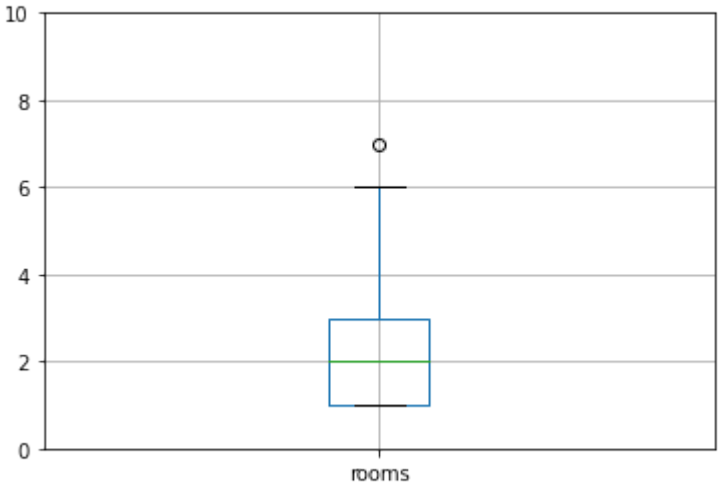

Семикомнатные попали в выбросы. Но мы их оставим, как интересные для исследования

Высота потолков

In [ ]:
```
data['ceiling_height'].describe()
```

Out[ ]:
```
count    13289.000000
mean         2.695765
std          0.240063
min          2.000000
25%          2.500000
50%          2.600000
75%          2.760000
max          5.300000
Name: ceiling_height, dtype: float64
```

In [ ]:
```
data.plot(y = 'ceiling_height', kind = 'hist', bins = 20, grid=True, range = (2,6), figsize = (10,6))
#построим гистограмму
plt.show()
```

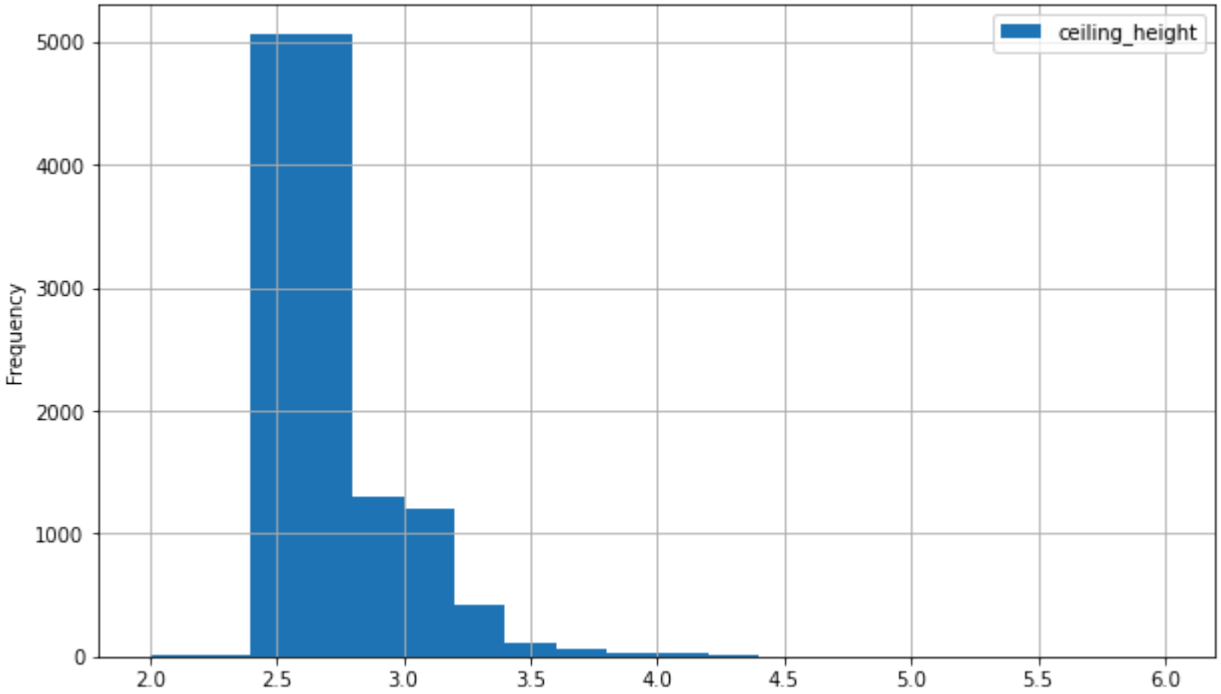

In [ ]:
```
plt.ylim(2, 3.5)
data.boxplot('ceiling_height')
plt.show()
```

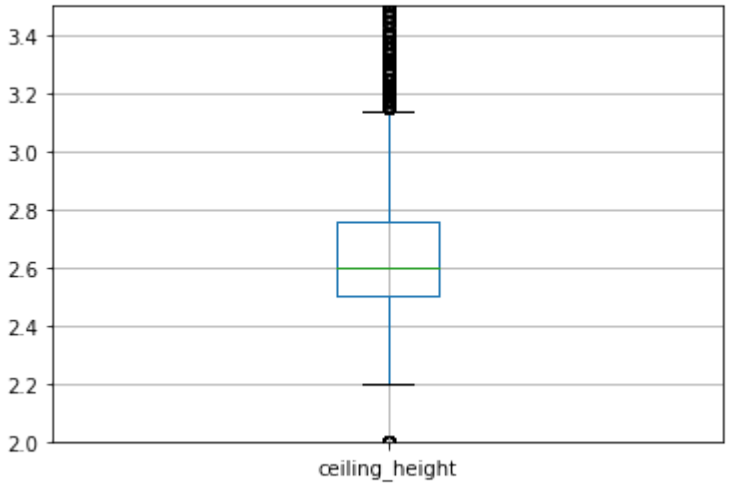

Средняя высота потолка 2,6 м. Минимальная высота сейчас 2,2 м., а максимум 5,3 м.. Т.к такие значения имеют место быть в реальности, не будем удалять их из таблицы, как выбросы.

Этаж

In [ ]:
```
data['floor'].describe()
```

Out[ ]:
```
count    21816.000000
mean         5.899936
std          4.885771
min          1.000000
25%          2.000000
50%          4.000000
75%          8.000000
max         33.000000
Name: floor, dtype: float64
```

In [ ]:
```
data.plot(y = 'floor', kind = 'hist', bins = 50, grid=True, range = (0,30), figsize = (10,6)) #построим гистограмму
plt.show()
```

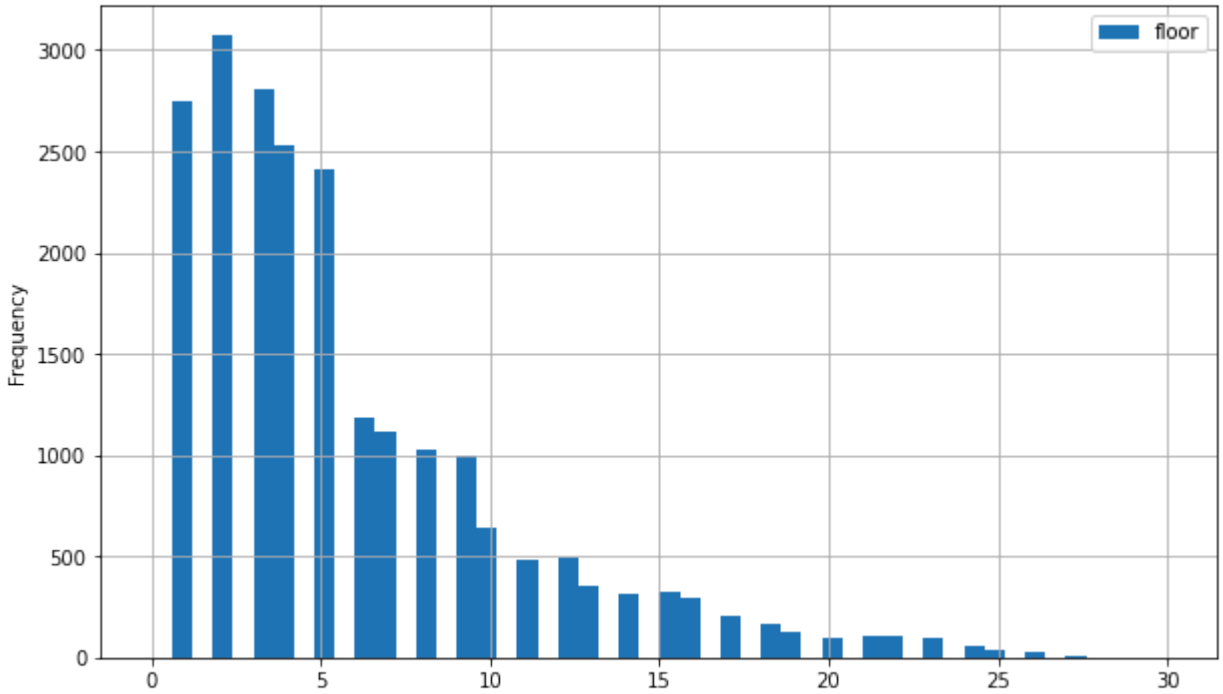

Самые часто встречающиеся значения 1-5. Очень похоже на правду. Стандартное отклонение небольшое, что говорит о небольшом разбросе значений.

Проверим на аномалии значения количества этажей в здании. Нет ли таких строк, где этаж больше количества этажей в здании.

In [ ]:
```
data.query( 'floor > floors_total').count()
```

Out[ ]:
```
total_images            71
last_price              71
total_area              71
first_day_exposition    71
rooms                   71
ceiling_height           7
floors_total            71
living_area             47
floor                   71
is_apartment            71
studio                  71
open_plan               71
kitchen_area            35
balcony                 71
locality_name           71
airports_nearest        65
cityCenters_nearest     65
parks_around3000        71
parks_nearest           31
ponds_around3000        71
ponds_nearest           43
days_exposition         63
price_m                 71
weekday                 71
month                   71
year                    71
type_floor              71
dtype: int64
```

In [ ]:
```
data.loc[data['floor'] > data['floors_total'], 'floors_total'] = data['floor']
```

Такие строки есть. Поменяем значения общего количества этажей на этаж, приняв его за последний. 72 строки - это меньше 1%.

Тип этажа

In [ ]:
```
data['type_floor'].value_counts().plot(kind='pie')
plt.show()
```

Квартир на первом и последнем этажах практически поровну.

Общее количество этажей в доме

In [ ]:
```
data['floors_total'].describe()
```

Out[ ]:
```
count    21816.000000
mean        10.749908
std          6.597222
min          1.000000
25%          5.000000
50%          9.000000
75%         16.000000
max         36.000000
Name: floors_total, dtype: float64
```

In [ ]:
```
data.plot(y = 'floors_total', kind = 'hist', bins = 50, grid=True, range = (0,30), figsize = (10,6))
#построим гистограмму
plt.show()
```

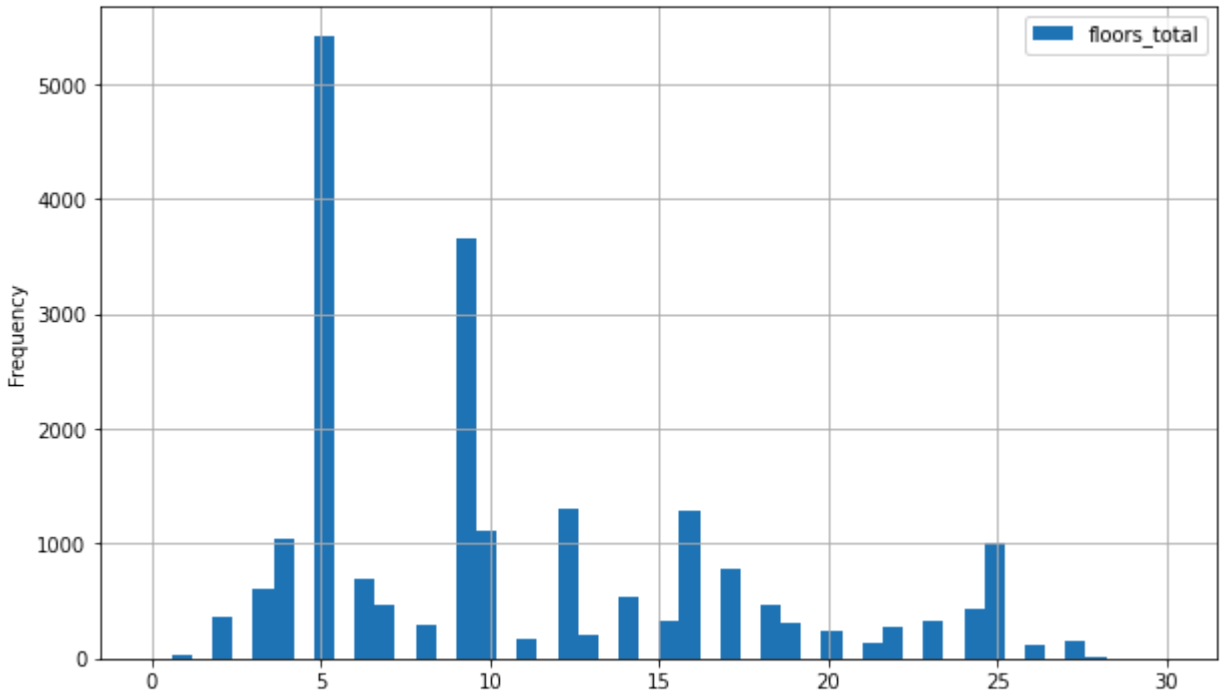

Чаще всего дома имеют 5 и 9 этажей. Так и есть.

Расстояние до центра города

In [ ]:
```
data['cityCenters_nearest'].describe()
```

Out[ ]:
```
count    16485.000000
mean        14.722414
std          8.511493
min          0.000000
25%         10.000000
50%         13.000000
75%         17.000000
max         66.000000
Name: cityCenters_nearest, dtype: float64
```

In [ ]:
```
data.plot(y = 'cityCenters_nearest', kind = 'hist', bins = 100, grid=True, range = (0,60), figsize = (10,6))
#построим гистограмму
plt.show()
```

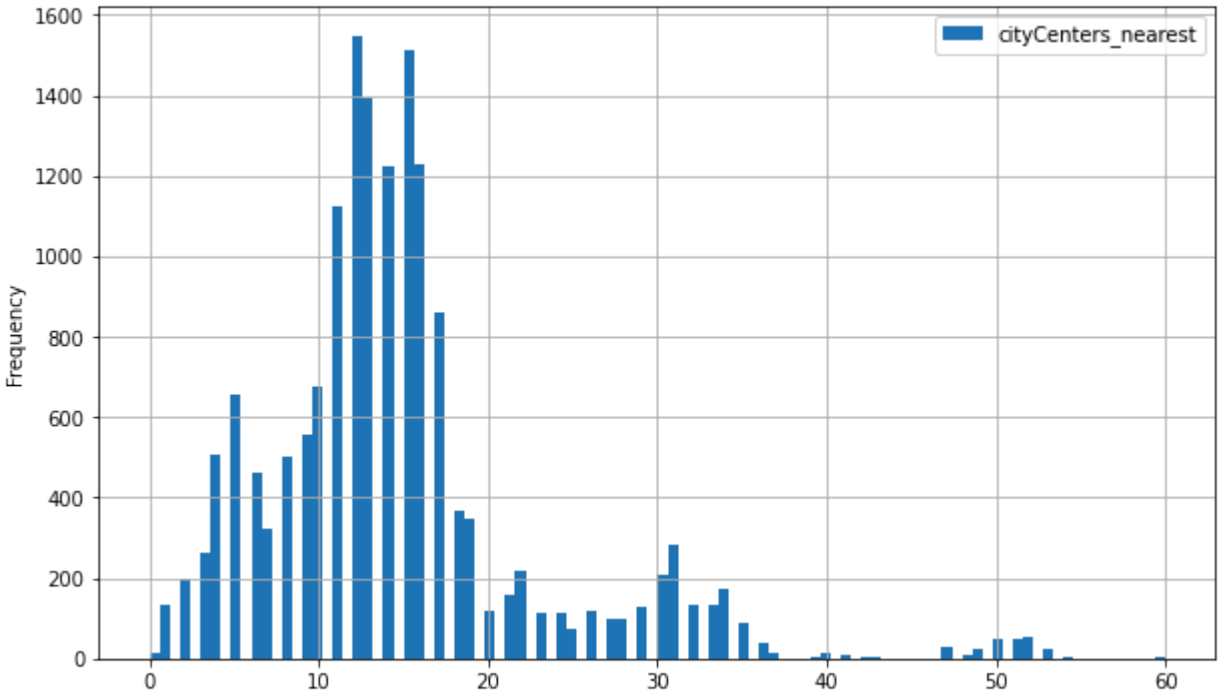

Меньше всего квартир находится в центре города. А некоторые расположены аж в 60 км.

In [ ]:
```
plt.ylim(0, 35)
data.boxplot('cityCenters_nearest')
plt.show()
```

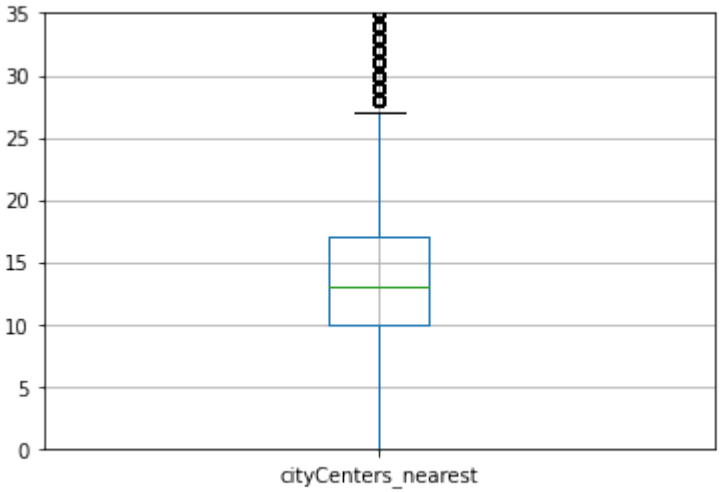

Большая часть квартир расположена на расстоянии 11-18 км от центра города. Нижний ус на отметке 2. Значит кто-то живет в центре. Верхний ус на 26 км. Остальное считаем выбросами

Расстояние до аэропорта

In [ ]:
```
plt.ylim(0, 100000)
data.boxplot('airports_nearest')
plt.show()
```

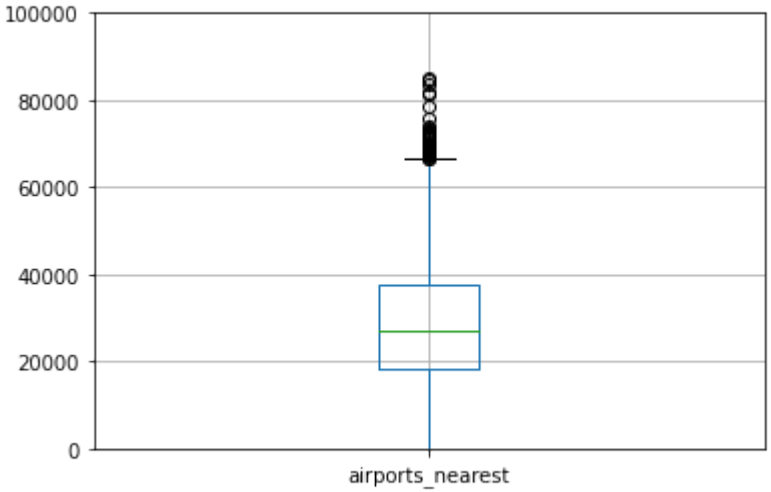

В основном расстояние до аэропорта в значениях от 18 до 39 км. Но мы помним, что во многих строках значения просто отсутствовали

In [ ]:
```
data.plot(y = 'airports_nearest', kind = 'hist', bins = 250, grid=True, range = (0,100000), figsize = (10,6))
#построим гистограмму
plt.show()
```

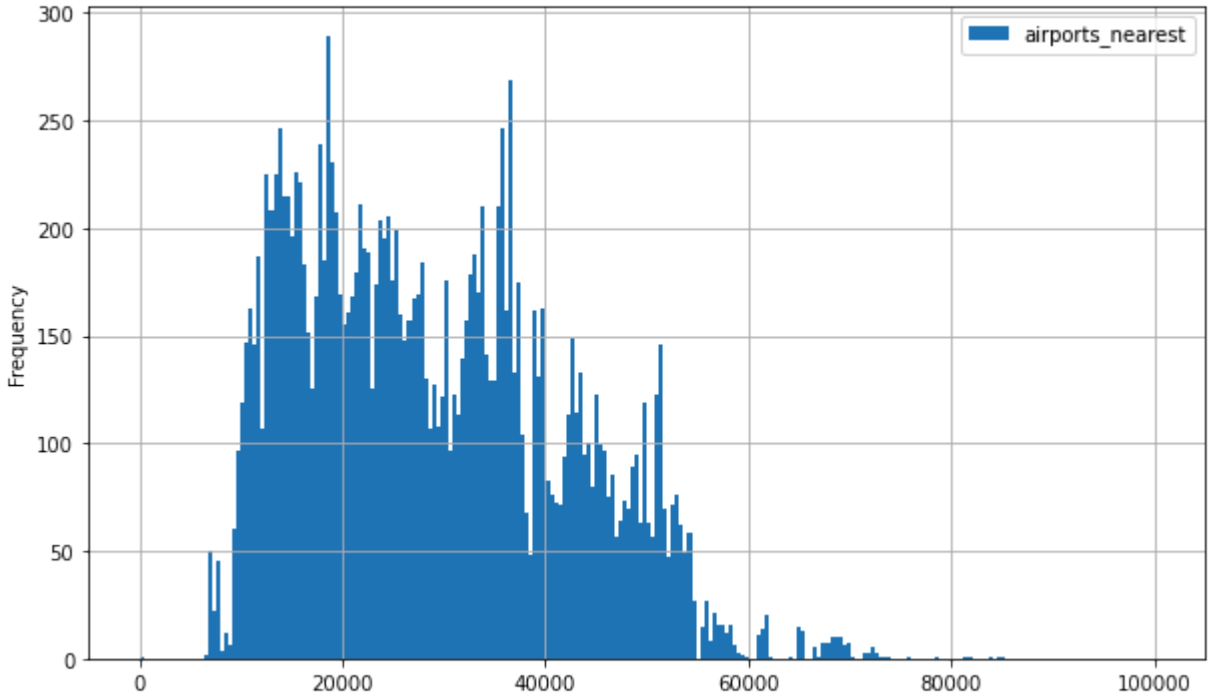

Расстояние до ближайшего парка

In [ ]:
```
data.plot(y = 'parks_nearest', kind = 'hist', bins = 200, grid=True, range = (0,3000), figsize = (10,6))
#построим гистограмму
plt.show()
```

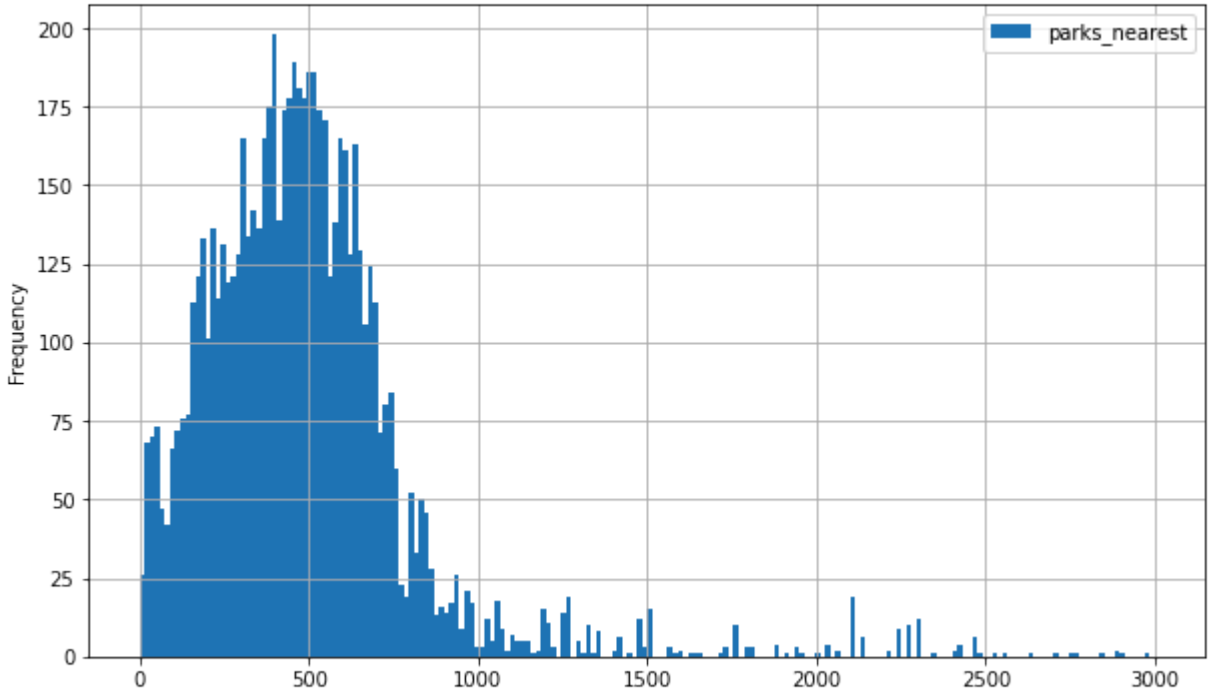

In [ ]:
```
plt.ylim(-200, 3000)
data.boxplot('parks_nearest')
plt.show()
```

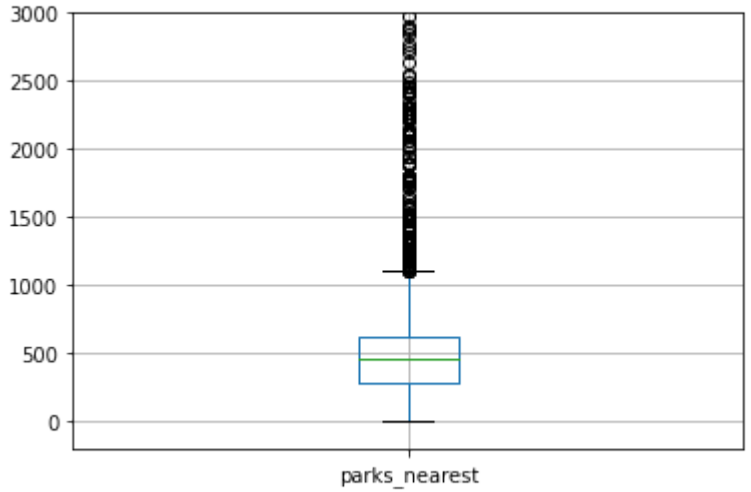

In [ ]:
```
data['parks_nearest'].describe()
```

Out[ ]:
```
count    7066.000000
mean      493.430795
std       339.088390
min         1.000000
25%       289.000000
50%       458.000000
75%       616.000000
max      3190.000000
Name: parks_nearest, dtype: float64
```

В основном в продаже квартиры недалеко от парка, в 300-600 метрах. Но кому-то очень повезет и до парка будет 1 м.

День и месяц публикации

In [ ]:
```
data.plot(y = 'weekday', kind = 'hist', bins = 7, grid=True, range = (0,7), figsize = (10,6)) #построим гистограмму
plt.show()
```

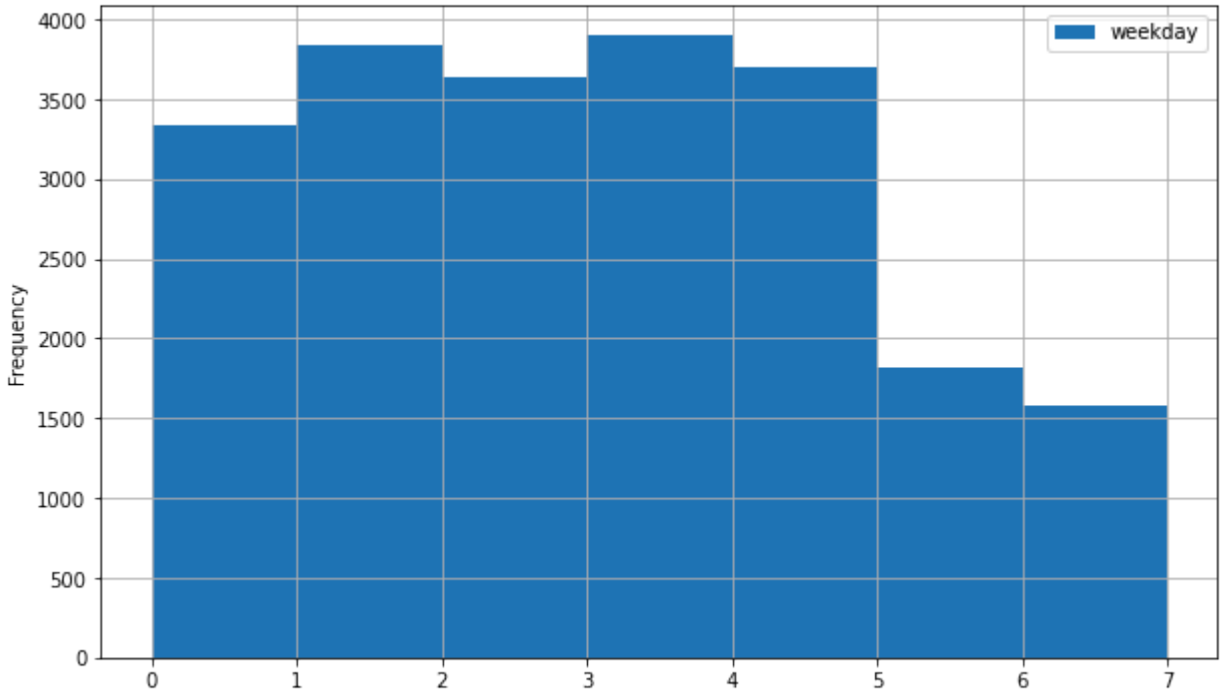

Чаще всего размещают объявления по четвергам, а реже всего по воскресеньям

In [ ]:
```
data.plot(y = 'month', kind = 'hist', bins = 24, grid=True, range = (1,12), figsize = (12,6)) #постоим гистограмму
plt.show()
```

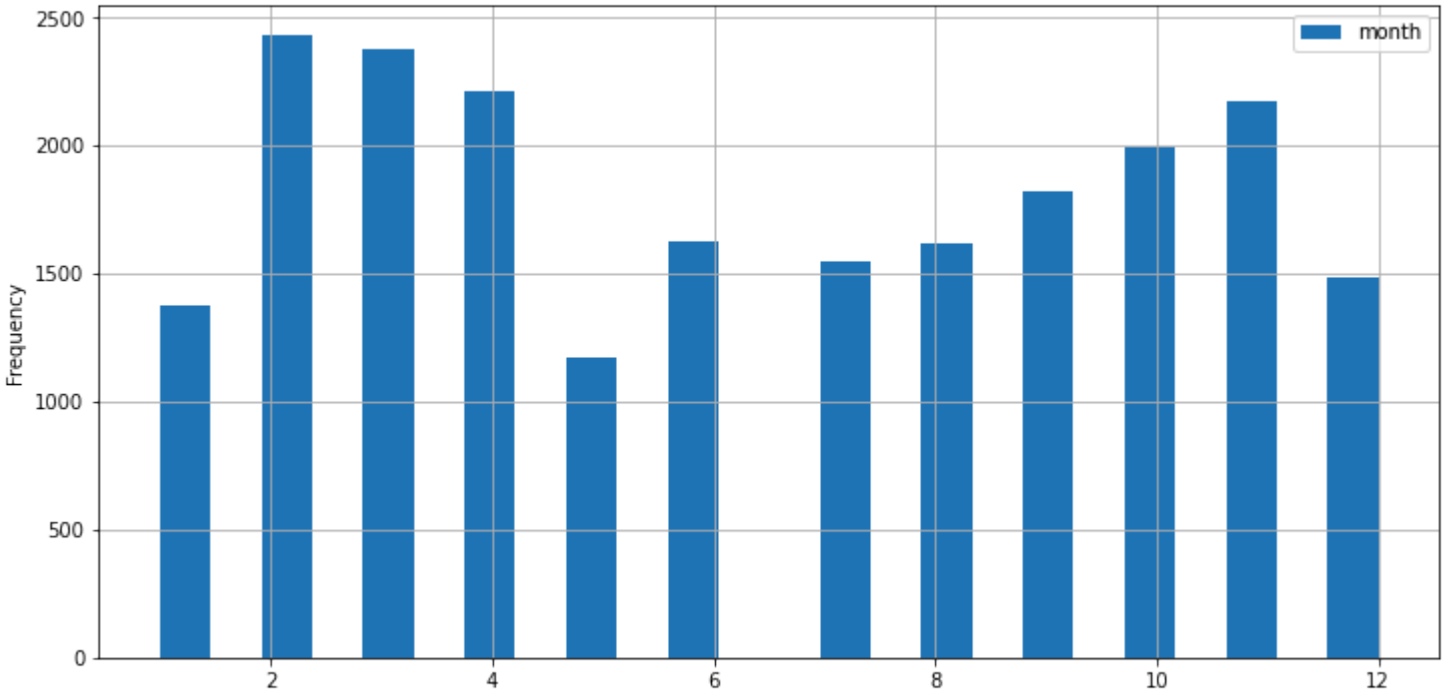

Самый насыщенный на объявления месяц февраль. В мае размещают объявления реже всего

In [ ]:
```
# check

# Показатели о кол-ве объявлений в датасете, минимальных и максимальных значениях
# в выбранных параметрах о продаже квартир

(
    data[['rooms', 'total_area', 'ceiling_height', 'days_exposition', 'last_price', 'living_area',  'kitchen_area',
          'floor', 'floors_total']]
    .apply (['count', 'min', 'max'])
    .style.format("{:,.2f}")
)
```

Out[ ]:

	rooms	total_area	ceiling_height	days_exposition	last_price	living_area	kitchen_area	floor	floors_total
count	21,816.00	21,816.00	13,289.00	19,009.00	21,816.00	20,097.00	19,897.00	21,816.00	21,816.00
min	1.00	20.00	2.00	3.00	430,000.00	10.00	4.00	1.00	1.00
max	7.00	120.00	5.30	999.00	20,000,000.00	78.00	40.00	33.00	36.00

In [ ]:
```
# check
data.hist(column = 'kitchen_area', bins = 50, figsize = (15,3), range = (0,5));
```

Как быстро продавались квартиры

In [ ]:
```
data_corr_days = data.query('~days_exposition.isna() and days_exposition >= 1')
# делаем выборку без нулевых значений и пустых строк
```

In [ ]:
```
data_corr_days.plot(y = 'days_exposition', kind = 'hist', bins = 400, grid=True, range = (0,1500), figsize = (12,6))
#построим гистограмму
plt.show()
```

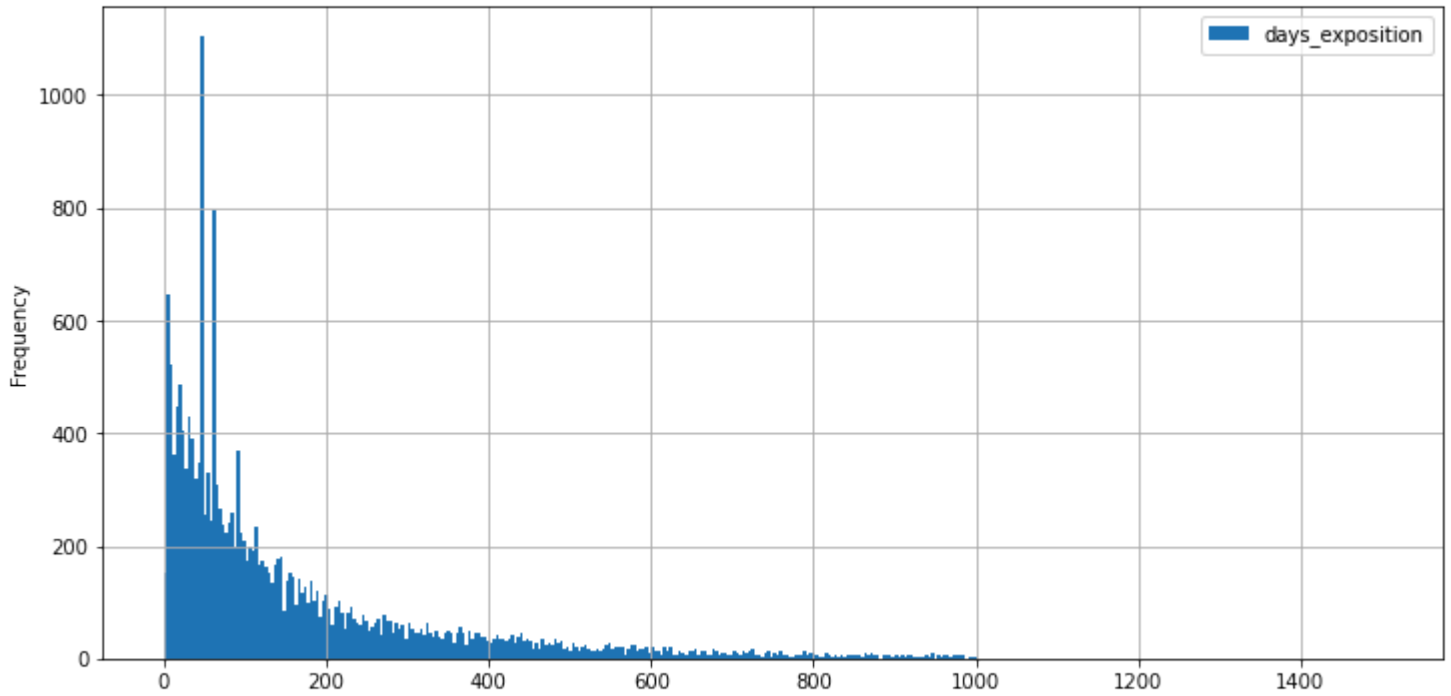

In [ ]:
```
data_corr_days['days_exposition'].describe()
```

Out[ ]:
```
count    19009.000000
mean       163.562944
std        184.226479
min          3.000000
25%         44.000000
50%         91.000000
75%        216.000000
max        999.000000
Name: days_exposition, dtype: float64
```

In [ ]:
```
plt.ylim(-200, 600)
data_corr_days.boxplot('days_exposition')
plt.show()
```

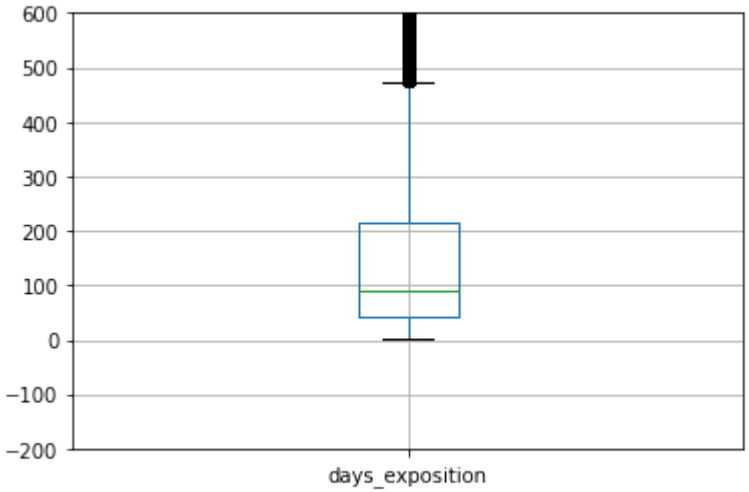

Большая часть объявлений висела на сайте от 50 до 200 дней. Все, что больше 500 возьмем за выбросы. Построим гистограмму без них

In [ ]:
```
#построим гистограмму
data_corr_days.plot(y = 'days_exposition', kind = 'hist', bins = 100, grid=True, range = (0,500), figsize = (12,6))
plt.show()
```

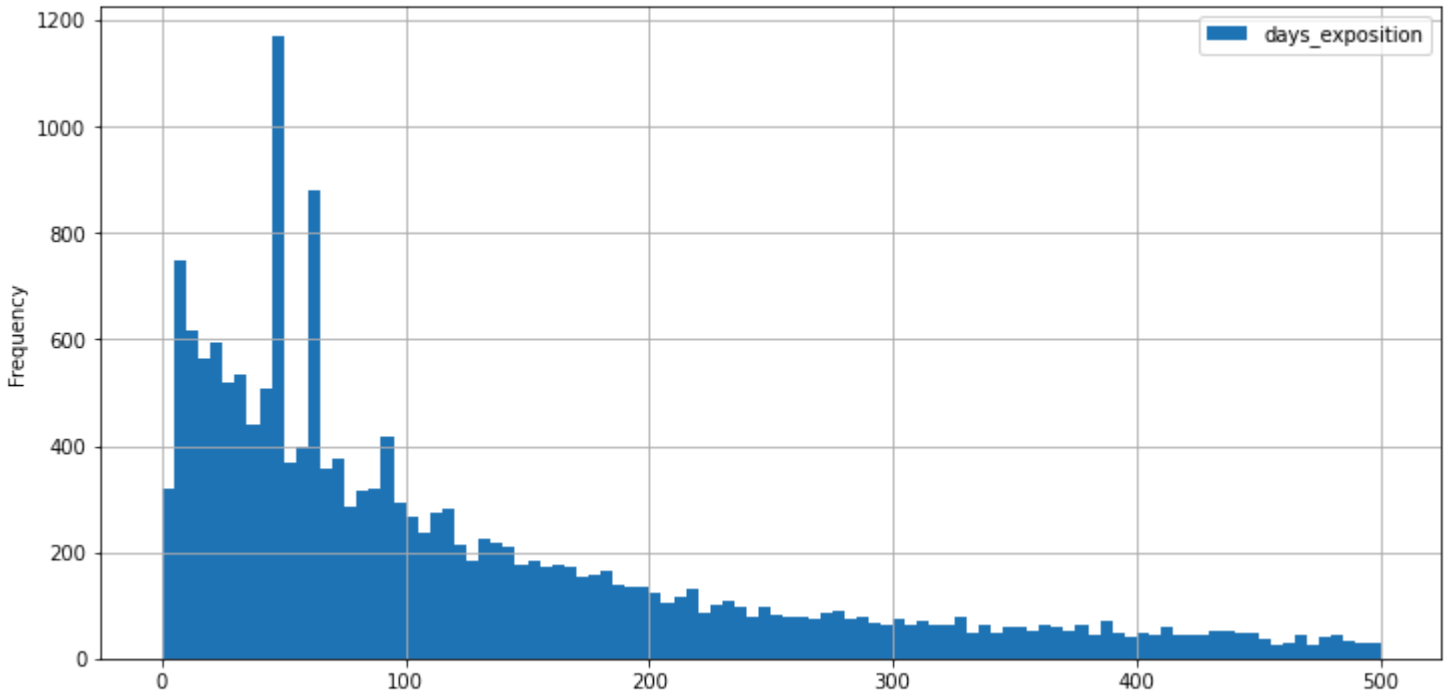

Чаще всего объявления висят около трех месяцев, но бывает, что квартиры продаются за 1 день или, наоборот, очень долго не продаются, как та, что висела дольше 4 лет.

Изучив сайт Яндекс.Недвижимость, видим, что срок публикации объявления для квартир от 10 млн — 90 дней. Поэтому на графике мы видим скачок. Это не значит, что квартиры проданы. Скорее всего у них просто закнчился срок объявления. Тоже самое происходит и с квартирами до 4,5 млн. — 45 дней, от 4,5 до 10 млн — 60 дней

In [ ]:
```
data.plot(y = 'year', kind = 'hist', bins = 100, grid=True, range = (2012,2022), figsize = (12,6))
plt.show()
```

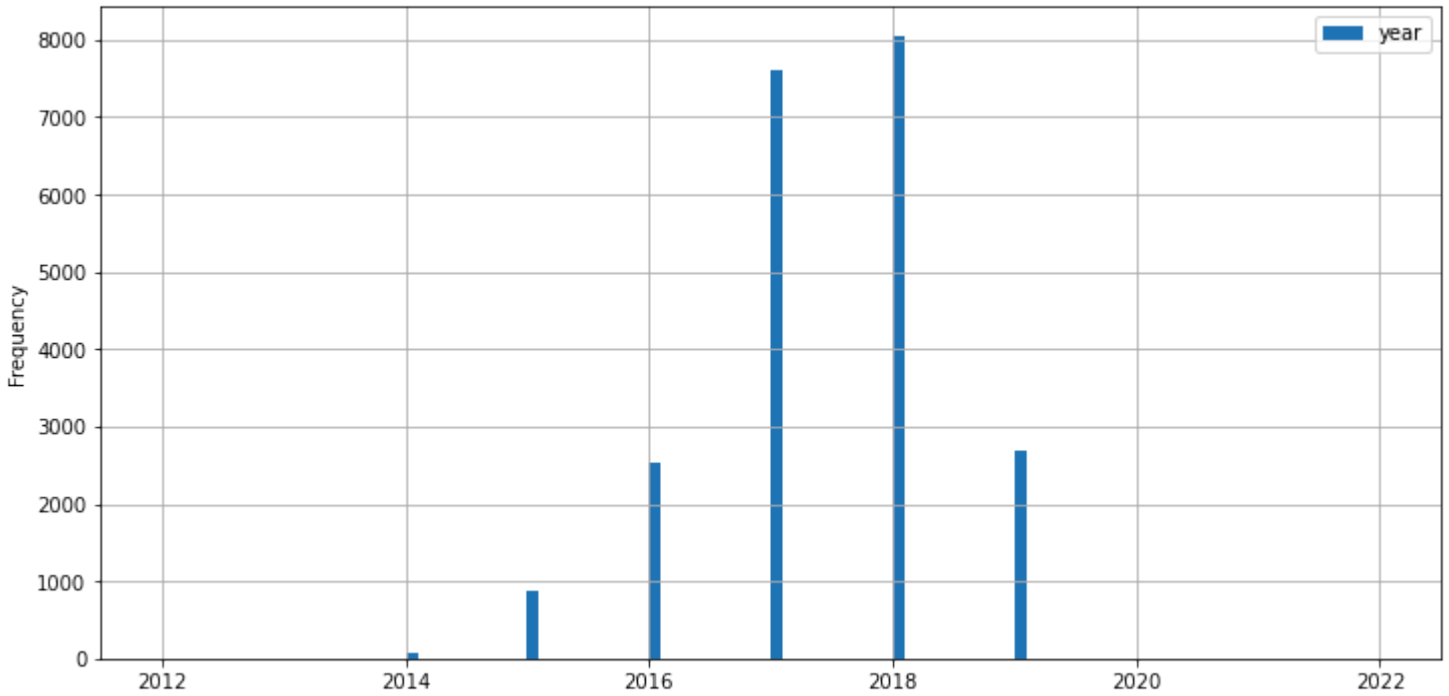

Либо продажи росли по годам, либо данные вводили регулярнее. Скорее всего данные в таблице не до конца 2019 г.

Изучим какие факторы больше всего влияют на общую стоимость объекта

Зависимость цены от общей площади

In [ ]:
```
data['last_price'].corr(data['total_area'])
```

Out[ ]:
```
0.730607090018265
```

Корреляция положительная. Коэффициент Пирсона в 0.73 говорит о наличии связи, и довольно сильной. Выходит, увеличение площади сопровождается увеличением цены, но так бывает не всегда.

In [ ]:
```
data.plot(x = 'last_price', y = 'total_area', kind = 'scatter',  alpha = 0.3)
plt.show()
```

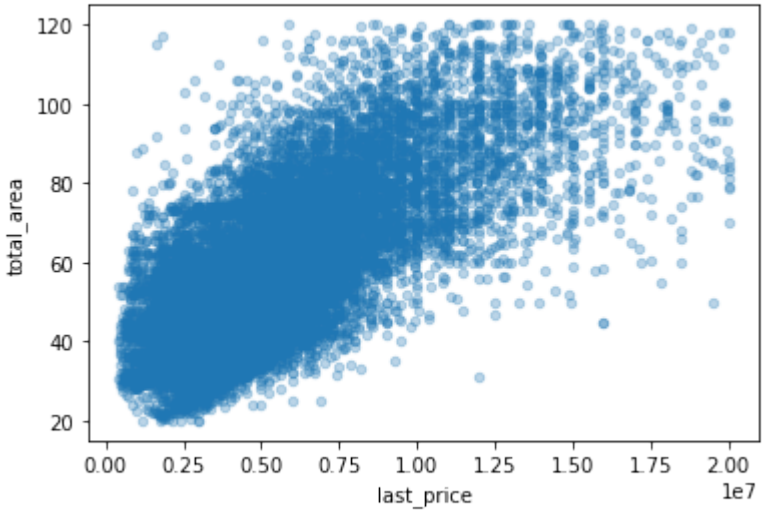

Есть основная масса точек с наиболее частыми сочетаниями цены и площади. При этом с увеличением площади увеличивается и цена. Это мы можем увидеть на графике. Но лишь в среднем. Можно найти уникальные примеры квартир с высокой ценой и не очень большой площадью.

Завсисимость цены от жилой площади

In [ ]:
```
data['last_price'].corr(data['living_area'])
```

Out[ ]:
```
0.5935695614314986
```

In [ ]:
```
data.pivot_table(index = 'living_area', values  = 'last_price').plot()
plt.show()
```

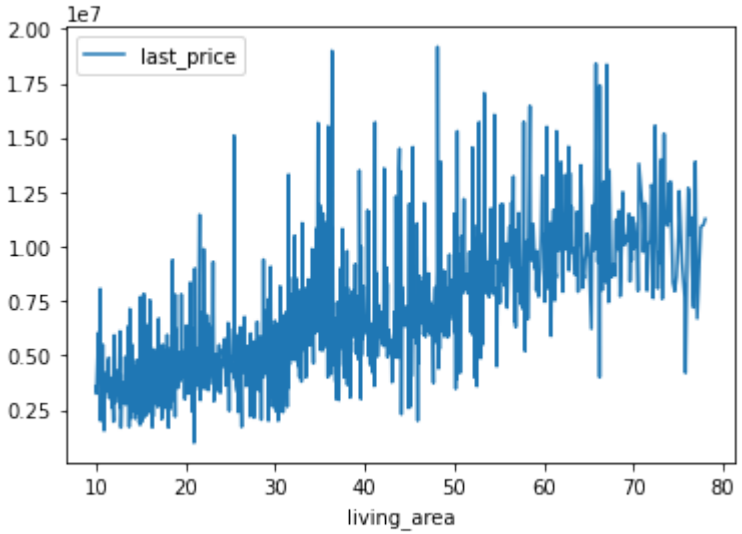

Очень похоже на общую площадь. Коэффициент Пирсона еще ниже, 0,59. Значит зависимость цены от жилой площади ниже, чем от общей

Завсисимость цены от площади кухни

In [ ]:
```
data['last_price'].corr(data['kitchen_area'])
```

Out[ ]:
```
0.5464135120612365
```

In [ ]:
```
data.pivot_table(index = 'kitchen_area', values  = 'last_price').plot()
plt.show()
```

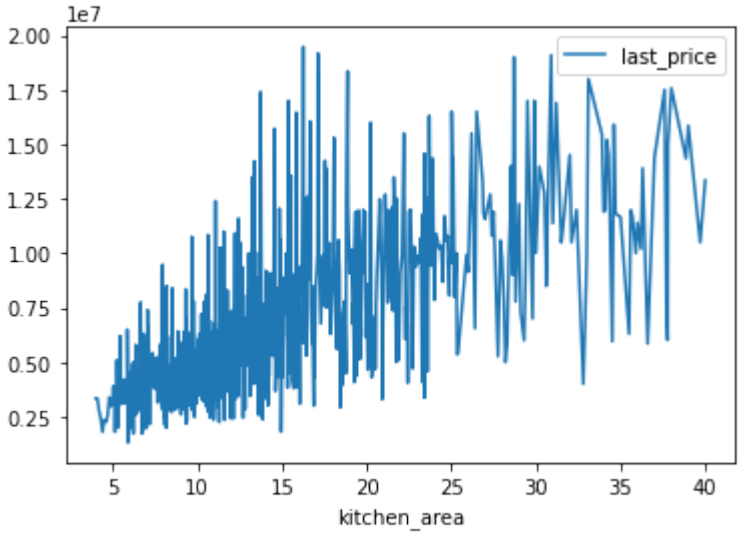

А зависимость цены от площади кухни еще ниже. *Хочется посмотреть как зависит жилая площадь и площадь кухни от общей площади*

In [ ]:
```
#создадим перемеенную для столбцов общая площадь, жилая площадь и площадь кухни
data_corr_area = data.filter(['total_area','kitchen_area','living_area'], axis=1)
#корреляция по трем столбцам
data_corr_area.corr()
```

Out[ ]:

	total_area	kitchen_area	living_area
total_area	1.000000	0.482685	0.909565
kitchen_area	0.482685	1.000000	0.191732
living_area	0.909565	0.191732	1.000000

Видим сильную связь между общей и жилой площадью. А вот связь между общей площадью и кухней низкая. Это значит, что и в больших квартирах часто встречаются маленькие кухни.

Завсисимость цены от количества комнат

In [ ]:
```
data['last_price'].corr(data['rooms'])
```

Out[ ]:
```
0.43332704396276617
```

In [ ]:
```
data.pivot_table(index = 'rooms', values  = 'last_price').plot()
plt.show()
```

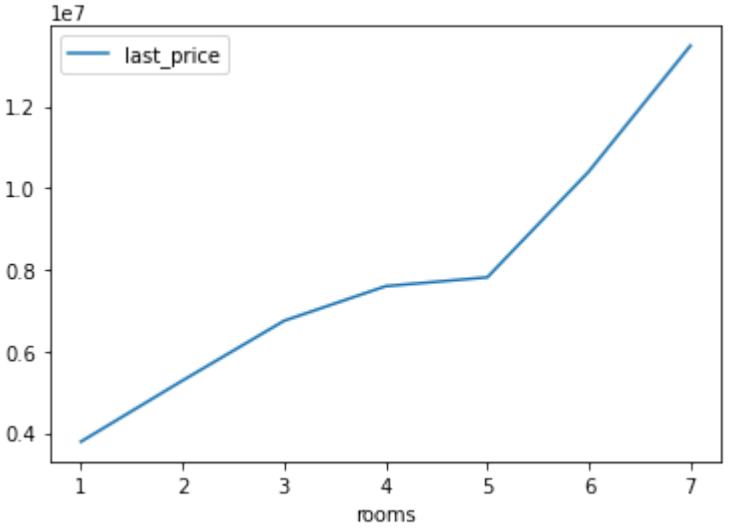

Коэффициент корреляции низкий, значит зависимость цены от количества комнат слабая

Завсисимость цены от этажа, на котором расположена квартира

In [ ]:
```
data['last_price'].corr(data['floor'])
```

Out[ ]:
```
0.1218105319163859
```

In [ ]:
```
data.pivot_table(index = 'floor', values  = 'last_price').plot()
plt.show()
```

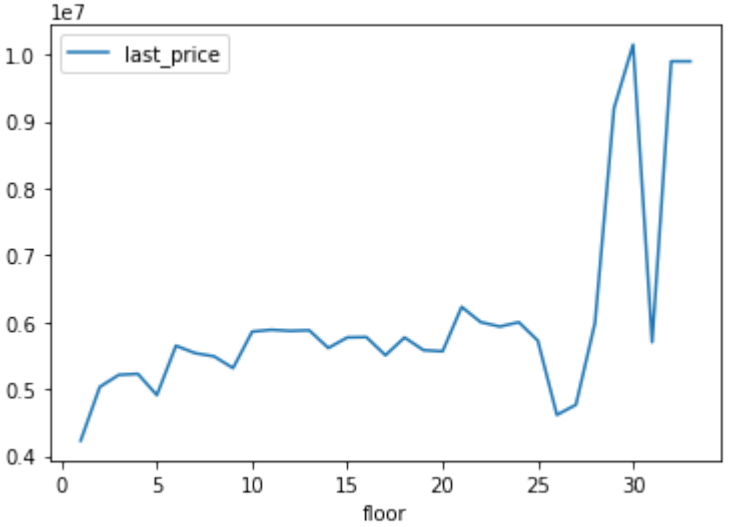

Корреляция цены и этажа очень слабая, всего 0,12.

In [ ]:
```
data_floor = data.groupby('type_floor')['last_price'].mean()
data_floor.plot()
plt.show()
```

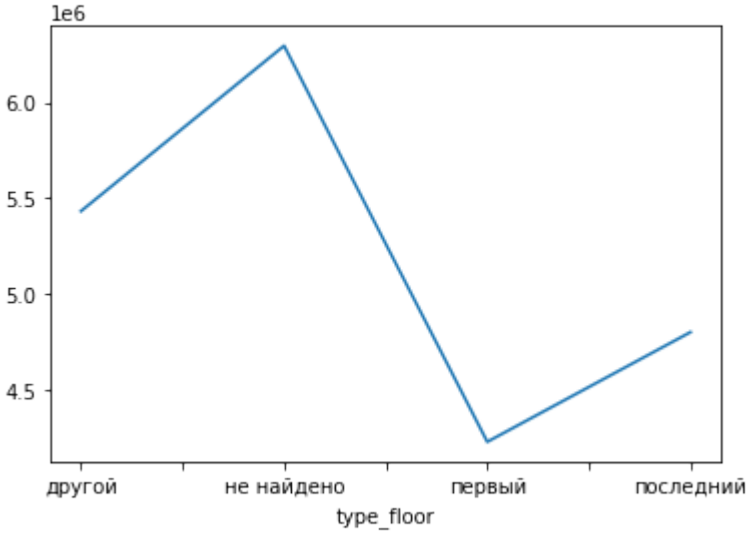

In [ ]:
```
data_floor
```

Out[ ]:
```
type_floor
другой         5.432199e+06
не найдено     6.294832e+06
первый         4.228888e+06
последний      4.800969e+06
Name: last_price, dtype: float64
```

Самые дешевые квартиры на первом этаже, далее на последнем, остальные дороже.

Завсисимость цены от даты размещения

In [ ]:
```
#создадим перемеенную для столбцов даты и цены.
#Т.к столбец Дата публикации имеет тип данных datetime и корреляцию по нему сделать невозможно
data_corr_date = data.filter(['last_price','weekday','month','year'], axis=1)
#корреляция по четырем столбцам
data_corr_date.corr()
```

Out[ ]:

	last_price	weekday	month	year
last_price	1.000000	-0.012034	0.006185	0.000945
weekday	-0.012034	1.000000	0.009439	-0.006376
month	0.006185	0.009439	1.000000	-0.276299
year	0.000945	-0.006376	-0.276299	1.000000

Корреляция цены и даты начинается с сотых значений, значит она очень слабая

In [ ]:
```
data.pivot_table(index = 'weekday', values  = 'last_price').plot()
plt.show()
```

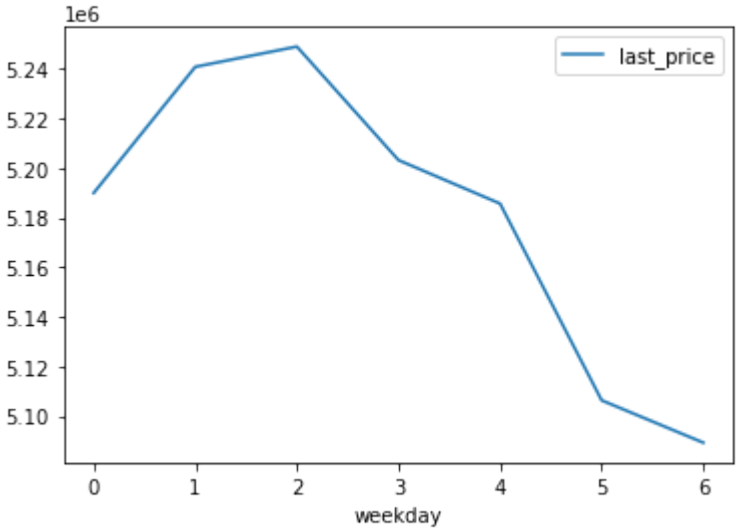

In [ ]:
```
data.pivot_table(index = 'month', values  = 'last_price').plot()
plt.show()
```

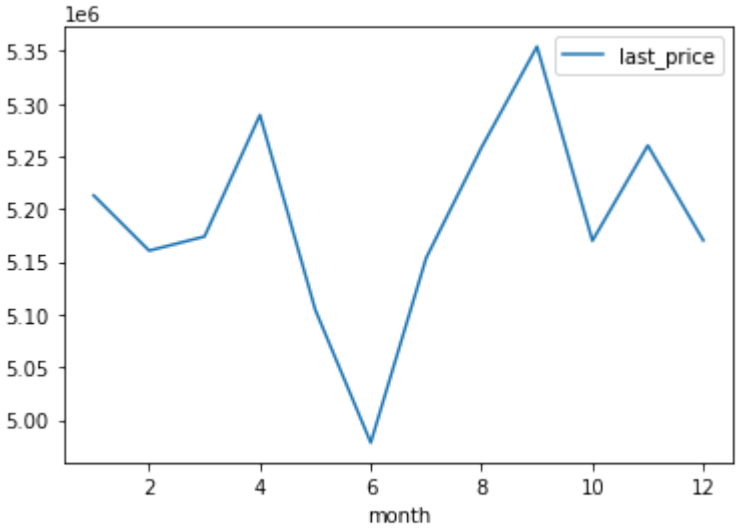

Посчитаем среднюю цену за квадратный метр в 10 населенных пунктах с наибольшим числом объявлений

In [ ]:
```
top10_price_m = data.pivot_table(index = 'locality_name', values = 'price_m', aggfunc=['count', 'mean'])
top10_price_m.columns = ['count', 'mean']
top10_price_m = top10_price_m.sort_values('count', ascending = False)
top10_price_m.head(10)
```

Out[ ]:

locality_name	count	mean
Санкт-Петербург	14146	108603.074085
Мурино	553	85498.848101
Кудрово	445	95142.062921
поселок Шушары	429	78224.370629
Всеволожск	384	67194.148438
Пушкин	341	101938.712610
Колпино	334	75316.068862
поселок Парголово	321	90374.937695
Гатчина	304	68919.016447
Выборг	229	58243.454148

Выведем минимальное и максимальное значение стоимости квадратного метра.

In [ ]:
```
top10_price_m.sort_values(by = 'mean').head(1)
```

Out[ ]:

locality_name	count	mean
деревня Старополье	3	11206.0

In [ ]:
```
top10_price_m.sort_values(by = 'mean', ascending = False).head(1)
```

Out[ ]:

locality_name	count	mean
поселок Лисий Нос	2	113728.0

Самый дешевый квадратный метр в деревне Старополье 10368 руб. Самый дорогой в Санкт-Петербурге 103796 руб.

In [ ]:
```
top10_price_m = top10_price_m.head(10)
```

In [ ]:
```
top10_price_m.sort_values(by = 'mean').plot(kind= 'bar', figsize = (10,6))
plt.show()
```

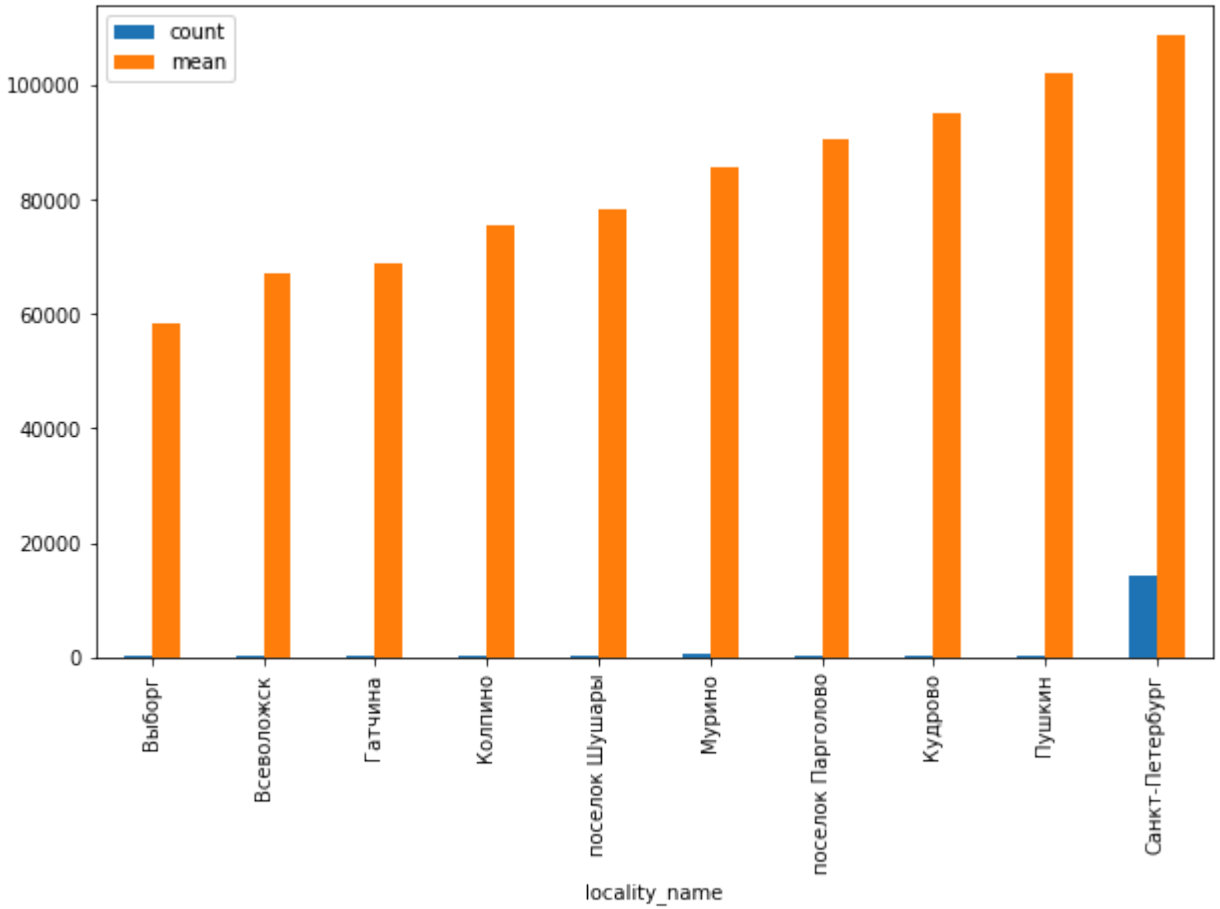

Изучим зависимость стоимости объектов от расстояния до центра города

In [ ]:
```
data.query('locality_name == "Санкт-Петербург"').pivot_table(index = 'cityCenters_nearest', values = 'price_m', aggfunc = 'mean')
plt.show()
```

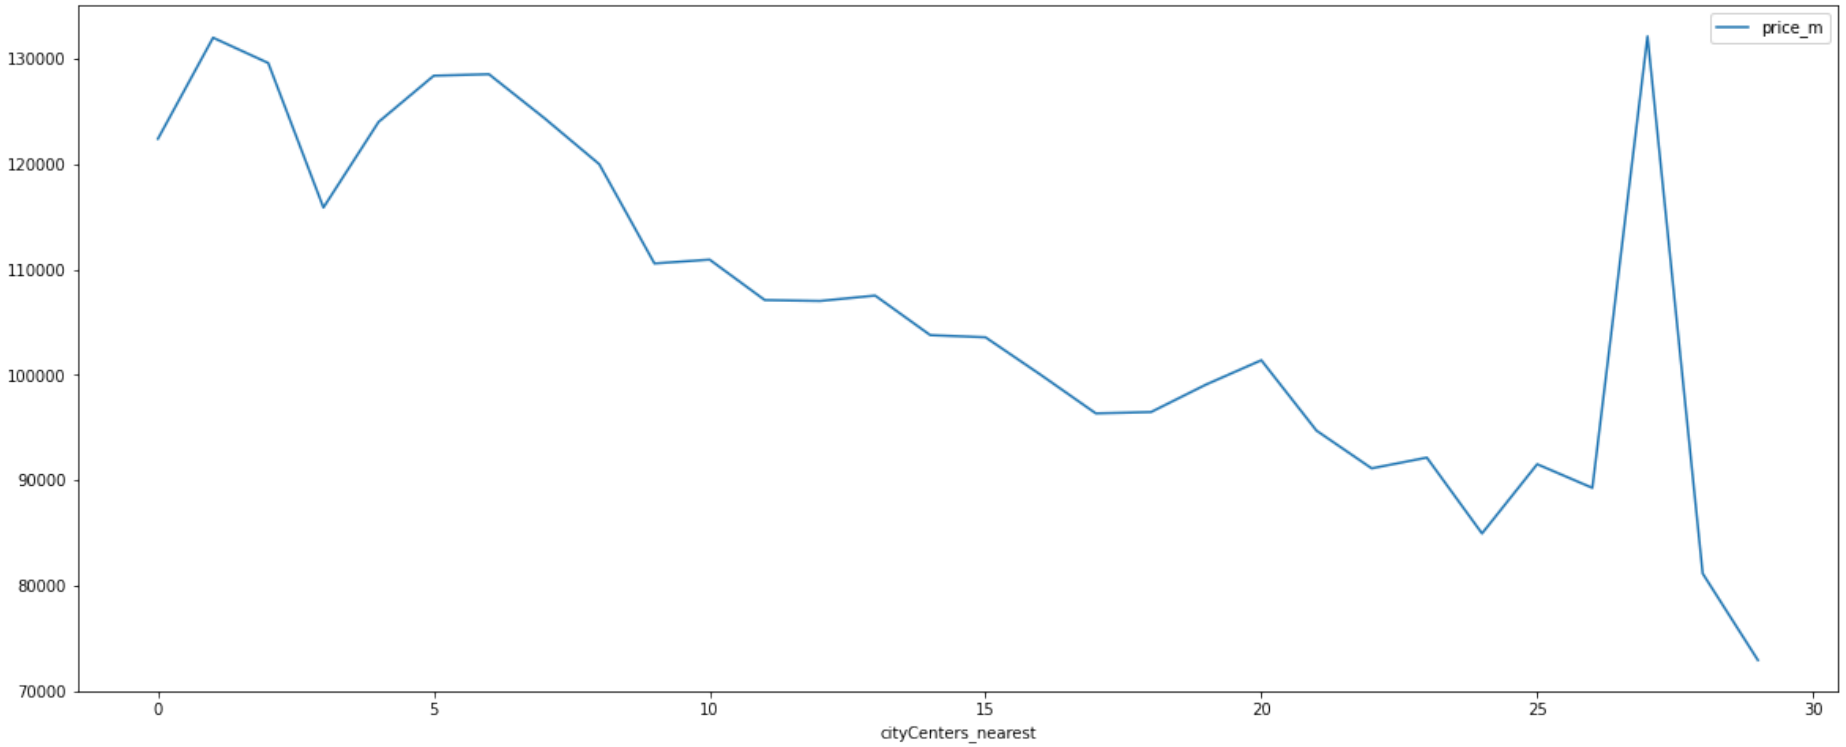

По графику видно, как средняя цена за квадратный метр уменьшается с отдалением от центра. Выведем сводную таблицу со средними значениями цен за каждый километр.

Изучим причину выбросов на 27 км.

In [ ]:
```
data.query('cityCenters_nearest < 28 and cityCenters_nearest > 26')
```

Out[ ]:

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
140	8	16912000	105.70	2016-12-09	2	2.70	3	48.40	1	False	False	False	
439	9	8570000	72.00	2018-08-11	3	3.00	6	42.00	4	False	False	False	
556	0	3500000	28.50	2018-06-06	1	2.50	5	16.00	4	False	False	False	
558	13	4500000	65.50	2017-10-27	3	2.60	10	42.00	7	False	False	False	
748	13	14350000	74.00	2017-11-28	2	3.13	5	30.00	3	False	False	False	
931	8	6650000	69.00	2017-06-20	3	3.20	3	50.00	2	False	False	False	
1138	1	8000000	84.40	2017-08-22	3	2.50	4	60.00	1	False	False	False	
1675	4	3300000	31.00	2017-02-20	1	2.50	4	17.00	3	False	False	False	
1719	12	4200000	38.00	2018-02-12	1	2.70	4	17.00	3	False	False	False	
1904	14	5150000	50.00	2018-11-11	2	NaN	3	30.00	3	False	False	False	
2104	11	3150000	32.00	2018-02-25	1	NaN	5	18.40	3	False	False	False	
2460	15	7500000	78.00	2018-09-19	3	3.00	3	50.00	2	False	False	False	
2776	8	10500000	105.00	2017-12-06	4	3.12	3	76.30	1	False	False	False	
2929	0	5830000	50.00	2017-11-11	2	NaN	3	34.00	3	False	False	False	
2948	23	11350000	75.00	2017-08-15	3	3.50	2	52.70	2	False	False	False	
2953	13	4500000	61.30	2017-10-05	3	2.50	9	37.00	8	False	False	False	
3185	19	4700000	74.20	2017-11-27	4	2.50	9	48.80	4	False	False	False	
3575	7	3680000	42.00	2017-10-31	2	NaN	5	29.90	3	False	False	False	
3579	18	2400000	31.40	2017-09-15	1	2.50	5	17.80	5	False	False	False	
3858	8	5200000	56.00	2019-03-16	2	NaN	18	NaN	6	False	False	False	
3961	11	3500000	31.10	2019-03-13	1	NaN	4	17.70	4	False	False	False	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
4400	4	12300000	78.65	2017-09-09	3	NaN	5	48.00	1	False	False	False	
4676	18	3700000	48.10	2018-12-18	2	2.64	9	27.20	4	False	False	False	
4678	11	4300000	59.00	2018-03-14	3	2.50	9	37.00	9	False	False	False	
4822	10	3100000	30.00	2018-09-18	1	2.50	4	16.00	1	False	False	False	
4842	10	3900000	52.40	2019-01-18	2	2.50	9	32.80	1	False	False	False	
4911	14	2999000	36.00	2018-02-12	1	NaN	17	16.70	17	False	False	False	
5168	7	3650000	33.80	2018-01-21	1	NaN	3	18.50	2	False	False	False	
5261	8	3200000	31.60	2016-04-02	1	NaN	4	17.80	2	False	False	False	
5961	6	2250000	32.00	2018-02-27	1	NaN	2	16.50	2	False	False	False	
5968	1	2800000	31.00	2017-12-26	1	2.60	17	15.00	15	False	False	False	
6028	5	3350000	30.00	2016-06-26	1	NaN	5	17.00	2	False	False	False	
6079	2	3600000	35.20	2019-01-06	1	NaN	9	19.00	4	False	False	False	
6223	9	3730000	57.70	2017-06-02	3	2.50	9	39.50	3	False	False	False	
6316	5	3200000	30.00	2017-08-07	1	2.50	5	16.50	2	False	False	False	
6676	12	3300000	45.00	2018-07-02	2	2.50	4	NaN	2	False	False	False	
6872	9	6000000	56.50	2018-12-12	3	2.60	5	39.00	5	False	False	False	
7103	10	3650000	35.20	2018-10-15	1	2.60	4	18.20	4	False	False	False	
7128	8	3180000	30.00	2018-12-18	1	2.55	4	17.00	1	False	False	False	
7295	14	7950000	50.00	2017-07-06	1	3.00	6	23.00	4	False	False	False	
7555	4	4700000	63.00	2018-10-23	3	2.50	9	38.60	5	False	False	False	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
7793	10	3500000	43.00	2018-10-05	2	NaN	5	28.00	1	False	False	False	
7936	20	5650000	48.60	2018-10-03	2	NaN	3	26.40	2	False	False	False	
7996	17	16600000	106.00	2017-12-02	4	3.20	3	50.00	3	False	False	False	
8213	0	2800000	29.54	2016-09-30	1	NaN	5	16.60	3	False	False	False	
8262	11	3900000	44.00	2019-02-14	2	2.60	5	29.00	2	False	False	False	
8281	17	2290000	31.70	2017-05-29	1	2.50	5	18.50	2	False	False	False	
8285	1	3550000	30.00	2017-11-16	1	2.60	3	17.00	1	False	False	False	
8466	20	4800000	60.00	2017-12-08	3	2.50	9	40.00	3	False	False	False	
9147	5	3500000	42.00	2018-07-18	2	2.55	4	26.50	2	False	False	False	
9241	14	7990000	68.00	2017-10-09	2	NaN	3	43.10	3	False	False	False	
9883	0	4800000	60.00	2016-05-26	3	2.60	9	38.00	7	False	False	False	
10098	9	7400000	70.00	2016-01-27	3	NaN	3	46.50	2	False	False	False	
10117	0	4250000	67.00	2015-07-09	3	2.50	9	39.00	5	False	False	False	
10162	11	8000000	56.79	2017-10-01	2	NaN	5	32.08	5	False	False	False	
10968	4	2850000	39.00	2016-01-12	1	2.50	9	18.00	7	False	False	False	
11002	20	5500000	51.00	2019-03-12	2	2.50	5	31.00	5	False	False	False	
11230	8	3080000	32.00	2018-03-08	1	2.60	4	18.00	2	False	False	False	
11311	14	5790000	50.60	2016-11-08	2	2.50	5	30.10	3	False	False	False	
11352	4	3300000	36.00	2017-06-18	1	2.00	17	15.20	12	False	False	False	
12022	7	3500000	30.50	2019-03-18	1	2.50	4	17.00	2	False	False	False	
12144	10	6300000	52.80	2018-03-06	2	3.00	3	33.00	2	False	False	False	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
12179	9	4240000	55.30	2017-09-20	3	3.00	5	40.70	4	False	False	False	
12466	11	15000000	89.60	2017-01-31	3	NaN	3	57.00	3	False	False	False	
12886	5	2450000	35.00	2017-05-26	1	2.60	17	14.50	10	False	False	False	
13375	3	3650000	31.00	2016-07-01	1	NaN	5	17.00	3	False	False	False	
13620	9	3500000	32.60	2019-01-28	1	2.55	4	22.00	2	False	False	False	
15019	1	2870000	38.80	2018-06-30	1	2.50	24	18.20	13	False	False	False	
15379	12	3900000	43.50	2019-01-27	2	NaN	5	28.20	5	False	False	False	
15415	11	3800000	43.00	2018-03-29	2	2.50	5	28.00	1	False	False	False	
15578	20	16000000	101.90	2018-01-08	2	2.87	4	48.10	1	False	False	False	
15696	1	5350000	66.10	2018-06-01	3	2.50	16	42.40	6	False	False	False	
15721	17	7500000	70.00	2019-01-22	2	3.00	3	40.00	1	False	False	False	
15918	9	7600000	63.00	2017-08-03	1	NaN	4	47.40	4	False	False	False	
15939	6	3850000	44.20	2018-08-31	2	2.40	5	28.60	2	False	False	False	
16097	12	4800000	75.00	2016-05-26	4	2.50	9	48.80	8	False	False	False	
16233	10	7700000	63.60	2014-12-10	3	2.60	4	41.90	3	False	False	False	
16303	0	4350000	58.00	2017-09-10	3	NaN	9	38.20	6	False	False	False	
16855	5	4800000	54.50	2017-04-10	2	NaN	3	35.00	2	False	False	False	
17234	17	3400000	45.00	2017-10-24	2	NaN	10	27.50	9	False	False	False	
17411	11	4300000	56.40	2017-04-23	2	2.76	12	32.00	5	False	False	False	
17847	7	4290000	37.30	2018-01-12	1	3.00	6	14.70	4	False	False	False	

	total_images	last_price	total_area	first_day_exposition	rooms	ceiling_height	floors_total	living_area	floor	is_apartment	studio	open_plan	k
18243	4	2350000	30.60	2017-11-09	1	2.50	5	17.30	2	False	False	False	
18725	5	3100000	30.00	2018-09-22	1	NaN	4	16.50	1	False	False	False	
20481	10	3750000	59.00	2016-06-09	2	NaN	3	36.00	2	False	False	False	
21092	10	9300000	70.00	2018-08-01	2	2.90	4	39.70	3	False	False	False	
21109	5	3450000	32.00	2018-01-22	1	NaN	5	18.00	4	False	False	False	
21280	14	2899000	34.50	2017-03-17	1	2.50	9	21.20	8	False	False	False	
21349	3	4100000	39.00	2017-12-04	1	2.40	4	NaN	2	False	False	False	
21479	7	3600000	43.40	2017-11-01	2	NaN	5	28.10	1	False	False	False	
21680	9	9300000	64.00	2016-02-12	2	3.00	6	38.00	2	False	False	False	
21942	9	3450000	37.50	2018-04-20	1	2.70	12	18.14	7	False	False	False	
22436	10	3100000	36.00	2017-10-27	1	NaN	17	16.00	14	False	False	False	
22503	8	5299000	56.00	2018-03-30	3	2.50	5	38.00	2	False	False	False	
22544	3	3000000	37.00	2015-12-04	1	NaN	12	14.00	4	False	False	False	
22619	8	6000000	50.00	2018-09-25	3	2.50	9	39.00	9	False	False	False	
23286	5	2450000	32.00	2017-03-09	1	2.50	9	20.00	1	False	False	False	
23438	0	4600000	55.00	2017-01-23	3	NaN	4	41.00	4	False	False	False	

In [ ]:
```
data['locality_name'].value_counts()
```

Out[ ]:

Санкт-Петербург	14146
Мурино	553
Кудрово	445
поселок Шушары	429
Всеволожск	384
Пушкин	341
Колпино	334
поселок Парголово	321
Гатчина	304
Выборг	229
Петергоф	192
Красное Село	174
Сестрорецк	172
деревня Новое Девяткино	139
Сертолово	134
Ломоносов	129
Кириши	124
Сланцы	112
Волхов	111
поселок Бугры	109
Кингисепп	104
Тосно	101
Кронштадт	92
Никольское	87
Коммунар	85
Сосновый Бор	84
Кировск	83
Отрадное	78
городской поселок Янино-1	67
Приозерск	66
поселок Металлострой	65
деревня Старая	64
Шлиссельбург	56
Луга	56
Тихвин	48
поселок Стрельна	41
поселок Тельмана	40
поселок Романовка	36
Волосово	36
поселок городского типа имени Свердлова	35
поселок городского типа Кузьмоловский	35
Павловск	34
поселок городского типа Рощино	34
поселок городского типа Сиверский	29

Ивангород	28
городской поселок Мга	26
городской поселок Новоселье	26
Сясьстрой	24
поселок Щеглово	23
Зеленогорск	22
поселок городского типа Вырица	21
поселок Новый Свет	21
поселок Новогорелово	20
поселок Понтонный	20
деревня Лесколово	20
деревня Вартемяги	20
поселок городского типа Синявино	19
Лодейное Поле	19
поселок городского типа Токсово	19
Подпорожье	19
Пикалёво	18
поселок Сосново	17
поселок городского типа имени Морозова	17
деревня Бегуницы	17
деревня Большие Колпаны	16
поселок Аннино	16
Бокситогорск	16
деревня Горбунки	15
городской поселок Назия	15
городской поселок Большая Ижора	15
поселок городского типа Лебяжье	15
поселок городского типа Рахья	15
Новая Ладога	14
поселок городского типа Дубровка	14
Каменногорск	13
поселок Елизаветино	13
поселок городского типа Ульяновка	13
поселок городского типа Кузнечное	13
деревня Гарболово	13
деревня Малое Верево	11
деревня Гостилицы	11
деревня Мистолово	11
Светогорск	11
деревня Сяськелево	10
деревня Низино	10
поселок Войсковицы	10
деревня Лаголово	10
поселок Мичуринское	10

деревня Белогорка	10
деревня Колтуши	10
деревня Малое Карлино	9
поселок Пудость	9
деревня Оржицы	9
деревня Батово	9
поселок Молодцово	9
поселок городского типа Приладожский	9
село Русско-Высоцкое	9
поселок Сельцо	9
городской поселок Павлово	9
деревня Нурма	9
поселок городского типа Советский	9
поселок Кобралово	9
поселок городского типа Красный Бор	8
поселок Ильичёво	8
поселок Запорожское	8
поселок Первомайское	8
деревня Фёдоровское	8
Любань	8
Приморск	8
поселок Суходолье	8
поселок Стеклянный	7
деревня Куттузи	7
городской поселок Фёдоровское	7
деревня Кузьмолово	7
деревня Извара	7
село Павлово	7
деревня Малые Колпаны	7
поселок городского типа Никольский	7
деревня Кипень	7
поселок Углово	7
поселок городского типа Тайцы	6
деревня Лопухинка	6
поселок городского типа Важины	6
деревня Пудомяги	6
поселок Сапёрный	6
поселок Кобринское	6
деревня Калитино	6
деревня Заневка	6
деревня Пеники	6
поселок городского типа Форносово	6
поселок Поляны	6
поселок Победа	6

поселок Новый Учхоз	6
поселок городского типа Мга	6
деревня Лампово	6
поселок Ушаки	6
поселок Терволово	6
деревня Кальтино	6
поселок Семрино	5
деревня Юкки	5
деревня Яльгелево	5
поселок Войскорово	5
городской поселок Рощино	5
поселок Петровское	5
поселок Усть-Луга	5
поселок Гаврилово	5
поселок Глажево	5
поселок городского типа Дружная Горка	5
поселок Селезнёво	5
село Копорье	5
поселок Плодовое	5
поселок Мельниково	5
деревня Разбегаево	4
городской поселок Будогощь	4
поселок Песочный	4
деревня Размételево	4
поселок Торфяное	4
поселок Старая Малукса	4
деревня Парицы	4
поселок Гарболово	4
деревня Келози	4
деревня Большая Вруда	4
поселок Суйда	4
поселок Перово	4
поселок станции Вещево	4
поселок Цвелодубово	4
деревня Агалатово	4
поселок Оредеж	3
поселок Возрождение	3
поселок Глебычево	3
деревня Торошковичи	3
городской поселок Виллози	3
поселок Торковичи	3
Высоцк	3
деревня Старополье	3
поселок Любань	3

деревня Заклинье	3
поселок Заводской	3
деревня Аро	3
поселок Пригородный	3
поселок Лукаши	3
поселок Жилгородок	3
поселок городского типа Лесогорский	3
деревня Старосиверская	3
деревня Ваганово	3
поселок Красная Долина	3
поселок Громово	3
поселок Кикерино	3
село Рождествено	3
деревня Торосово	3
поселок Зимитицы	3
поселок городского типа Ефимовский	3
поселок Молодёжное	3
поселок Котельский	3
поселок станции Громово	3
деревня Глинка	2
деревня Фалилеево	2
поселок Лисий Нос	2
поселок городского типа Вознесенье	2
деревня Ненимяки	2
поселок Серебрянский	2
поселок Сапёрное	2
поселок Кингисеппский	2
поселок Пансионат Зелёный Бор	2
село Путилово	2
поселок Пушное	2
поселок Лесное	2
село Старая Ладога	2
поселок станции Приветнинское	2
деревня Коркино	2
поселок Коробицыно	2
поселок Житково	2
деревня Тарасово	2
поселок городского типа Павлово	2
поселок Усть-Ижора	2
поселок Сумино	2
деревня Старая Пустошь	2
деревня Выскатка	2
село Паша	2
городской поселок Лесогорский	2

поселок Починок	2
деревня Камышовка	2
поселок Ленинское	2
деревня Суоранда	2
поселок станции Свирь	2
деревня Ям-Тесово	2
поселок Барышево	2
городской поселок Советский	2
Рябово	2
поселок городского типа Назия	2
поселок Совхозный	2
деревня Старые Бегуницы	2
поселок Репино	2
деревня Мины	2
садовое товарищество Рахья	1
деревня Большой Сабск	1
деревня Реброво	1
поселок Жилпоселок	1
деревня Большая Пустомержа	1
деревня Иссад	1
поселок городского типа Кондратьево	1
поселок Мыза-Ивановка	1
коттеджный поселок Кивеннапа Север	1
деревня Пустынка	1
садовое товарищество Новая Ропша	1
поселок Высокоключевой	1
деревня Нижняя	1
деревня Пижма	1
поселок Коммунары	1
деревня Раздолье	1
деревня Пчева	1
деревня Рабитицы	1
поселок Ропша	1
поселок при железнодорожной станции Приветнинское	1
деревня Каськово	1
садовое товарищество Садко	1
коттеджный поселок Лесное	1
деревня Щеглово	1
поселок Левашово	1
деревня Ялгино	1
коттеджный поселок Счастье	1
деревня Меньково	1
деревня Шпаньково	1
поселок Рабитицы	1

деревня Пикколово	1
деревня Кисельня	1
поселок при железнодорожной станции Вещево	1
деревня Старое Хинколово	1
поселок Форт Красная Горка	1
деревня Чудской Бор	1
поселок Рябово	1
деревня Русско	1
деревня Кривко	1
деревня Борисова Грива	1
деревня Тойворово	1
поселок Белоостров	1
поселок Ромашки	1
поселок Гончарово	1
поселок Тёсово-4	1
деревня Рапполово	1
поселок Пчевжа	1
деревня Большое Рейзино	1
деревня Терпилицы	1
поселок Цвылёво	1
деревня Зимитицы	1
поселок Каложицы	1
село Никольское	1
поселок Кирпичное	1
поселок Плоское	1
поселок Красносельское	1
поселок Александровская	1
поселок Почап	1
поселок Платформа 69-й километр	1
деревня Малая Романовка	1
деревня Пельгора	1
деревня Снегирёвка	1
деревня Курковицы	1
поселок Володарское	1
деревня Котлы	1
поселок Шугозеро	1
деревня Бор	1
садовое товарищество Приладожский	1
поселок Дружноселье	1
село Шум	1
поселок станции Лужайка	1
поселок Семиозерье	1
поселок Алексеевка	1
поселок городского типа Большая Ижора	1

```
деревня Тихковицы                                                  1
деревня Хапо-Ое                                                    1
деревня Трубников Бор                                              1
поселок Калитино                                                   1
деревня Вахнова Кара                                               1
деревня Сижно                                                      1
поселок Гладкое                                                    1
городской поселок Свирьстрой                                       1
деревня Лупполово                                                  1
поселок Дзержинского                                               1
деревня Мануйлово                                                  1
деревня Куровицы                                                   1
деревня Нижние Осельки                                             1
деревня Лаврики                                                    1
садоводческое некоммерческое товарищество Лесная Поляна           1
деревня Новолисино                                                 1
Name: locality_name, dtype: int64
```

Большая часть строк - это город Пушкин, где Црское село. Исторический объект объясняет высокую стоимость на жилье. Очевидно, что при продаже вместо Пушкина был указан Санкт-Петербург

In [ ]:
```
data.query('locality_name == "Санкт-Петербург"').pivot_table(index = 'cityCenters_nearest',\
                                                             values = 'price_m', aggfunc = 'mean')
```

Out[ ]:

cityCenters_nearest	price_m
0.0	122387.333333
1.0	131978.625954
2.0	129577.454545
3.0	115866.942966
4.0	123990.453831
5.0	128374.314024
6.0	128516.484783
7.0	124369.257764
8.0	119979.808765
9.0	110569.506306
10.0	110933.162242
11.0	107095.751337
12.0	107010.435964
13.0	107522.960545
14.0	103770.166531
15.0	103566.940397
16.0	100013.221498
17.0	96350.104442
18.0	96475.916000
19.0	99090.304636
20.0	101390.913043
21.0	94714.964602
22.0	91136.575758

cityCenters_nearest	price_m
23.0	92157.913580
24.0	84962.000000
25.0	91531.038462
26.0	89285.415094
27.0	132115.000000
28.0	81161.571429
29.0	72952.666667

Общий вывод

Итак, мы выяснили, что самые дорогие объекты недвижимости находятся в Санкт-Петербурге - в среднем 103796 руб. за кв.м. Чем ближе к центру города, тем выше цена за квадратный метр жилья. Самое большое количество объектов в предложениях находятся на расстоянии 11-18 км. от центра города.

В Санкт-Петербурге распределение цены от центра к окраине возрастает.

In [ ]:
```
data.query('locality_name == "Санкт-Петербург"')\
    .pivot_table(index = 'cityCenters_nearest', values = 'last_price', aggfunc = 'mean').plot(figsize=(20,8))
plt.show()
```

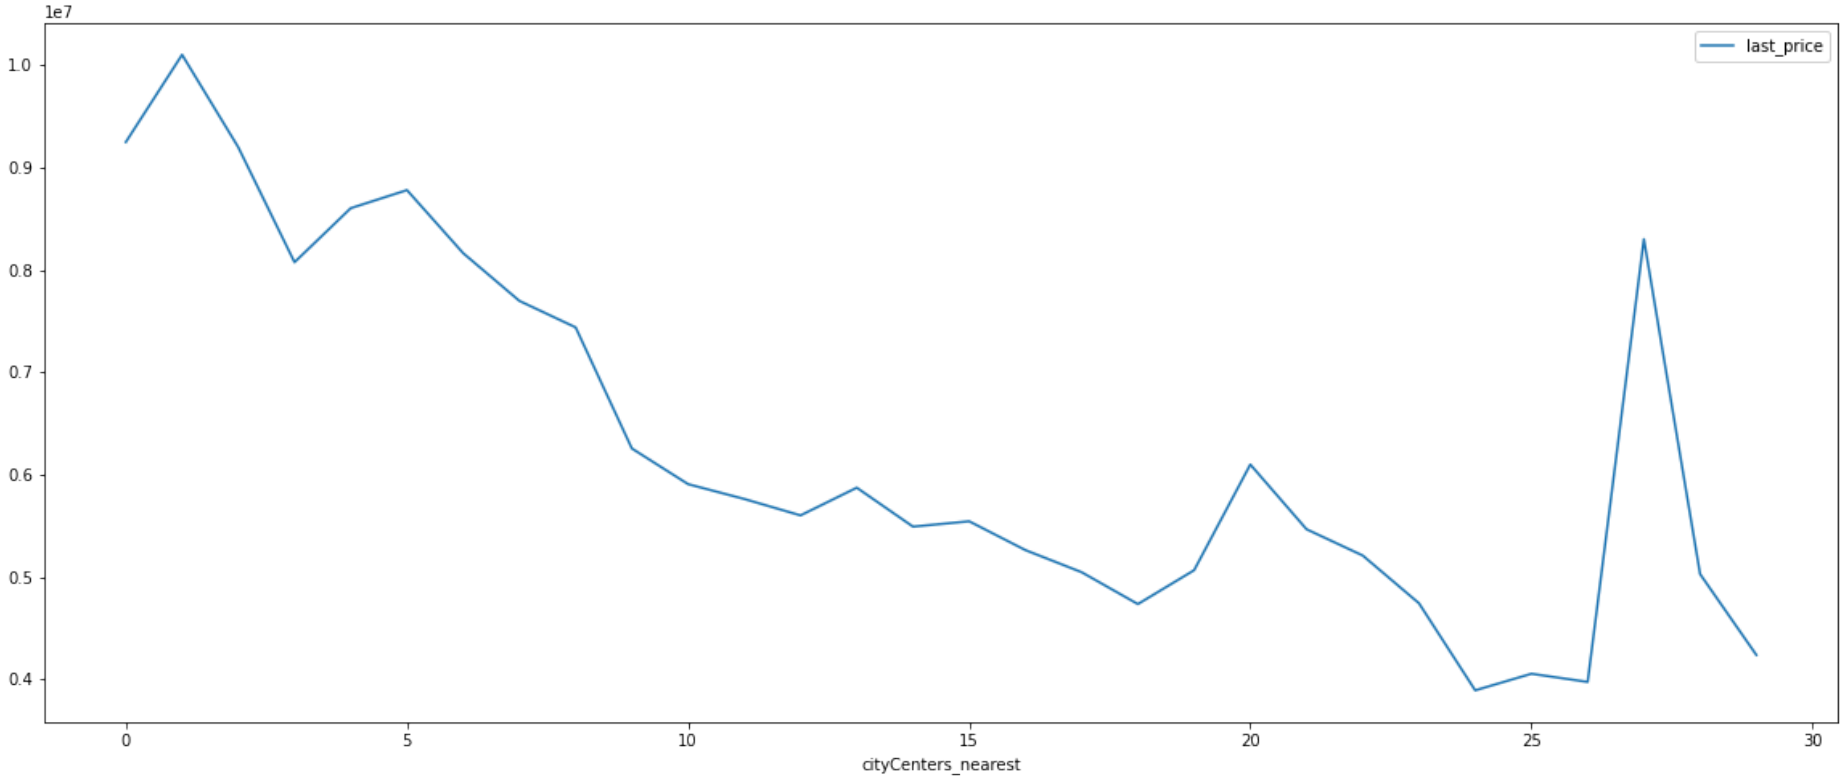

Также цена очень зависит от общей площади квартиры. При этом площадь кухни мало влияет на цену и, практически, не зависит от общей площади.

Этаж, количество комнат и дата размещения объявления слабо влияют на стоимость квартиры. Самая распространенная этажность домов 5ти и 9тиэтажки, скорее всего "хрущевки" и "панельки". Правдоподобно. При этом чаще всего в объявлениях встречаются квартиры на 1-5 этажах.

Большая часть объявлений размещается по четвергам. Меньше всего публикуется по воскресеньям. Чаще всего объекты продаются в течение 90 дней. Но бывают исключения. Большое количество объявлений снимается до 45 дней.